

Fundamentos de Análise de Séries Temporais



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>




Série como composição de componentes

- Uma série temporal pode ser estudada como combinação de tendência, sazonalidade e resíduo.
- Separar componentes ajuda a interpretar estrutura e ruído.
- Muitos detectores de eventos operam sobre um componente específico.

$$x_t = \beta_t + \pi_t + \omega_t$$

Decomposição da temperatura global



A série é separada em tendência, sazonalidade e resíduo.

O que é estacionaridade



Uma série estacionária mantém propriedades estatísticas estáveis ao longo do tempo.



Muitos modelos assumem que média, variância e dependência temporal não mudam.



Quando a hipótese falha, inferência e previsão podem se tornar enganosas.

Média constante

O nível esperado não depende do tempo.

Variância constante


A dispersão não muda ao longo da série.

Autocovariância


Depende da defasagem, não do instante absoluto.

Tipos de não estacionaridade


- Tendência determinística desloca a média ao longo do tempo.
- Quebras estruturais produzem mudanças de nível.
- Heteroscedasticidade altera a variância.
- Raiz unitária produz comportamento difference stationary.




(a) stationary




(b) trend stationary



(c) level stationary




(d) heteroscedastic



(e) random walk

ACF: intuição

- A autocorrelação mede quanto a série se relaciona com versões defasadas dela mesma.
- Em séries estacionárias, a ACF tende a cair rapidamente.
- Em séries não estacionárias, a dependência pode persistir por muitos lags.



Impacto na detecção de eventos

- Não estacionaridade pode parecer anomalia.
- Mudanças de nível podem ser confundidas com outliers persistentes.
- Sazonalidade não tratada pode gerar falsos positivos periódicos.
- Pré-processamento adequado reduz essas ambiguidades.

Por que pré-processar séries temporais



Pré-processamento melhora a qualidade dos dados antes da modelagem.



Em séries temporais, ele também corrige escala, frequência, tendência e dependência temporal.



É uma etapa decisiva para que detectores vejam eventos, não artefatos.


Principais tarefas

- Limpeza: valores ausentes, erros e ruídos.
- Transformação: tendência, variância, decomposição e diferenciação.
- Janelas, normalização e divisão temporal para modelagem e avaliação.

Agregação temporal

- Agrupa observações em uma frequência mais baixa.
- Reduz ruído e simplifica a análise.
- Também pode remover detalhes importantes para eventos curtos.

Frequência e granularidade



A agregação temporal muda o nível de frequência usado na análise.

Formalização da agregação



Uma série X pode ser agregada em blocos de tamanho m .

Cada valor agregado representa a média do bloco correspondente.

No exemplo mensal para anual, $m = 12$.


$$y_j = \text{média de } x \text{ entre } m(j-1)+1 \text{ e } m \cdot j$$

MGT para YGT



Temperatura global mensal agregada em temperatura global anual.

Ganho e perda de informação

Ganho

- Menos ruído local.
- Visualização mais simples.
- Modelagem mais estável em alguns cenários.

Perda

- Eventos curtos podem desaparecer.
- Picos e variações locais são suavizados.
- A escolha da escala altera a interpretação.

Extração de tendência

- Extrair tendência estima o movimento de longo prazo.
- Regressão linear captura tendência monotônica simples.
- Média móvel suaviza flutuações e acompanha variações graduais.

Regressão linear e média móvel



Regressão linear

- Assume uma forma global simples.
- Boa para tendência aproximadamente linear.
- Facilita interpretação.

Média móvel

- Usa vizinhança local.
- Suaviza ruído de curto prazo.
- Depende do tamanho da janela.

Tendência na YGT



Extração de tendência por regressão linear e média móvel.

Estabilização de variância

Algumas séries mudam sua variância ao longo do tempo.

Transformações reduzem heteroscedasticidade.

Isso torna resíduos e erros mais comparáveis ao longo da série.

Log transform e Box-Cox



Log transform

- Reduz amplitude de valores altos.
- Útil para crescimento multiplicativo.
- Exige valores positivos.

Box-Cox

- Família de transformações parametrizada.
- Escolhe λ para estabilizar variância.
- Mais flexível que log simples.

Exemplo de estabilização



Transformação logarítmica e Box-Cox aplicadas à YGT.


Detrending

- Remove uma tendência determinística estimada.
- Permite analisar desvios em torno da tendência.
- É útil quando a tendência é parte esperada do processo.

Differencing

- Substitui valores por diferenças entre observações sucessivas.
- Ajuda a remover tendência estocástica e raiz unitária.
- Muda a interpretação da série: de nível para variação.

Detrending vs differencing



Comparação entre remoção de tendência, diferença simples e mudança percentual.

Decomposição no domínio da frequência



Transformações de frequência representam a série por componentes periódicos.




A FFT identifica frequências relevantes no sinal.




Filtrar frequências pode separar estrutura periódica e resíduo.

Exemplo com EMD



(a) temperature and EMD trend



(c) residual (sum of IMFs)

EMD aplicada à YGT: componente residual de tendência e primeira IMF.


Sliding windows

Janelas deslizantes transformam a série em subsequências.

São base para previsão, classificação, motivos e anomalias intervalares.

A escolha do tamanho da janela define a escala temporal observada.

Subsequências e janelas deslizantes



Uma série pode ser decomposta em janelas que se deslocam ao longo do tempo.

Normalização

- Normalização coloca valores em escalas comparáveis.
- É essencial para métodos baseados em distância e ML.
- Sem normalização, amplitude pode dominar forma e similaridade.

Min-Max, decimal scaling e Z-Score

Escala fixa

Min-Max coloca valores em faixa definida.

Decimal scaling ajusta ordem de grandeza.

Útil para entrada de modelos.






Padronização

Z-Score remove média e divide pelo desvio.

Produz média zero e variância um.

Muito usado em comparação de subsequências.

Exemplo de normalização






Comparação visual de técnicas de normalização em série temporal.

Divisão treino/teste em séries temporais


- Em séries temporais, a ordem dos dados precisa ser preservada.
- Treino deve ocorrer antes do teste.
- Embaralhar dados cria vazamento de futuro e avaliação irrealista.

Cross-validation temporal



Exemplos de divisão treino/teste e validação temporal com previsão step-ahead.

Cross-validation com sliding window




Treino e teste com janelas deslizantes de tamanho três.

Erros comuns de avaliação

- Embaralhar observações temporais.
- Normalizar usando informação do conjunto de teste.
- Escolher hiperparâmetros olhando o futuro.
- Comparar modelos em protocolos temporais diferentes.

Processo geral de predição



Pipeline de predição: aquisição, pré-processamento, modelagem, predição, pós-processamento e avaliação.

Métricas de predição

- **MSE** mede erro quadrático médio.
- **sMAPE** mede erro percentual simétrico.
- **RSS** mede soma dos resíduos ao quadrado.
- **R²** mede proporção da variância explicada pelo modelo.


Modelos estatísticos

- Modelam estrutura temporal com hipóteses explícitas.
- Incluem ARIMA, modelos estruturais, espaço de estados, suavização exponencial e GARCH.
- São importantes como baseline e como fonte de resíduos para detecção de eventos.

ARIMA: intuição

- Combina autoregressão, diferenciação e média móvel.
- Modela dependência temporal e pode lidar com não estacionaridade por differencing.
- Resíduos de ARIMA são úteis para detectar anomalias por desvio do esperado.


Exemplo com ARIMA



(a) ARIMA(1, 1, 3) four-step-ahead prediction


Modelo ARIMA ajustado no treino e previsão quatro passos à frente.

ML com sliding windows



Modelos de ML usam valores defasados como entrada para prever a próxima observação.

Redes neurais, Conv1D e LSTM



(a) LSTM four-step-ahead prediction

Exemplo de LSTM com quatro entradas para previsão quatro passos à frente.