

Detecção de Eventos em Séries Temporais



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>




Evento como trecho informativo

Um evento é um instante ou intervalo em que a série muda de forma relevante.

A relevância depende do domínio: clima, saúde, indústria, segurança, finanças.

A ideia central é procurar mudanças que carregam mais informação para análise ou decisão.

Exemplo guia: temperatura global anual



YGT obtida da NOAA: uma série univariada usada como exemplo recorrente.

Formalização básica de série temporal


Uma série temporal X é uma sequência ordenada de n observações.

Cada observação x_t é indexada pelo tempo t .

A ordem dos dados é parte do significado: permutar a sequência destrói informação temporal.

$$X = \langle x_1, x_2, x_3, \dots, x_n \rangle, \quad |X| = n, \quad t \in \{1, \dots, n\}$$

Taxonomia de eventos em séries temporais



A taxonomia organiza tipos de eventos, estruturas de dados, cenários, métodos e avaliação.

Eventos pontuais: ideia geral

Um evento pontual ocorre quando uma característica temporal foge do esperado.

A expectativa pode ser estimada pelo passado, pelo futuro ou pela divergência entre os dois lados.

Essa visão permite unificar anomalias e pontos de mudança.

$tc(xt)$: valor, tendência ou volatilidade em t

Eventos pontuais: formalização

$ep(tc(xt), k)$: característica esperada a partir das k observações anteriores.

$ef(tc(xt), k)$: característica esperada a partir das k observações seguintes.

σ define a tolerância para considerar uma mudança significativa.

$$e(X, k, \sigma) = \{t : |tc(xt) - ep| > \sigma \vee |tc(xt) - ef| > \sigma \vee |ep - ef| > \sigma\}$$

Anomalias: intuição

Uma anomalia é uma observação que não se ajusta ao comportamento típico da série.

Pode representar erro, falha, incidente crítico ou mudança externa.

Em análise aplicada, interessa menos o valor isolado e mais o desvio em relação ao contexto temporal.

Anomalias: formalização

A observação é anômala quando escapa do esperado antes e depois do instante t .

Essa condição separa uma irregularidade local de uma transição de regime.

$$a(X, k, \sigma) = \{t : |tc(xt) - ep(tc(xt), k)| > \sigma \wedge |tc(xt) - ef(tc(xt), k)| > \sigma\}$$

Anomalias por resíduos

Ajusta-se um modelo α para estimar a série esperada.

O resíduo mede o que o modelo não explicou.

Se o modelo estiver bem ajustado, resíduos extremos indicam candidatos a evento.

$$\omega_t = x_t - \hat{x}_t, \text{ com } \hat{x}_t = \alpha(x_t)$$

Limiar para resíduos extremos


Paramétrico: assume resíduos aproximadamente gaussianos e usa média ± 3 desvios.

Não paramétrico: evita suposição de distribuição e usa quartis e distância interquartil.

Gaussiano: $w_t \notin [\bar{W} - 3 \cdot \text{sd}(W), \bar{W} + 3 \cdot \text{sd}(W)]$

Boxplot: $w_t \notin [Q1(W) - 1.5 \cdot \text{IQR}(W), Q3(W) + 1.5 \cdot \text{IQR}(W)]$

Anomalias no exemplo YGT



Anomalias marcadas em vermelho a partir da análise dos resíduos de um modelo ARIMA.

Change points: intuição

- Um change point indica uma transição entre regimes da série.
- A mudança pode ocorrer na média, variância, correlação, tendência ou outro parâmetro.
- Diferente da anomalia, o novo comportamento pode continuar após o ponto de mudança.

Change points: formalização

O instante t é compatível com um lado da vizinhança, mas não com ambos.

Também há mudança quando as expectativas antes e depois de t diferem acima de σ .

$$cp(X, k, \sigma) = \{t : (|tc(xt) - ep| > \sigma \sqcap |tc(xt) - ef| > \sigma) \vee |ep - ef| > \sigma\}$$

Change point como teste de hipótese


A ausência de mudança sugere distribuições semelhantes ao longo do tempo.

A presença de mudança sugere ao menos uma vizinhança com distribuição diferente.

Essa leitura conecta change point detection e concept drift.

$$H_0: P_n(t) \approx P_n(k) \quad H_A: \text{existe } k \text{ tal que } P_n(t) \neq P_n(k)$$

Change points no exemplo YGT



Linhas tracejadas indicam pontos de mudança detectados com estatística de Chow.

Motifs: padrões que se repetem

Um motif é uma subsequência aproximadamente recorrente dentro de uma série maior.

A repetição revela estrutura: sazonalidade local, comportamento recorrente ou assinatura de processo.

Motifs são úteis para classificação, explicação, compressão e descoberta de padrões.


Discords: padrões que não se repetem

Um discord é uma subsequência muito diferente das demais.

Ele pode ser visto como uma anomalia intervalar.

A dificuldade está em comparar subsequências sem explodir o custo computacional.

Motifs e discords no ECG



Três sequências anotadas: podem ser um motif raro ou discords, dependendo da interpretação.

Motif: definição operacional

Dada uma sequência q e uma série X , q é motif se ocorre em X ao menos σ vezes.

A descoberta exige uma noção de distância ou similaridade entre subsequências.

A busca ingênua compara muitas subsequências e tende a custo $O(n^2)$.


$$q \text{ é motif em } X \Leftrightarrow \text{ocorrências}(q, X) \geq \sigma$$

Estrutura dos dados

Séries temporais podem ser vetores, tabelas, matrizes ou objetos especializados.

Eventos podem ser representados por rótulos, intervalos, timestamps ou escores.

A estrutura escolhida influencia diretamente o método e a avaliação.

Granularidade dos eventos

Eventos pontuais

Associados a um instante específico.

Representados por timestamp e atributos do evento.

Exemplo: pico de temperatura em um ano.

Eventos intervalares

Possuem início e fim.

Demandam análise de duração e sobreposição.

Exemplo: período prolongado de chuva intensa.

Granularidade no exemplo de temperatura

year\month	1	2	3	4	5	6	7	8	9	10	11	12
1971	13.9	13.8	13.8	13.8	13.9	13.8	13.9	13.9	13.9	13.8	13.9	13.9
1972	13.7	13.7	14.0	14.0	13.9	14.0	14.0	14.0	13.9	14.0	14.0	14.0
1973	14.3	14.3	14.3	14.2	14.1	14.2	14.1	14.0	14.0	14.0	13.9	14.0
1974	13.8	13.7	13.9	13.9	13.9	13.8	13.9	14.0	13.9	13.8	13.8	13.8
1975	14.0	14.0	14.0	14.0	14.0	14.0	13.9	13.9	13.9	13.8	13.7	13.8
1976	13.9	13.8	13.8	13.9	13.8	13.9	13.9	13.9	13.9	13.7	13.9	14.0
1977	14.1	14.1	14.2	14.2	14.2	14.2	14.1	14.1	14.1	14.0	14.1	14.0
1978	14.1	14.1	14.1	14.0	14.0	14.0	14.0	13.9	14.0	14.0	14.1	14.0
1979	14.0	13.8	14.1	14.0	14.1	14.1	14.1	14.2	14.2	14.2	14.2	14.4
1980	14.3	14.3	14.2	14.2	14.3	14.2	14.2	14.1	14.1	14.1	14.2	14.1

(a)

year	value
1971	13.8
1972	13.9
1973	14.1
1974	13.8
1975	13.9
1976	13.9
1977	14.1
1978	14.0
1979	14.1
1980	14.2

(b)

Temperatura global mensal agregada para temperatura global anual entre 1971 e 1980.

Dimensionalidade

Univariada

Uma variável observada ao longo do tempo.

Estrutura simples, frequentemente um vetor com índice temporal.

Boa para introduzir conceitos e métodos básicos.

Multivariada

Duas ou mais variáveis observadas no tempo.

Permite estudar relações, dependências e causas prováveis.

Aumenta a complexidade de modelagem e interpretação.

Representações univariadas e multivariadas

value
13.8
13.9
14.1
13.8
13.9
13.9
14.1
14.0
14.1
14.2

(a)

time	value
1971	13.8
1972	13.9
1973	14.1
1974	13.8
1975	13.9
1976	13.9
1977	14.1
1978	14.0
1979	14.1
1980	14.2

(b)

time	global temperature	crude oil production
1971	13.8	2491
1972	13.9	2634
1973	14.1	2870
1974	13.8	2875
1975	13.9	2740
1976	13.9	2966
1977	14.1	3069
1978	14.0	3108
1979	14.1	3229
1980	14.2	3111

(c)

Vetor univariado, série com coluna temporal e série multivariada.

Famílias de métodos de detecção



Regressão

Modela o valor esperado e procura desvios.



Classificação

Aprende rótulos de evento quando há dados anotados.



Clustering

Encontra grupos e isola padrões pouco frequentes.



Estatísticos e baseados em domínio

Usam hipóteses, limites ou conhecimento especialista.

Teoria, dados e aprendizado

Theory-driven

- Parte de hipóteses e modelos do domínio.
- Mais interpretável quando o processo é bem conhecido.
- Exemplo: modelos físicos, regras clínicas, limites operacionais.

Data-driven

- Aprende padrões diretamente dos dados.
- Inclui KNN, K-Means, SVM, redes neurais, Conv1D e LSTM.
- Depende de volume, qualidade e representatividade dos dados.

Cenários de detecção

Offline

Identifica eventos depois que a série já foi coletada.

Online

Detecta eventos à medida que novas observações chegam.

Predição

Estima a ocorrência futura de eventos a partir do histórico.

Online muda as restrições


- O algoritmo não pode olhar para o futuro.
- A decisão precisa ocorrer antes da próxima observação ou com atraso controlado.
- Fluxos de alta velocidade exigem baixa latência, pouco ajuste manual e atualização contínua.

$\langle \dots, x_{t-2}, x_{t-1}, x_t, x_{t+1}, \dots \rangle \Rightarrow$ decidir sobre x_t antes de x_{t+1}

Avaliação de detecção de eventos

- Compara a saída do algoritmo com eventos de referência.
- Métricas usuais: precisão, revocação, F1-score e AUC-ROC.
- Eventos intervalares exigem cuidado com tolerância temporal, sobreposição e atraso.

Como podemos organizar o tema



Do fundamento de séries temporais aos tipos de eventos, detecção online, avaliação e desafios.