

Detecção de Anomalias em Séries Temporais




Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Taxonomia de anomalias



A taxonomia organiza tipo, circunstância, dimensão, interpretação e forma de aprendizado.

Anomalias pontuais vs sequenciais



Pontuais

- Uma única observação difere significativamente do restante da série.
- A decisão depende do contexto local e do modelo do comportamento típico.
- É a forma mais direta de anomalia, mas não necessariamente a mais fácil de detectar.

Sequenciais

- Uma subsequência inteira apresenta comportamento incomum.
- O ponto isolado pode parecer aceitável, mas a sequência completa revela o evento.
- Exige comparar janelas, formas ou representações temporais.

Ponto vs sequência no exemplo de Seattle



Exemplo com temperatura semanal: anomalia pontual no painel (a) e sequência anômala no painel (b).

Anomalias contextuais vs fora de contexto

Anomalias contextuais

A observação não é estranha por si só.

Ela se torna anômala quando considerada no **contexto temporal**.

Exemplo: 26°C pode ser comum no verão, mas anômalo no inverno.

Anomalias fora de contexto

O valor é atípico **independentemente** do instante em que ocorre.

A explicação não depende fortemente da vizinhança temporal.

Esse caso se aproxima da noção clássica de **outlier estatístico**.

Univariada vs multivariada

Univariada

Uma variável é analisada ao longo do tempo.

A anomalia aparece como valor ou sequência atípica naquela série.

Métodos são mais simples e interpretáveis.


Multivariada

A anomalia pode surgir da combinação entre variáveis.

Cada variável isolada pode parecer normal.

Relações entre dimensões passam a importar.

Anomalia multivariada com PCA



O exemplo mostra anomalias capturadas pela relação entre variáveis, não apenas por valores extremos individuais.

Séries rotuladas e não rotuladas

Rotuladas

Cada observação pode indicar presença ou ausência de anomalia.

Permite avaliação e aprendizado supervisionado.

Rótulos podem ser incompletos ou temporalmente imprecisos.

Não rotuladas

Não há indicação direta do que é anomalia.

A detecção depende de hipótese estatística, distância ou raridade.

É o caso mais comum em aplicações reais.

Cenários de aprendizado

Supervisionado

- Usa observações com rótulos de típico/anômalo.
- A anomalia é tratada como classe a ser prevista.
- O problema central é a escassez e a imperfeição dos rótulos.

Semissupervisionado

- Treina o modelo apenas com dados típicos.
- Novas observações são anômalas quando não se ajustam ao padrão aprendido.
- É comum quando a classe anômala é rara ou difícil de rotular.

Não supervisionado

- Não requer rótulos para treinamento.
- Assume que observações típicas são mais frequentes ou mais densas.
- É flexível, mas exige cuidado maior na interpretação dos alertas.

Quando usar cada cenário


Mais rótulos

- **Supervisionado** quando os rótulos são confiáveis.
- Útil em operação online depois de uma fase de treinamento.
- Permite otimizar métricas como F1.

Menos rótulos

- **Semissupervisionado** quando há exemplos típicos confiáveis.
- **Não supervisionado** quando quase não há rótulo.
- Exige análise posterior dos alarmes.

Exemplo-base para comparar métodos



Série sintética do Harbinger: região de treinamento e teste permitem comparar famílias de detectores.



A mesma série é usada para contrastar famílias de detectores.



Nem todo método encontra o mesmo tipo de anomalia.



O objetivo é entender a hipótese operacional de cada família, não ranquear algoritmos.

Regressão por janela deslizante: fundamentos

O modelo aprende o comportamento esperado da série e produz uma estimativa $\hat{x}_t$ para cada instante t . A anomalia é caracterizada por erro, resíduo ou distância incomum entre x_t e $\hat{x}_t$. O objetivo é dar intuição operacional: como a janela deslizante vira exemplo supervisionado e como o erro vira escore.

	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	$\hat{x}_t$	x_t
5	v_1	v_2	v_3	v_4	$\hat{v}_5$	v_5
6	v_2	v_3	v_4	v_5	$\hat{v}_6$	v_6
7	v_3	v_4	v_5	v_6	$\hat{v}_7$	v_7
8	v_4	v_5	v_6	v_7	$\hat{v}_8$	v_8
9	v_5	v_6	v_7	v_8	$\hat{v}_9$	v_9
10	v_6	v_7	v_8	v_9	$\hat{v}_{10}$	v_{10}
11	v_7	v_8	v_9	v_{10}	$\hat{v}_{11}$	v_{11}
12	v_8	v_9	v_{10}	v_{11}	$\hat{v}_{12}$	v_{12}
13	v_9	v_{10}	v_{11}	v_{12}	$\hat{v}_{13}$	v_{13}
14	v_{10}	v_{11}	v_{12}	v_{13}	$\hat{v}_{14}$	v_{14}

(a)

Janela deslizante

Uma janela de tamanho p usa observações passadas como atributos. O alvo é a próxima observação. A cada instante, a janela anda uma posição.

$$\langle x_{t-p}, \dots, x_{t-2}, x_{t-1} \rangle \rightarrow x_t$$

Exemplo tabular (p=5)

Com $p = 5$, uma linha contém quatro defasagens e um alvo. A série passa a ser vista como regressão supervisionada. Preservar ordem temporal: treino antes, teste depois.

$$[x_{t-4}, x_{t-3}, x_{t-2}, x_{t-1}] \rightarrow x_t$$

Os termos defasados $x_{t-4}, \dots, x_{t-1}$ predizem x_t ; a diferença entre previsão e observação vira resíduo.

Do erro ao escore de anomalia

Depois da previsão, calcula-se uma distância entre x_t e $\hat{x}_t$.

Esse valor é o escore de desvio do modelo.

Quanto maior o escore, maior a evidência de que o comportamento observado não foi esperado pelo modelo.

$$\omega_t = \text{distance}(x_t, \hat{x}_t)$$

Do escore ao limiar

Escolhas de distância

Erro absoluto

- Mantém a escala original da série.
- É fácil de explicar para o domínio.
- Menos agressivo com erros muito grandes.

Erro quadrático

- Amplifica erros grandes.
- É comum em regressão e otimização.
- Pode aumentar a sensibilidade a picos.

Como decidir o limiar

O modelo gera uma série de resíduos $\mathbf{W} = \langle \omega_1, \dots, \omega_n \rangle$. A detecção depende de separar resíduos típicos de resíduos extremos. Essa separação pode ser **paramétrica**, **não paramétrica** ou **baseada em valores extremos**.

Estratégias de limiar

Gaussiano

- Assume distribuição gaussiana dos resíduos típicos.
- Resíduos muito distantes da média são anomalias.
- Simples, mas frágil com distribuições assimétricas ou multimodais.

$$wt > média(W) + 3 \cdot sd(W)$$

Boxplot

- Não exige assumir distribuição específica.
- Usa quartis e distância interquartil.
- Normalmente interessa o limite superior dos erros.

$$wt > Q3(W) + 1,5 \cdot IQR(W)$$

Valores extremos (EVT)

- Modela especificamente a cauda da distribuição dos erros.
- Útil quando os eventos relevantes são raros e extremos.
- Mais adequada em detecção online; evita hipótese simples para toda a distribuição.

Famílias de regressão

Seguidores de tendência

- Suavizam ou decompõem a série para estimar o comportamento esperado.
- Exemplos: média móvel, splines, FFT, wavelet, EMD, REMD e FBIAD.
- A anomalia aparece quando a observação se afasta da curva seguida.


Modelos estatísticos

- ARIMA e regressão linear com hipóteses estatísticas explícitas.
- Bons quando há estrutura temporal interpretável: autocorrelação, tendência ou sazonalidade.
- Resíduo direto: o que sobrou depois do modelo.

Aprendizado de máquina

- A janela deslizando permite usar modelos supervisionados gerais.
- Exemplos: KNN, SVM, Random Forest, XGBoost, MLP e ELM.
- O detector continua baseado no erro entre previsão e observação.

ARIMA como detector por desvio



O modelo ajustado estima a série; resíduos altos ao redor das anomalias sustentam a detecção.

Regressores avançados e lógica comum

Regressores profundos

- Conv1D e LSTM exploram padrões temporais em sequências.
- DeepAnT usa redes convolucionais para prever a próxima janela e detectar desvios.
- Telemanom e detectores LSTM usam erro de previsão para localizar comportamento inesperado.

Métodos recentes e híbridos

- Triple Exponential Smoothing incorpora nível, tendência e sazonalidade.
- Median Method usa a mediana da janela contextual como previsão robusta.
- Métodos híbridos e ensembles combinam modelos para reduzir fragilidades individuais.

O que muda e o que permanece

Muda o modelo esperado

ARIMA, média móvel, spline, RF, XGBoost, LSTM. Cada um captura uma forma diferente de padrão temporal. Modelo ruim gera resíduo ruim.

Permanece a lógica

Prever x_t . Calcular erro. Comparar erro com uma referência de normalidade.

Classificação: anomalia como classe

Um classificador aprende a separar observações típicas e anômalas.

Durante o treinamento, os rótulos precisam estar disponíveis.

Durante o teste, o modelo prediz o rótulo das novas observações.



t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\hat{e}_t$	e_t
5	v_1	v_2	v_3	v_4	v_5	$\hat{b}_5$	b_5
6	v_2	v_3	v_4	v_5	v_6	$\hat{b}_6$	b_6
7	v_3	v_4	v_5	v_6	v_7	$\hat{b}_7$	b_7
8	v_4	v_5	v_6	v_7	v_8	$\hat{b}_8$	b_8
9	v_5	v_6	v_7	v_8	v_9	$\hat{b}_9$	b_9
10	v_6	v_7	v_8	v_9	v_{10}	$\hat{b}_{10}$	b_{10}
11	v_7	v_8	v_9	v_{10}	v_{11}	$\hat{b}_{11}$	b_{11}
12	v_8	v_9	v_{10}	v_{11}	v_{12}	$\hat{b}_{12}$	b_{12}


(a)

t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\hat{e}_t$
13	v_9	v_{10}	v_{11}	v_{12}	v_{13}	$\hat{b}_{13}$
14	v_{10}	v_{11}	v_{12}	v_{13}	v_{14}	$\hat{b}_{14}$

(b)

Na etapa de treino, a janela tem rótulo; na etapa de teste, o modelo prediz a presença de anomalia.

Exemplo com SVM




O SVM detecta parte das anomalias no teste; o exemplo também evidencia falso negativo.

Desafio da classificação

- Anomalias são raras, gerando forte desbalanceamento de classes.
- Rótulos humanos podem perder eventos ou marcar o instante com atraso.
- A classe aprendida pode não representar anomalias futuras ainda não vistas.


Agrupamento: anomalia como distância

- Observações típicas formam grupos ou regiões densas.
- Anomalias aparecem longe dos representantes ou fora dos grupos.
- A abordagem é naturalmente não supervisionada.



Cada janela é associada a um grupo; a distância ao representante apoia a detecção.

Exemplo com K-Means



Sequências distantes dos centroides são marcadas como anômalas.

Limitações do agrupamento



A escolha de k e da métrica de distância afeta diretamente a detecção.



Escala e normalização podem mudar quais pontos parecem distantes.





Dados com anomalias no treinamento podem formar grupos espúrios.

Métodos estatísticos

- Assumem que observações típicas ocupam regiões de alta probabilidade.
- Anomalias aparecem em regiões de baixa probabilidade.
- Podem usar modelos paramétricos, testes de hipótese ou perfis não paramétricos.

Exemplo com histograma




Bins raros ou fora do intervalo típico indicam candidatos a anomalia.

Métodos espectrais


- Projetam os dados em um espaço de menor dimensão.
- A estrutura principal da série deve ser preservada na projeção.
- Anomalias aparecem como observações mal representadas ou mal reconstruídas.

Autoencoder: arquitetura



A forma de ampulheta força a rede a aprender uma representação compacta dos padrões típicos.

Autoencoder: erro de reconstrução



Sequências mal reconstruídas produzem erro alto e são marcadas como anômalas.

Anomalias de volatilidade


A anomalia não está necessariamente no nível da série, mas em sua variabilidade. ARCH e GARCH modelam a volatilidade instantânea. Esse caso é central em risco financeiro e em séries com variação não linear.

Formalização

A característica temporal passa a ser a volatilidade $v(x_t)$. O evento ocorre quando a volatilidade foge do esperado antes e depois de t .

$$v_a(X, k, \sigma) = \{t : |v(x_t) - e_p(v(x_t), k)| > \sigma \wedge |v(x_t) - e_f(v(x_t), k)| > \sigma\}$$

Exemplo com GARCH



A região entre as linhas tracejadas tem aumento de volatilidade; o detector encontra anomalias internas e um falso positivo.