

Pontos de Mudança e Desvio de Conceitos



CEFET/RJ

Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Por que detectar mudanças importa

Modelos de previsão e descoberta de padrões só são válidos enquanto o processo observado permanece semelhante.

Mudanças afetam controle, monitoramento, alerta e adaptação de modelos.

O instante da mudança pode ser tão importante quanto a existência da mudança.

Change point vs concept drift

Change point

Localizar o instante ou intervalo em que a dinâmica da série muda.

Concept drift

Monitorar mudanças que afetam a relação entre dados e modelo ao longo do tempo.

Na prática


Change point enfatiza segmentação; drift enfatiza validade e adaptação do modelo.

O que é um change point

É uma observação que marca transição entre dinâmicas distintas da série.

A mudança pode envolver distribuição, tendência, média, variância, volatilidade ou autocorrelação.

Quando a mudança é gradual, o ponto exato pode ser ambíguo.



A série é dividida em cinco segmentos, com mudanças de volatilidade, tendência e regime.

Segmentos e tipos de mudança

Cada segmento entre change points representa uma dinâmica temporal própria. A detecção busca fronteiras que tornam os segmentos internamente homogêneos, separando mudanças reais de flutuações locais.

Mudanças bruscas

Transição abrupta entre regimes.

Ponto de mudança mais fácil de localizar.

Comum em falhas, intervenções e quebras estruturais.

Mudanças graduais

Transição distribuída em um intervalo.

O instante exato é menos evidente.

Pode envolver tendência, deriva ou volatilidade.

Configurações do problema: modo e número de mudanças

A forma de detectar change points depende de como os dados chegam e de quanto se sabe sobre o número de mudanças esperadas.

Offline vs Online

Offline

A série já foi coletada. O objetivo é explicar quando as dinâmicas mudaram. Pode usar informação antes e depois da mudança.

Online

As observações chegam em fluxo. A decisão precisa ser rápida. Há trade-off entre atraso e falso alarme.

Número de change points


Conhecido

O problema é localizar m mudanças. Mais comum em análise offline controlada. Permite formular busca por melhores partições.

Desconhecido

O método precisa decidir quantos segmentos existem. Superdetecção gera falsos positivos. Subdetecção gera falsos negativos.

Taxonomia de change point detection



Os métodos se organizam por busca via segmentação, regressão ou janelas deslizantes.

Estratégias de busca por change points

Os métodos de detecção se diferenciam pela forma como percorrem a série em busca de candidatos a change point.

Busca por segmentação

Intuição: Procura partições que tornem cada segmento internamente coerente, minimizando distância dentro dos segmentos ou maximizando diferença entre eles.

- Avalia a qualidade global da partição.
- Quando o número de segmentos cresce, é preciso penalizar soluções muito fragmentadas.
- Exemplos: AMOC, BinSeg, PELT.

Busca por regressão

Intuição: Avalia breakpoints por meio de modelos de regressão ajustados aos segmentos. Um bom breakpoint reduz o erro de ajuste de forma significativa.

- Compara o ajuste de um modelo único com modelos separados por segmento.
- Sensível a quebras estruturais nos parâmetros do modelo.
- Exemplos: Chow Test, GFT/CUSUM.

Busca por janelas deslizantes

Intuição: Analisa subsequências de tamanho fixo ao longo da série. Dentro de cada janela, testa-se se há diferença relevante entre o comportamento antes e depois de um candidato.

- Não requer que toda a série esteja disponível.
- Adequada para detecção online e em fluxo.
- Exemplos: SCP, Change Finder.

Detectores por verossimilhança – AMOC, BinSeg e PELT

Buscam a partição da série que melhor explica os dados sob um critério probabilístico. Comparam um regime único contra múltiplos segmentos.

AMOC

Intuição: Testa se existe exatamente uma mudança em toda a série. Cada candidato k divide X em dois segmentos e a razão de verossimilhança decide se a divisão é melhor que um regime único.

- **H0:** série explicada por uma única distribuição (parâmetros θ_0).
- **H1:** segmentos antes e depois de k têm parâmetros θ_1 e θ_2 distintos.

1

BinSeg

Intuição: Aplica AMOC recursivamente. Encontra a primeira mudança, divide a série e repete o processo em cada segmento gerado.

- Abordagem gulosa: não garante ótimo global.
- Eficiente e útil como aproximação prática.
- Número de mudanças pode ser fixado ou controlado por limiar.

PELT

Intuição: Busca a segmentação globalmente ótima usando programação dinâmica com poda (pruning) para ganhar eficiência.

- Usa penalização para evitar excesso de change points.
- Complexidade linear quando os pontos crescem de forma controlada.
- Garante solução ótima, ao contrário do BinSeg.

Detectors por regressão e resíduos – Chow Test e GFT/CUSUM

Ajustam modelos de regressão à série e avaliam se os parâmetros ou os resíduos acumulados indicam quebra estrutural.

Chow Test

Intuição: Testa se os parâmetros de um modelo de regressão linear permanecem estáveis ao longo do tempo. Um bom breakpoint reduz significativamente o erro de ajuste.

- Modelo base: $y_t = \beta_t x_t + \omega_t$
- Compara RSS do modelo único com a soma dos RSS dos dois segmentos.
- Estatística F alta indica evidência de quebra estrutural.

$$F = \frac{(RSS - ESS)}{ESS / (n - 2r)}$$

GFT / CUSUM

Intuição: Ajusta um modelo e monitora as flutuações acumuladas dos resíduos. Sob estabilidade, o processo fica dentro de limites esperados; sob mudança, apresenta pico próximo ao change point.

- Baseado em resíduos do modelo ajustado.
- Sob H_0 , o processo acumulado converge para um movimento browniano.
- O pico da estatística indica a localização provável da mudança.


$$W_n^0(u) = \frac{1}{\hat{\sigma}\sqrt{n}} \cdot \sum \hat{\omega}_i$$

Detectores por janela deslizante – SCP e Change Finder

Analisa subsequências locais da série, comparando o comportamento antes e depois de um candidato dentro de uma janela móvel.

SCP

Intuição: Desliza uma janela pela série e, em cada posição, compara o ajuste de uma regressão única com regressões separadas antes e depois do candidato. O ponto com maior ganho de ajuste é o change point.




Compara o ajuste de uma regressão única com regressões separadas antes e depois do candidato.

Change Finder

Intuição: Opera em duas fases sequenciais para separar outliers de mudanças estruturais, usando modelos autoregressivos e suavização.

1. Ajusta um modelo autoregressivo e identifica outliers nos resíduos.
2. Aplica média móvel aos resíduos para dar inércia ao sinal.
3. Uma segunda modelagem dos resíduos suavizados permite marcar change points com maior precisão.

Comparação dos detectores de change point



Verde indica acerto, azul indica evento perdido e vermelho indica detecção incorreta.

Concept drift: definição e formalização

Mudança no conceito aprendido ou monitorado ao longo do tempo. Afeta a validade de modelos em ambientes dinâmicos e é central em cenários online, streaming e aprendizado adaptativo.

Conceito como distribuição

- Dados D são organizados em batches.
- O conceito em um batch é a distribuição associada aos dados observados.
- Mudança de conceito = mudança estatisticamente relevante nessa distribuição.


$$\text{concept}(SD_i) = p(\chi_i)$$

Drift como mudança entre distribuições

- Entre batches consecutivos, drift ocorre quando as distribuições deixam de ser equivalentes.
- A diferença pode ocorrer nos dados de entrada, na relação $X \rightarrow Y$ ou no erro do modelo.

$$p(\chi_i) \neq p(\chi_{i+1})$$

Taxonomia de concept drift



A taxonomia organiza tipos de drift, tipos de detector, métodos e formas de tratamento.

Drift real vs virtual

Virtual drift

A distribuição dos dados de entrada muda.

A relação com a variável-alvo pode permanecer válida.

Pode afetar representatividade e amostragem.





Real drift

A relação entre entrada e saída muda.

O modelo perde validade preditiva.

Normalmente exige adaptação ou retreinamento.

Tipos de drift



Drifts podem ser abruptos, incrementais, graduais ou recorrentes.

Detectar mudança vs adaptar modelo

Detectar drift responde se o conceito mudou.

Adaptar o modelo responde o que fazer depois da mudança.

Um detector sensível demais causa falso alarme; um detector conservador reage tarde.

Tipos de detector de drift

Baseados em erro

Monitoram queda de desempenho do modelo.

DDM, HDDM, CUSUM e ECDD seguem essa linha.

Dependem de rótulo ou feedback.


Baseados em distribuição

Comparam batches, janelas ou amostras.

MCDD, KLD, KSWIN, Page-Hinkley e ADWIN são exemplos.


Podem atuar antes do impacto no erro.

Tratamento de drift



Baseline não reage, passive atualiza continuamente e active atualiza após detecção.

Framework geral de drift detection



Quando atualizar o modelo

- Atualização contínua pode acompanhar mudanças, mas também absorver ruído.
- Atualização após alarme reduz custo, mas depende de boa detecção.
- A escolha depende de latência aceitável, custo de retreinamento e risco de falso alarme.

O framework combina dados em fluxo, monitoramento, detecção e eventual adaptação do modelo.

Detectores baseados em erro – DDM, HDDM e Hoeffding bound

Monitoram a taxa de erro do modelo ao longo do fluxo. Indicam drift real quando o desempenho cai de forma persistente.

DRIFT REAL

DDM

Intuição: Monitora a taxa de erro de um classificador. Se o erro cresce persistentemente além de um limiar estatístico, sinaliza mudança de conceito.

- Compara erro atual com o mínimo histórico observado.
- Dois limiares: aviso e alarme.

DRIFT REAL

HDDM

Intuição: Versão do DDM com controle probabilístico mais rigoroso, usando desigualdades estatísticas.

- Usa desigualdade de Hoeffding para limitar falsos alarmes.
- Mais robusto a flutuações aleatórias do que o DDM clássico.

FUNDAMENTO ESTATÍSTICO

Hoeffding bound

Intuição: Garante que diferenças grandes entre estimativas amostrais são improváveis por acaso — base para decisão incremental em fluxo.

$$\Pr(|\bar{x} - E[x]| \geq \varepsilon) \leq 2 \exp(-2n\varepsilon^2)$$

Detectores por acumulação de desvio – CUSUM, Page-Hinkley e ECDD

Acumulam evidências de desvio ao longo do tempo. Sensíveis a mudanças persistentes e graduais. Indicam principalmente drift real.

DRIFT REAL

CUSUM

Intuição: Acumula desvios sucessivos em relação ao comportamento esperado. Quando a soma ultrapassa um limiar, sinaliza mudança.

- Simples e incremental.
- Sensível a mudanças persistentes de média.

$$z_t = \max(0, z_{t-1} + \omega_t - \delta)$$

DRIFT REAL

Page-Hinkley

Intuição: Variação do CUSUM que acumula diferenças em relação à média corrente, adaptando-se ao nível atual da série.

- Funciona bem para mudanças abruptas de média.
- Mais sensível a shifts unidirecionais.

DRIFT REAL

ECDD

Intuição: Usa EWMA (média móvel exponencial) para suavizar a taxa de erro, dando inércia ao monitoramento e reduzindo falsos alarmes.

- Detecta quando o seguidor EWMA se afasta do limite de controle.
- Equilibra sensibilidade e estabilidade.

Detectores baseados em distribuição – MCDD, KSWIN, KLD e ADWIN

Comparam distribuições entre janelas de dados. Detectam tanto drift virtual (mudança nos dados de entrada) quanto drift real (mudança na relação $X \rightarrow Y$).

DRIFT VIRTUAL / REAL

MCDD

Intuição: Compara batches recentes e anteriores avaliando média e variância das variáveis preditoras. Pode usar testes paramétricos ou não paramétricos.

- Detecta mudança nos dados de entrada (virtual) ou no erro (real).
- Flexível na escolha do teste estatístico.

DRIFT VIRTUAL / REAL

KLD

Intuição: Mede o excesso de surpresa ao usar a distribuição antiga P para explicar os dados recentes Q . Drift é indicado quando a divergência ultrapassa um limiar.

$$D_{KL}(P\|Q) = \sum P(x_i) \cdot \ln \left(\frac{P(x_i)}{Q(x_i)} \right)$$

DRIFT VIRTUAL / REAL

KSWIN

Intuição: Usa o teste Kolmogorov-Smirnov para comparar a distribuição de duas janelas deslizantes, sem exigir suposição paramétrica.

- Não paramétrico: funciona para qualquer distribuição.
- Sensível a mudanças de forma, não apenas de média.

DRIFT REAL

ADWIN

Intuição: Mantém uma janela de tamanho variável. Divide-a em parte antiga e recente e testa diferença estatística. Quando detecta mudança, descarta a parte antiga.

- Adapta automaticamente o tamanho da janela.
- Sem necessidade de definir janela fixa a priori.

Tópicos avançados e desafios práticos

Séries multivariadas e espaço-temporais

- Mais dimensões aumentam a dificuldade de localizar e explicar mudanças.
- Mudanças podem surgir nas relações entre variáveis, não apenas em cada série isolada.
- Dados espaço-temporais adicionam dependência espacial, mobilidade e padrões regionais.

Métodos espectrais

- PCA e autoencoders reduzem dimensionalidade e capturam representações compactas.
- Drifts podem aparecer como mudança na reconstrução ou no espaço latente.
- Esses métodos são promissores para séries multivariadas, não estacionárias e em fluxo.

Desafios práticos

- **Atraso:** detectar cedo o suficiente para agir.
- **Falso alarme:** evitar adaptação desnecessária.
- **Custo:** manter monitoramento e retreinamento viáveis.
- **Interpretação:** explicar que tipo de mudança ocorreu.