

Motif Discovery em Séries Temporais



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Por que motivos importam

Motivos revelam padrões recorrentes que ajudam a explicar a estrutura interna de uma série temporal. Em domínios como saúde, clima, finanças e sensores, esses padrões repetidos podem representar estados ou comportamentos relevantes — e a ausência de um motivo esperado também pode ser informativa.

Dois lados da mesma moeda

Motif Discovery

Procura **repetição**: identifica subsequências similares que aparecem mais de uma vez na série.

O objetivo é encontrar padrões frequentes que caracterizam um comportamento recorrente.

Anomaly Detection

Procura **raridade ou desvio**: identifica observações ou subsequências incomuns (discords).

Os dois problemas se conectam: o que não se parece com nenhum motivo pode ser exatamente uma anomalia.

O que é um motif

Um **motif** é uma subsequência recorrente em uma série temporal, descoberta automaticamente ao varrer a série e comparar janelas deslizantes — sem precisar conhecer o padrão previamente.

Ocorrências de uma sequência

Dada uma sequência q de tamanho p , extraímos de X todas as janelas deslizantes W de mesmo tamanho. As ocorrências de q são as janelas suficientemente similares a q :

$$\text{occurs}(q, X) = \{w_i \mid w_i \in W \wedge w_i \approx q\}$$

A relação $w_i \approx q$ depende da medida de similaridade adotada — na prática, distância abaixo de um limiar ou similaridade acima de um corte.

Formalização de motif


Uma sequência q é motif quando aparece vezes suficientes na série. O parâmetro **suporte** σ define o número mínimo de ocorrências, e o tamanho p da sequência é chamado de **word size**:

$$\text{motif}(q, X) \iff |\text{occurs}(q, X)| \geq \sigma$$

Motifs triviais e exclusion zone

Janelas vizinhas tendem a ser muito parecidas por sobreposição, o que pode inflar artificialmente o suporte. A **exclusion zone** impede que matches muito próximos no tempo sejam contados como ocorrências distintas.

Taxonomia de motif discovery



A descoberta depende de indexação, função de similaridade e método de busca.

Por que indexar séries temporais

- Comparar todas as subsequências diretamente pode ser caro.
- Indexação reduz dimensionalidade, discretiza valores ou organiza candidatos.
- O objetivo é acelerar a busca preservando padrões relevantes.

Normalização em séries temporais

Duas subsequências podem ter a mesma forma em escalas diferentes. Sem normalização, amplitude e deslocamento dominam a distância — tornando a comparação insensível à forma do padrão. Normalizar corrige esse viés.

Z-Score

Produz média zero e variância um. Ideal para comparações baseadas em forma, independente de escala absoluta.

Min-Max

Escala os valores para uma faixa definida, como $[0, 1]$. Preserva a proporção relativa entre os pontos da série.

Adaptativas

Lidam melhor com não estacionaridade local, ajustando a normalização dinamicamente ao longo da série.

PAA – Piecewise Aggregate Approximation

A PAA reduz uma série temporal substituindo segmentos contíguos pela sua média, tornando o sinal mais compacto e menos sensível ao ruído local. É também uma ponte natural para métodos simbólicos como o SAX.

Compactação

Reduz n observações para n' observações, preservando a estrutura global da série.

Robustez ao ruído

A média por segmento atenua variações locais espúrias, focando nas tendências essenciais.

Ponte para SAX

Serve de base para a discretização simbólica, permitindo análises qualitativas e buscas eficientes.

Formalização

A série X é particionada em segmentos de mesmo tamanho. Cada valor x'_j da série transformada representa a média dos valores originais no segmento j :

$$x'_j = \frac{1}{|seg_j|} \sum_{t \in seg_j} x_t$$

A transformação mapeia as n observações originais para n' valores agregados, com $n' < n$.

SAX – Symbolic Aggregate approXimation

O SAX transforma uma série temporal (tipicamente após a PAA) em uma sequência de símbolos discretos, permitindo buscar e comparar padrões como palavras num alfabeto.

Transformação simbólica

Valores numéricos são mapeados para letras de um alfabeto, reduzindo a representação a símbolos discretos.

Intervalos equivalentes

Valores em faixas semelhantes recebem o mesmo símbolo, tornando a representação robusta a pequenas variações.

Padrões como palavras

Com o *word size* definido, cada janela da série vira uma palavra simbólica, habilitando agrupamento e *matching* eficiente.


Formalização

O tamanho do alfabeto a define quantas faixas são usadas. Os **breakpoints** β separam os intervalos de discretização. Para cada valor x_t da série PAA, o símbolo correspondente é determinado pelo intervalo em que ele cai:

$$x_t \in [\beta_{k-1}, \beta_k) \Rightarrow \text{símbolo } k$$

Os breakpoints β são escolhidos de forma a produzir faixas equiprováveis sob uma distribuição gaussiana normalizada, garantindo uso balanceado de todos os símbolos do alfabeto.

ECG: normalização, PAA e SAX



Exemplo de batimento cardíaco normalizado, agregado por PAA e discretizado com limiares SAX.

Similaridade: medidas e escolhas

Motif discovery depende de decidir quando duas subsequências são parecidas. A escolha da medida de distância muda quais padrões serão considerados motivos — e não há medida universal: a escolha depende do fenómeno e das distorções esperadas.

Lock-step

Compara ponto a ponto, mantendo alinhamento rígido entre as séries temporais.

- Simples e eficiente computacionalmente
- Sensível a desalinhamentos e variações de ritmo

Medidas elásticas

Permitem desalinhamento temporal e variações de ritmo entre as séries.

- DTW é o exemplo clássico
- Mais robustas a distorções temporais

Distância Euclidiana

Compara duas sequências de mesmo tamanho **ponto a ponto**, somando as diferenças ao quadrado entre cada par de elementos. É simples, rápida e amplamente usada — funciona bem quando as subsequências estão alinhadas no tempo.

- Dadas duas sequências q e q' de tamanho p , a distância acumula as diferenças ponto a ponto ao quadrado.
- Quanto **menor** o valor resultante, **maior** a similaridade entre as duas sequências.

Formalmente, a distância euclidiana é definida como:

$$EDist(q, q') = \sqrt{\sum_{i=1}^p (q_i - q'_i)^2}$$

Distância de Hamming

Compara duas sequências de mesmo tamanho **símbolo a símbolo**, contando quantas posições diferem entre si. É a medida natural para sequências simbólicas — como as palavras geradas pelo algoritmo SAX — e equivale ao número mínimo de substituições necessárias para tornar as duas sequências idênticas.



Cada posição contribui com **zero** para a distância se os símbolos forem **iguais**.



Cada posição contribui com **um** para a distância se os símbolos forem **diferentes**.

Formalmente, a distância de Hamming é definida como:

$$HDist(q, q') = \sum_{i=1}^p HItem(q_i, q'_i)$$

onde a função auxiliar *HItem* é:

$$HItem(x, y) = \begin{cases} 0 & \text{se } x = y \\ 1 & \text{caso contrário} \end{cases}$$

DTW – Dynamic Time Warping

Dynamic Time Warping é uma técnica que permite alinhar sequências que evoluem em **ritmos diferentes**, sendo especialmente útil quando a forma importa mais do que o alinhamento exato no tempo.

O método procura um **caminho de menor custo** na matriz de distâncias entre os pontos das duas sequências.


A matriz acumula o menor custo para alinhar **prefixos** das duas sequências, onde cada célula depende de vizinhos já calculados.

O custo final representa a **distância elástica** entre as sequências.

Formalmente, o custo acumulado é calculado por programação dinâmica:

$$dtw_{i,j} = custo(i, j) + \min (dtw_{i-1,j}, dtw_{i,j-1}, dtw_{i-1,j-1})$$

Exemplo visual de DTW



(a)

$$\min(|2 - 3| + 2, |2 - 3| + 1, 2|2 - 3| + 1) = 2$$

(b)

DTW entre duas sequências pequenas, mostrando matriz de custo e cálculo por programação dinâmica.

Famílias de métodos de descoberta



Brute-force

Compara tudo com tudo.



Index-based

Reduz e discretiza para acelerar a busca.



Random Projection

Usa amostragem e colisões para candidatos prováveis.



Matrix Profile

Estrutura distâncias para revelar motifs e discords.

Brute-force Discovery

A abordagem mais direta para descoberta de motivos: comparar tudo com tudo, de forma exata.

Intuição

- Extrai todas as subsequências de tamanho q .
- Compara cada subsequência com todas as demais.
- É exato, mas o custo cresce rapidamente com o tamanho da série.

Algoritmo e Complexidade

- Normaliza a série.
- Para cada subsequência, verifica quais outras estão abaixo de ϵ .
- Se o número de ocorrências atinge σ , registra um motif.
- A complexidade é **$O(n^2)$** vezes o custo da distância.

Index-based Discovery

Em vez de comparar todas as subsequências numéricas diretamente, esta abordagem usa representações simbólicas para encontrar motivos de forma eficiente.


Intuição

- Evita comparar diretamente todas as subsequências numéricas.
- Usa PAA e SAX para representar janelas como palavras simbólicas.
- Motifs aparecem como palavras ou grupos simbólicos recorrentes.

Pipeline PAA/SAX e Agrupamento

- A série é normalizada, agregada (PAA) e discretizada (SAX).
- Janelas simbólicas iguais ou próximas são agrupadas no espaço simbólico.
- Grupos com suporte suficiente viram candidatos a motif.

Motifs detectados com SAX



Index-Based Discovery encontra motifs em batimentos regulares no ECG.

Random Projection

Abordagem probabilística para descoberta eficiente de motivos em séries temporais simbólicas.

Intuição

- Projetar reduz a dimensão considerada na comparação.
- Subsequências similares tendem a colidir nas mesmas projeções.
- O método troca busca exaustiva por evidência probabilística de similaridade.

Colisões e Suporte

- Executa projeções múltiplas sobre janelas simbólicas.
- Uma matriz de colisões acumula candidatos recorrentes.
- Motifs são selecionados entre candidatos com suporte alto.

Early-abandon distance

- Interrompe o cálculo de distância quando o erro parcial já excede ϵ .
- Economiza tempo evitando completar comparações que não podem virar match.
- Mantém a lógica do brute-force, mas reduz custo prático.

Matrix Profile

Para cada subsequência de uma série temporal, o Matrix Profile guarda a distância até sua subsequência mais parecida — revelando padrões e anomalias de forma eficiente.

Distâncias baixas → Motifs

Subsequências com vizinhos muito parecidos: padrões recorrentes na série.

Distâncias altas → Discords

Subsequências sem par próximo: comportamentos incomuns ou anomalias.

Estrutura de dados

Vetor M

Armazena a **menor distância** encontrada para cada subsequência.


Índice I

Aponta **onde está** a subsequência mais parecida para cada posição.

Exclusion Zone

Em self-join, evita **matches triviais** próximos da diagonal principal.

Motifs detectados com Matrix Profile



Matrix Profile com STAMP também encontra motifs em batimentos regulares no ECG.

Matrix Profile: Motifs e Discords

O mesmo vetor **M** que revela padrões recorrentes também aponta subsequências isoladas — tudo depende do valor da distância ao vizinho mais próximo.

↓ Menores valores: Motifs

- Um valor **baixo** em **M** indica que existe uma subsequência muito parecida em outro ponto da série.
- Pares com baixa distância são candidatos naturais a motifs.
- Ocorrências adicionais podem ser buscadas a partir desses pares.

↑ Maiores valores: Discords

- Um valor **alto** em **M** indica isolamento da subsequência.
- A subsequência não tem vizinhos próximos no restante da série.
- Essa leitura conecta motif discovery com detecção de anomalias intervalares.

- O Matrix Profile mede a distância ao vizinho mais próximo — se até esse vizinho está longe, a subsequência é candidata a discord.

Extensões de Motif Discovery

Além do cenário básico univariado e de tamanho fixo, aplicações reais exigem extensões que lidam com maior complexidade estrutural e dimensional.

Motifs Multivariados

Séries com múltiplas dimensões apresentam o desafio de capturar relações entre variáveis sem explodir o espaço de busca. As abordagens incluem:

- Redução de dimensionalidade antes da busca
- Combinação de descobertas por dimensão
- Busca conjunta sobre todas as variáveis

Em muitos casos, os motifs mais relevantes emergem justamente na *interação entre variáveis*, não em cada uma isoladamente.

Tamanho Variável de Motifs

A maioria dos métodos assume um tamanho fixo q , mas na prática o comprimento do padrão pode ser desconhecido a priori. As estratégias para contornar essa limitação incluem:

- Busca em faixas de tamanhos candidatos
- Concatenação de motifs menores em padrões compostos
- Penalização por complexidade para selecionar o tamanho ideal

Ambas as extensões são desafios complementares: um expande o espaço *dimensional*, o outro expande o espaço *temporal* da busca.

Ranking de motivos e ocorrências

- Nem todo padrão recorrente é interessante.
- Motifs podem ser ranqueados por suporte, similaridade, entropia, raridade ou densidade das ocorrências.
- Padrões triviais ou quase constantes podem ser descartados.

Escalabilidade e métodos modernos

Desafios de escala

Séries longas tornam comparação e armazenamento desafiadores.

iSAX, SWAMP, mSTAMP e algoritmos disk-aware atacam escala e memória.

Em streaming, o método precisa atualizar candidatos sem recomputar tudo.

Métodos modernos

STAMP e SCRIMP calculam Matrix Profile com estratégias eficientes e anytime.

STOMP explora localidade para reduzir custo computacional.

AAMP calcula Matrix Profile com distância Euclidiana não normalizada.