

Detecção Online de Eventos



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Por que o cenário online muda o problema

No offline, a série completa está disponível para análise.

No online, observações chegam continuamente e a decisão precisa ser tomada no fluxo.

O método precisa equilibrar rapidez, precisão, memória e capacidade de adaptação.

Três cenários de eventos

Detecção offline

Reconhecer eventos passados.

- A série já foi coletada antes da análise.
- O algoritmo pode olhar para passado e futuro em torno de um candidato a evento.
- É adequada para auditoria, explicação retrospectiva e benchmark de métodos.

Detecção online

Detectar eventos enquanto eles acontecem.

- As observações chegam em sequência.
- O detector precisa decidir usando apenas o que já chegou.
- A decisão deve ser rápida o suficiente para permitir reação operacional.

Predição online

Antecipar eventos antes que ocorram.

- O objetivo é prever a ocorrência futura de um evento.
- É uma forma antecipatória de event detection.
- A utilidade depende de emitir alerta antes que a ação deixe de ser possível.

Treino e teste: tradicional vs streaming


Cenário tradicional

- A série é dividida em treino e teste de forma estática.
- O modelo é ajustado com dados passados e avaliado em dados mais recentes.
- Validação temporal e ajuste de hiperparâmetros ocorrem antes da implantação.


Cenário streaming

- Cada batch pode treinar ou atualizar o modelo para o próximo batch.
- A ordem temporal é parte do protocolo experimental.
- Esse desenho imita a operação de um sistema que aprende com o fluxo.

Treinamento e teste: tradicional vs streaming



(a)



(b)

No streaming, o batch i é usado para construir ou atualizar o modelo avaliado no batch i+1.

Online detection: definição e restrições

O que é online detection

É a identificação de eventos conforme as observações chegam. O detector processa a série sequencialmente. Todo aprendizado, atualização e decisão ocorre durante a execução.

Formalização do fluxo temporal

A série online é um fluxo contínuo de entradas. Em t , o modelo usa observações anteriores para decidir sobre o comportamento atual. A decisão precisa ocorrer antes que o fluxo avance demais.

$\langle \dots, x_{t-2}, x_{t-1}, x_t, x_{t+1}, x_{t+2}, \dots \rangle$

Não dá para olhar para o futuro

No online, usar observações futuras viola o cenário operacional. Alguns eventos só ficam claros depois de algumas observações. Isso cria uma tensão inevitável entre decisão imediata e confirmação confiável.

Early detection

Detectar cedo pode evitar falhas, perdas ou danos.

O valor do alerta depende do tempo disponível para agir.

Em sistemas críticos, atraso pequeno pode ser a diferença entre prevenção e diagnóstico tardio.

Rapidez vs falso positivo

Detector sensível

Reage rapidamente.

Pode antecipar eventos importantes.

Tende a gerar mais falsos positivos.

Detector conservador

Exige mais evidência.

Reduz alarmes indevidos.

Pode detectar tarde ou perder eventos.

Fast data e sistemas críticos

Fast data envolve grande volume, alta velocidade e mudança em intervalos curtos.

Redes, IoT, indústria, saúde e segurança exigem monitoramento contínuo.

A solução precisa operar sob restrições de tempo, memória e confiabilidade.

Modelos estáticos vs dinâmicos

Estáticos

- Treinados antes da implantação.
- Permanecem inalterados durante a execução.
- Funcionam quando a distribuição é estável.

Dinâmicos

- São atualizados com novos dados.
- Podem acompanhar mudanças no fluxo.
- Exigem política de memória e adaptação.

Por que offline não migra diretamente



Métodos offline podem depender da série completa.



O custo computacional pode ser incompatível com fluxo contínuo.



A presença de drift muda a noção de comportamento típico.



Métricas offline podem ignorar atraso temporal da detecção.

Por que memória vira problema



Em fluxo contínuo, guardar todas as observações pode ser inviável.



Mesmo quando armazenamento é possível, reprocessar tudo pode ser caro demais.



A política de memória define o que o modelo lembra e o que esquece.

Estratégias de gerenciamento de memória

Full-memory

- Mantém todas as observações ou batches vistos até o momento.
- Preserva histórico completo.
- Tende a ser impraticável para fluxos longos, rápidos ou de alta dimensão.

No-memory


- O modelo é atualizado incrementalmente sem armazenar histórico bruto.
- É leve em memória.
- Pode esquecer detalhes úteis ou sofrer com atualizações ruidosas.

Windowed memory


- Mantém apenas uma janela recente de observações ou batches.
- Equilibra memória, adaptação e contexto temporal.
- A escolha do tamanho da janela controla o quanto o modelo lembra.

Gerenciamento de memória


(a) full memory



(b) no memory



(c) windowed memory



Full-memory, no-memory e windowed memory definem estratégias diferentes de retenção do histórico.

Estratégias de atualização do modelo

Retreinamento por batches recentes

- O modelo pode ser reconstruído usando apenas batches recentes.
- Isso ajuda a acompanhar mudanças no processo.
- O custo é descartar parte do histórico e depender da representatividade da janela.

Aprendizado incremental

- O modelo é atualizado a cada exemplo ou batch.
- A nova versão depende da versão anterior e dos dados recém-chegados.
- É adequado para fluxo, mas precisa lidar com ruído, drift e esquecimento.

Não estacionaridade, concept drift e adaptação

Não estacionaridade

O processo gerador pode mudar ao longo do tempo. O que era típico ontem pode deixar de ser típico hoje. Essa mudança afeta diretamente detectores treinados no passado.

Concept drift

Concept drift ocorre quando o conceito aprendido muda no fluxo. Modelos precisam reconhecer que a definição de comportamento típico evoluiu. Isso aproxima detecção online de change point detection e adaptação de modelo.

Dilema estabilidade-plasticidade

Estabilidade: resistir a variações irrelevantes e ruído. Plasticidade: adaptar-se rapidamente a mudanças reais. Um bom sistema online precisa equilibrar as duas forças.

Estratégias de adaptação a drift

Active learning

- O sistema tenta detectar drift antes de adaptar o modelo.
- A atualização ocorre quando há evidência de mudança.
- Reduz adaptações desnecessárias, mas depende da qualidade do detector de drift.

Passive learning

- O modelo é atualizado continuamente, independentemente de alarme de drift.
- Pode acompanhar mudanças graduais.
- Pode absorver ruído ou eventos raros como se fossem parte do comportamento normal.

Online prediction

Vai além de detectar eventos passados ou em andamento. Busca prever se um evento ocorrerá em uma janela futura. É útil quando o objetivo é mitigação, prevenção ou alerta antecipado.

Predição por classificação

- Extrai sequências e atributos de observações anteriores.
- O modelo prevê rótulos de evento para novas observações.
- É adequada quando há rótulos confiáveis para treinar o classificador.

Predição por regressão

- Usa o histórico $X = \langle x_1, \dots, x_t \rangle$ para prever valores futuros.
- A detecção de eventos é aplicada sobre a série prevista.
- Essa abordagem pode funcionar sem rótulos diretos de evento.

Problemas com classificação online



Instâncias rotuladas escassas

Muitos fluxos têm poucas instâncias rotuladas.



Forte desbalanceamento

Eventos são raros, gerando forte desbalanceamento.



Rotulação cara e imprecisa

Obter rótulos por especialistas pode ser caro, lento ou impreciso.

Detectar eventos na série prevista

01

Primeiro prevê-se uma sequência futura.

02

Depois aplica-se um detector sobre a previsão.

03

O alerta antecipa eventos esperados pelo comportamento projetado da série.

Online multivariate anomaly detection



Fluxos multivariados têm alta dimensionalidade e relações que mudam no tempo.



A anomalia pode surgir de combinações entre variáveis.



Métodos online precisam ser leves, adaptativos e robustos a drift.

Métodos para detecção multivariada online

Distance-based

- Monitoram distâncias entre observações no fluxo.
- COD acompanha outliers baseados em distância continuamente.
- CPOD usa core points para resumir regiões locais e reduzir custo.

Tree-based

- Particionam o espaço de dados para isolar observações anômalas.
- HS-Tree atualiza uma estrutura hierárquica em ambientes não estacionários.
- RRCF usa árvores com cortes aleatórios para detecção escalável em tempo real.

Projection-based

- Reduzem dimensionalidade por projeções aleatórias.
- LODA projeta dados em subespaços unidimensionais e usa histogramas.
- XStream adapta projeções e modelos conforme novas observações chegam.

Latência e viés temporal

Não basta saber se o detector acertou.

É preciso medir quando ele detectou em relação ao evento real.

Detecções antecipadas, atrasadas e alarmes persistentes têm impactos diferentes.

Métodos híbridos

Uma série pode conter anomalias, change points e motifs.

Detectores especializados capturam evidências diferentes.

Combinar métodos pode dar uma visão mais completa dos eventos no fluxo.