

Avaliação de Detecção de Eventos



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Avaliar eventos não é só classificar pontos

Em séries temporais, a posição da detecção importa.

Uma detecção próxima ao evento pode ser útil mesmo sem coincidir exatamente.

Eventos podem ser pontuais, intervalares, antecipáveis ou detectáveis apenas com atraso.

O problema do acerto exato

Métricas clássicas tratam cada instante como independente.

Um erro de uma unidade no tempo pode virar falso positivo e falso negativo ao mesmo tempo.

Isso pode descartar detectores úteis em aplicações reais.

Framework clássico de avaliação

Cada instante do sinal é classificado individualmente, gerando quatro resultados possíveis de comparação entre detecção e realidade.

Classificação de instantes

Cada instante é rotulado em uma de duas classes:

- **Evento (classe positiva):** instante em que um evento ocorre
- **Não evento (classe negativa):** instante de observação típica, sem evento

Quatro resultados possíveis

- **TP** — evento real corretamente detectado
- **TN** — não evento corretamente ignorado
- **FP** — alarme onde não havia evento
- **FN** — evento real não detectado

Métricas clássicas: accuracy, precision e recall

Accuracy

Mede a proporção total de acertos. Em eventos raros pode ser enganosa: acertar muitos não eventos pode esconder falhas nos eventos reais.

$$\text{accuracy} = \frac{TP + TN}{P + N}$$

Precision

Entre tudo que detectei como evento, quanto era evento real? Sensível a falsos positivos. Importa quando alarmes indevidos têm custo alto.

$$\text{precision} = \frac{TP}{TP + FP}$$

Recall

Entre os eventos reais, quantos foram detectados? Sensível a falsos negativos. Importa quando perder um evento é mais grave que emitir alarme extra.

$$\text{recall} = \frac{TP}{P}$$

F1 e $F\beta$

F1 combina precision e recall por média harmônica.


$F\beta$ permite pesar recall mais ou menos que precision.

São úteis quando a avaliação precisa equilibrar alarme falso e evento perdido.

$$F1 = 2 \cdot \text{precision} \cdot \text{recall} / (\text{precision} + \text{recall})$$

Escores e curvas de avaliação

Alguns detectores produzem um **rótulo binário** (evento ou não evento), enquanto outros produzem um **escore** — um grau de evidência de evento. Com escore, o limiar de decisão pode variar, permitindo gerar curvas de avaliação que resumem o desempenho do detector em diferentes pontos de operação.



ROC resume tpr contra fpr; AUC-PR é útil em cenários desbalanceados comuns em detecção de eventos.

Por que métricas clássicas falham

- Elas ignoram que a ordem temporal tem significado.
- Tratam uma detecção vizinha ao evento como erro total.
- Não avaliam atraso, antecipação, persistência ou cobertura temporal.

Limitações do instante exato

Fronteira imprecisa

Eventos reais podem não ter fronteira temporal perfeitamente definida. Um detector pode marcar o efeito do evento em vez do instante rotulado. Exigir igualdade exata pode ser rígido demais.

Efeito antecipado ou atrasado

Alguns eventos apresentam sinais antes do instante oficial. Outros só ficam observáveis depois que seus efeitos se propagam. A avaliação precisa distinguir atraso útil de erro irrelevante.

Imprecisão em labels humanos


Rótulos podem ter atraso, arredondamento ou incerteza. Tolerância temporal ajuda quando o ground truth não é pontual perfeito.

Near miss e tolerância temporal

Uma detecção muito próxima pode ser operacionalmente útil, mas métricas hard não diferenciam quase acerto de erro distante — esse é o problema que a tolerância temporal resolve.

- Permite considerar detecções próximas ao evento como válidas ou parcialmente válidas.
- A distância temporal passa a influenciar o score da detecção.
- A avaliação deixa de ser apenas hard (acerto ou erro) e passa a ser graduada.

Exemplo com métodos A e B



Métodos A e B detectam próximo de E₁; apenas B detecta próximo de E₂.

Detecção próxima ao evento



A proximidade temporal precisa ser recompensada de forma controlada.




Detecções muito distantes ainda devem ser penalizadas.



O tamanho da janela de tolerância deve refletir o domínio da aplicação.

Hard evaluation vs soft evaluation



A avaliação hard exige coincidência exata; a avaliação soft considera grau de associação temporal.

SoftED: intuição



SoftED flexibiliza métricas clássicas usando tolerância temporal.



Cada detecção recebe grau de pertinência em relação a eventos reais.



Quanto mais próxima do evento, maior sua contribuição para o score.

Função de pertinência temporal

A função $\mu_{ej}(t)$ mede a proximidade entre uma detecção e o evento e_j .





O valor máximo ocorre no instante do evento.

Fora da janela de tolerância k , a pertinência cai para zero.



$\mu_{ej}(t_{di}) \in [0,1]$, controlada por uma tolerância k

SoftED mapping



SoftED mapeia detecções a eventos usando pertinência temporal e restrições de associação.

SoftED: métricas, restrições e interpretabilidade

Restrições de matching

- Uma detecção não deve ser recompensada por vários eventos ao mesmo tempo.
- Várias detecções não devem inflar o score de um único evento.
- O problema é tratado como matching bipartido entre detecções e eventos.

Contadores soft

- **TPs** = soma das pertinências temporais das detecções representativas.
- **FNs** = parte dos eventos não coberta pelas detecções.
- **FPs** = penaliza detecções associadas de forma fraca ou inexistente.
- Precision, recall e F1 são recalculados com esses valores — a escala permanece interpretável.

Hard vs SoftED

- **Hard** exige coincidência exata entre detecção e evento.
- **SoftED** recompensa detecção próxima de acordo com a tolerância.
- A escolha depende do quanto o domínio aceita imprecisão temporal.

Relação com Harbinger

SoftED está disponível no Harbinger, permitindo comparar avaliação hard e soft no mesmo fluxo experimental. É uma ponte prática entre teoria de avaliação e experimentação.

Avaliação de eventos intervalares

Pontuais vs intervalares

- Eventos pontuais ocorrem em um instante.
- Eventos intervalares têm início, fim e duração.
- Avaliar intervalos exige considerar cobertura, atraso e sobreposição.

Distorção ponto a ponto

- Um evento longo pode dominar a métrica por ter muitos pontos.
- Uma pequena detecção dentro de um intervalo pode ser suficiente em algumas aplicações.
- Em outras, é necessário cobrir bem o intervalo completo.

Variantes de F-score para eventos intervalares

Point-Adjusted F-score

Se qualquer ponto dentro do segmento real é detectado, todo o segmento é considerado detectado.

- Generoso para detecções parciais.
- Pode superestimar desempenho quando a cobertura importa.

Delay-thresholded PA F-score

Adiciona uma janela máxima de atraso: o evento só conta como detectado se houver detecção nos primeiros k passos.

- Mais alinhado a cenários em que detectar tarde não resolve o problema.

Segment-wise F-score

Cada segmento real é tratado como uma unidade. Basta uma detecção no segmento para gerar verdadeiro positivo.

- Não penaliza fortemente a extensão exagerada de um intervalo detectado.

Range-based F-score

Avalia cobertura parcial de eventos reais e detecções.

- Recall local mede quanto do evento foi coberto.
- Precision local mede quanto da detecção corresponde ao evento.

Avaliação online: características e tipos de detecção





Por que é diferente

- O detector não vê a série completa.
- A detecção pode mudar conforme novos batches chegam.
- O momento da detecção é parte essencial do desempenho.

Tipos de detecção

- Uma detecção pode ocorrer antes (antecipada), durante ou depois (tardia) do evento.
- Em online detection, detecções tardias podem ser inúteis.
- Um método também pode mudar sua decisão conforme a janela evolui (inconsistente).

Exemplo de avaliação online



Métodos A e B são avaliados conforme novas observações chegam, evidenciando atraso e inconsistência.

Métricas e parâmetros de avaliação online

Detection Probability

Mede a probabilidade de uma observação ser detectada ao longo das oportunidades disponíveis. Compara a frequência de detecção com o número de vezes em que a observação esteve disponível. Ajuda a distinguir detecção eventual de detecção consistente.

Detection Lag

Mede o atraso entre a primeira disponibilidade da observação e sua primeira detecção. Quanto menor o lag, mais cedo o método reagiu. Pode ser expresso em número de batches ou em número de observações.

Batch size, memória e janela

Batch size altera a granularidade da avaliação. Memória parcial limita quantas vezes uma observação pode ser reavaliada. A janela de avaliação precisa refletir a operação real do sistema.

Benchmarks: qualidade, problemas e referências recentes

Qualidade importa

A escolha do benchmark influencia fortemente a conclusão sobre um método. Benchmarks ruins podem criar falsa sensação de progresso. Avaliar o dataset é parte da avaliação do detector.

Problemas comuns

Anomalias triviais podem favorecer métodos simples demais. Densidade irreal de eventos altera precision e recall. Ground truth mal rotulado compromete qualquer métrica. Muitas anomalias no fim da série podem enviesar resultados.

Referências recentes

UCR Anomaly Archive reúne séries curadas para avaliação. TimeEval oferece toolkit para comparar algoritmos de anomalias em séries temporais. Benchmarks recentes também discutem qualidade de labels, eventos intervalares e métricas apropriadas.