

Agenda de Pesquisa em Detecção de Eventos



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Uma área ampla e ativa

- Depois dos métodos, precisamos olhar para a área como um todo.
- O capítulo identifica tendências, lacunas e temas emergentes.
- A pergunta deixa de ser apenas como detectar e passa a ser o que ainda falta resolver.
- Time series event detection envolve métodos estatísticos, mineração de dados, aprendizado de máquina e sistemas.
- A produção científica cresce porque séries temporais aparecem em sensores, saúde, clima, indústria, finanças e segurança.
- O campo não converge para um único problema: ele se organiza em subáreas complementares.

Três áreas centrais

Anomaly detection

Procura desvios e comportamentos raros.

Change point detection

Localiza transições entre regimes.

Motif discovery

Descobre padrões recorrentes e, indiretamente, discords.

Mapa sistemático da produção

O capítulo resume consultas no Scopus realizadas em 29 de novembro de 2023.

As buscas incluem documentos com restrição a time series.

As áreas analisadas são event detection, anomaly, change point/concept drift e motif.

Anomaly detection

É a subárea com maior volume de publicações.


Change point e concept drift

Formam uma linha consolidada, com base estatística forte.

Motif discovery

É menor em volume, mas central para padrões recorrentes e subsequências.

Evolução das publicações



Número de publicações em escala logarítmica nas principais áreas de detecção de eventos.

- Anomalias dominam a produção científica.
- Change points crescem fortemente após os anos 1980.
- Event detection se consolida como termo mais geral a partir dos anos 2000.
- Motifs aparecem de forma mais recente e com ritmo estável.

Interseções entre áreas

- Event detection se conecta principalmente com anomaly detection.
- Anomaly e change point têm interseção expressiva.
- Anomaly e motif também se encontram, especialmente quando discords entram na discussão.

Séries reais podem conter anomalias, mudanças de regime e padrões recorrentes ao mesmo tempo.


Métodos especializados veem partes diferentes do fenômeno.

Uma visão unificada pode produzir detectores mais robustos e interpretações melhores.


Vocabulário das subáreas




(a)



(b)



(C)



(d)

Além da contagem de publicações, o vocabulário revela a identidade das subáreas. A comparação mostra que compartilham o tema temporal, mas falam dialetos diferentes.

Event detection

Sistemas, mineração de dados e aprendizado. Foco operacional: detectar ou prever eventos em aplicações.

Anomaly detection

Fortemente orientada por aplicações. Sensores, clima, redes e domínios específicos. Anomalia depende do contexto.

Change points

Vocabulário estatístico forte.
Concept drift conecta
mudança temporal com
aprendizado adaptativo.

Motifs

Padrões, subsequências e discovery. Lógica de descoberta de formas recorrentes, não classificação de pontos.

Word clouds para event detection, anomaly, change point e motif.

Desafios técnicos

Séries multivariadas

Fontes modernas coletam muitas variáveis ao longo do tempo.

Eventos podem surgir da relação entre dimensões, não apenas de uma série isolada.

Dimensionalidade, dependência e interpretabilidade tornam o problema mais difícil.

Escala e big data

Sensores, redes sociais e sistemas industriais geram séries longas e rápidas. Métodos tradicionais podem falhar em custo, memória ou latência. Spark, Kafka e Flink aparecem como infraestrutura para workflows escaláveis.

Detecção online

Em streaming, não há série completa para analisar. O detector precisa decidir no fluxo, com memória limitada e dados em mudança. Anomalias próximas a drift ou change points podem ser especialmente ambíguas.

Desafios metodológicos

Métricas para eventos

Ainda faltam métricas unificadas para eventos pontuais, intervalares e online. Tolerância temporal precisa ser tratada de forma consistente. Métricas devem evoluir quando novos dados chegam em streaming.

Explicabilidade

Detectores complexos podem funcionar como caixas-pretas. Em saúde, finanças e segurança, explicar o evento é tão importante quanto detectá-lo. SHAP, LIME e visualização interativa podem inspirar soluções mais confiáveis.

Visão unificada

Anomalias, change points e motifs ainda são estudados como problemas separados. Séries reais frequentemente combinam os três tipos de evento. Um detector mais amplo deve integrar evidências de desvio, mudança e recorrência.

Tendências emergentes



Transfer learning e adaptação

Modelos treinados em um domínio nem sempre generalizam para outro. Transfer learning pode reduzir dependência de rótulos no novo domínio. A adaptação em séries multivariadas ainda é pouco explorada.



LLMs e séries como tokens

Modelos recentes podem tratar séries temporais discretizadas como sequências de tokens. Isso abre espaço para pré-treinamento em grandes coleções e ajuste fino por tarefa. A promessa é aproveitar representação aprendida quando há poucos rótulos.



Robustez contra ataques adversariais

Em segurança e finanças, pequenos ajustes nos dados podem enganar detectores. Modelos de ML precisam ser avaliados contra manipulação intencional. Robustez vira requisito quando o detector participa de decisão crítica.

Oportunidades de pesquisa

Associação entre eventos

Eventos podem formar sequências e relações causais. Pequenas anomalias podem preceder change points relevantes. Associar eventos aproxima detecção de mineração de sequências e raciocínio causal.

Eficiência energética e edge

IoT, wearables e edge computing têm restrições fortes de energia e memória. Detectores precisam ser leves sem perder confiabilidade. Eficiência energética será requisito para implantação em larga escala.

Métodos híbridos e detectores amplos

Métodos híbridos podem combinar anomalia, mudança e recorrência. A vantagem é capturar fenômenos diferentes no mesmo fluxo temporal. O desafio é integrar saídas, métricas e explicações sem criar um sistema opaco.

O que falta para aplicações reais

- Benchmarks representativos.
- Métricas temporais adequadas.
- Explicações compreensíveis para especialistas.
- Custo computacional compatível com operação contínua.