



Detecção de Eventos em Séries Temporais

parte 1 - Fundamentos



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



As Duas Perguntas do Curso

Dada uma série temporal, queremos responder duas perguntas: **o que acontecerá depois?** e **quando algo relevante aconteceu ou está acontecendo?**

Predição

Estimar valores futuros a partir de padrões temporais. Modelos aprendem o comportamento esperado — o que é normal, recorrente, previsível.

Predição e detecção são complementares: prever o padrão é o que torna possível identificar a ruptura. Os fundamentos desta aula — média, variância, autocorrelação, estacionariedade — servem às duas tarefas.

Detecção de Eventos

Identificar instantes em que o comportamento se desvia do esperado. Só é possível reconhecer o *inesperado* quando se sabe o que era *esperado*.

Série Temporal como Sequência de Observações

Uma série temporal é uma sequência ordenada de valores no tempo, onde cada observação está associada a um instante temporal específico. A ordem importa: o passado informa o futuro e define o contexto em que eventos ocorrem.

$$x_1, x_2, \dots, x_T$$

Onde x_t é o valor observado no instante t , e T é o número total de observações. A série também pode ser representada como função do tempo: $x(t)$.


Sequência Original

A ordem natural preserva a estrutura temporal: cada valor carrega a história do que veio antes e condiciona o que pode vir depois.

Após Permutação

Trocar a ordem destrói a estrutura temporal. Diferentemente de dados comuns, não podemos reorganizar os valores sem alterar o significado da informação.

Em dados tradicionais, a ordem não importa; em séries temporais, ela é fundamental. É a dependência entre observações consecutivas que torna possível prever valores futuros e detectar quando o comportamento muda.



Processo Estocástico e Trajetória Observada

Pense no processo estocástico como um mecanismo gerador que nunca observamos diretamente — ele contém todas as trajetórias possíveis. A série observada é apenas uma delas: o caminho concreto que o processo tomou.

Processo Estocástico

$$\{X_t\}_{t=1}^T$$

Todas as trajetórias possíveis, descritas por um modelo probabilístico.


Trajetoória Observada

$$x_t = X_t(\omega)$$

O caminho concreto que o processo tomou — os dados que temos em mãos.

Nunca temos acesso ao processo gerador — só à trajetória que ele produziu. É por isso que predição e detecção de eventos são tarefas de inferência: a partir de uma única realização observada, tentamos reconstruir a estrutura do mecanismo subjacente e usá-la para antecipar o futuro ou identificar quando algo relevante aconteceu.

Processo estocástico e trajetória



Covariância e Autocovariância Temporal

Média e variância descrevem cada instante isoladamente. A autocovariância vai além: mede a memória temporal do processo — o quanto o valor em um instante depende do que aconteceu antes. Essa memória é o que modelos preditivos exploram para antecipar o futuro.

Instante $t-h$

O valor passado, separado por h períodos.

Defasagem h

O intervalo entre os dois instantes comparados.

Instante t

O valor presente.

A covariância entre dois instantes depende do intervalo entre eles — não dos instantes em si. Isso nos permite resumir toda a estrutura de dependência em uma única função da defasagem h , chamada função de autocovariância:

$$\gamma(h) = \text{Cov}(X_t, X_{t-h})$$

- ❏ Quanto maior a defasagem, menor tende a ser a dependência. Processos com memória longa mantêm autocovariância significativa mesmo para h grande.

A função $\gamma(h)$ é a base para medir autocorrelação e identificar padrões estruturais na série. Mudanças nessa estrutura ao longo do tempo são sinais potenciais de eventos — momentos em que a dinâmica do processo se alterou.

Autocorrelação

A autocovariância depende da escala da série, o que dificulta comparações. A autocorrelação resolve isso: normaliza a dependência para um intervalo entre -1 e 1, tornando a memória temporal comparável entre séries diferentes e interpretável diretamente.

Autocovariância

Mede dependência, mas na escala original dos dados.

Normalização

Dividimos pela variância para eliminar o efeito da escala.


Autocorrelação

Resultado padronizado, comparável entre séries diferentes.

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)}$$

A autocorrelação é a principal ferramenta para quantificar a memória temporal de uma série. Modelos preditivos como AR exploram essa estrutura para antecipar valores futuros. Padrões incomuns na ACF — picos abruptos, quebras, mudanças de sinal — podem indicar eventos relevantes na série.

ACF



Estacionariedade

Uma série é estacionária quando suas propriedades estatísticas — média, variância e estrutura de dependência — permanecem estáveis ao longo do tempo. Estacionariedade não é apenas uma condição matemática: ela é o que permite usar o passado como evidência confiável para o futuro. Sem ela, o que aprendemos de um período pode não valer para outro.

Média Constante

$$\mathbb{E}[X_t] = \mu$$

A média não varia ao longo do tempo

Variância Constante

$$\text{Var}(X_t) = \sigma^2$$

A dispersão permanece estável


Autocovariância Dependente Apenas da Defasagem

$$\text{Cov}(X_t, X_{t-h}) = \gamma(h)$$


A dependência depende só do intervalo, não do tempo absoluto

Quando uma série não satisfaz essas condições, o passado não é uma guia confiável para o futuro — e a detecção de eventos fica comprometida, pois não há uma referência estável de comportamento normal. Por isso, verificar e garantir estacionariedade é o primeiro passo antes de modelar.

Ruído branco (estacionário)



Passeio aleatório (não estacionário)



Fundamentos como Base para Predição e Detecção

Ordem temporal, processos estocásticos, autocovariância, autocorrelação e estacionariedade formam a base estatística que torna possível analisar séries temporais de forma rigorosa. Sem esses pilares, qualquer tentativa de prever ou detectar eventos na série seria construída sobre areia.

Com esses fundamentos estabelecidos, o próximo passo é olhar para dentro da série: entender como ela se organiza internamente — quais forças a moldam e como separá-las. Esse é o papel da **decomposição de séries temporais**.

Ordem Temporal

A sequência importa. Observações não são intercambiáveis — o tempo define a estrutura dos dados.

Memória Temporal

Autocovariância e autocorrelação quantificam como o passado influencia o presente.

Estacionariedade

Média, variância e dependência estáveis no tempo — condição para que o passado oriente o futuro.

Decomposição de Séries Temporais

Uma série temporal pode ser separada em componentes interpretáveis, cada um representando um aspecto distinto do comportamento ao longo do tempo.

$$X_t = T_t + S_t + C_t + \varepsilon_t$$

T_t – Tendência

Direção de longo prazo da série: crescimento, queda ou estabilidade.

S_t – Sazonalidade

Padrões cíclicos regulares que se repetem com período s conhecido.

C_t – Ciclo

Oscilações de médio prazo sem período fixo, associadas a conjunturas econômicas ou setoriais.

ε_t – Resíduo


O que não foi explicado pelos demais componentes. **É aqui que eventos anômalos se manifestam.**

- ❏ O resíduo ε_t é o componente central para detecção de anomalias — anomalias aparecem como desvios inesperados após remover tendência e sazonalidade.


Tendência

A **tendência** é a direção de longo prazo de uma série temporal — o movimento persistente e sistemático que revela se os valores estão crescendo, caindo ou se mantendo estáveis ao longo do tempo.

Tendência determinística (linear) + ruído



Tendência estocástica (passeio aleatório)



Crescimento

Usuários ativos de uma plataforma digital crescendo continuamente ao longo dos anos.



Queda

Custo de armazenamento em nuvem diminuindo progressivamente à medida que a tecnologia avança.



Estabilidade

Temperatura média anual de uma região sem variação expressiva ao longo de décadas.



Quando a tendência muda de direção ou inclinação de forma abrupta, isso pode indicar um evento relevante — uma **mudança estrutural** no processo subjacente.

Sazonalidade: Padrões Periódicos


A sazonalidade corresponde a padrões que se repetem regularmente ao longo do tempo — variações mensais, trimestrais ou semanais que fazem parte do comportamento esperado da série. Diferentemente da tendência, não representa mudança estrutural permanente, mas sim uma oscilação cíclica e previsível.

A condição formal de periodicidade é expressa por:

$$S_{t+s} = S_t$$

Onde s representa o período sazonal — por exemplo, $s = 12$ para séries mensais com ciclo anual. Essa propriedade distingue a sazonalidade de outros componentes temporais e permite modelá-la com funções trigonométricas, dummies sazonais ou decomposições espectrais.

Sazonalidade: padrão periódico ($s = 12$)



Energia Elétrica

Consumo residencial apresenta **pico no verão** (ar-condicionado) e quedas no outono/primavera. Ciclo anual bem definido com $s = 12$ meses.

Varejo

Vendas no comércio atingem **pico em dezembro** (Natal) e Janeiro (liquidações). Padrão robusto e recorrente, essencial para planejamento de estoque.

Tráfego de Rede

Picos de acesso ocorrem em **horário comercial** (9h–18h), com queda noturna e nos fins de semana. Ciclo diário com $s = 24$ horas.

- Quando um padrão sazonal esperado **não aparece** — por exemplo, vendas de dezembro abaixo do normal ou consumo de energia flat no verão — isso pode ser sinal de um evento relevante: crise econômica, falha operacional ou mudança estrutural no comportamento dos usuários.

Componente Aleatória: O Ruído


A componente aleatória representa flutuações imprevisíveis que não podem ser explicadas por tendência, sazonalidade ou ciclos. É o ruído inerente ao processo observado.

Em modelos clássicos, assume-se que o ruído tem média zero e variância constante:

$$\mathbb{E}[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2$$

Essas hipóteses simplificam a análise, mas podem ser relaxadas em modelos mais sofisticados que capturam heterocedasticidade e dependência temporal no ruído.

Ruído: flutuações aleatórias



Ruído Puro

Flutuações aleatórias sem estrutura subjacente. O resíduo oscila em torno de zero com amplitude estável — exatamente o que o modelo assume.

- Média zero
- Variância constante σ^2
- Sem autocorrelação

Ruído com Estrutura

O resíduo ainda carrega um padrão não capturado — tendência residual, sazonalidade não modelada ou dependência temporal. O modelo está incompleto.

- Autocorrelação positiva ou negativa
- Padrão visível no gráfico de resíduos
- Sinal de subajuste do modelo

Evento no Resíduo

O desvio é grande demais para ser explicado por variabilidade aleatória natural. Indica uma anomalia real — falha, fraude, mudança de regime ou evento externo.

- Magnitude muito acima de 3σ
- Desvio pontual e súbito
- Requer investigação causal

 Distinguir ruído de evento é o problema central da detecção de anomalias: um limiar muito baixo gera falsos alarmes; muito alto deixa eventos reais passarem despercebidos.

Decomposição e Análise

Cada método de decomposição gera uma representação diferente da série temporal. A escolha do método não é neutra: ela define o que será visto como padrão, o que ficará no resíduo e, portanto, o que poderá ser detectado como desvio.

Um mesmo ponto pode ser ruído em uma decomposição e anomalia em outra. O resíduo não é um dado bruto — é o resultado de uma decisão analítica.

❏ Não há resíduo neutro. A decomposição define o que é considerado "normal". Escolher o método é escolher o que será visto.

Método define o normal

A estrutura extraída (T_t, S_t, C_t) determina o que é esperado. O resíduo ε_t é o que sobra dessa expectativa.

Resíduo como espaço de análise

É no ε_t que eventos, anomalias e desvios podem se manifestar. A qualidade da decomposição determina a qualidade da análise.

Ponte para modelos

Compreender a estrutura da série é o pré-requisito para transformá-la em uma representação analisável para predição e detecção.

Engenharia Temporal e Detecção de Desvios

Após compreender a estrutura da série — tendência, sazonalidade e ruído — o próximo passo é **transformá-la em uma representação analisável**. Essa transformação é expressa como:

$$Y_t = \mathcal{T}(X_t)$$

A escolha de $\mathcal{T}$ determina quais padrões e desvios se tornam visíveis. O pipeline abaixo mostra como ela se traduz em detecção de eventos: o modelo define o esperado; o resíduo revela o inesperado; o limiar decide o que é evento.

Modelar o comportamento esperado

Ajustamos um modelo à série para estimar o valor esperado em cada instante.

$$\hat{X}_t$$

Calcular o resíduo

Medimos o quanto o valor real se afasta do esperado.

$$R_t = X_t - \hat{X}_t$$

Aplicar o limiar

Quando o resíduo ultrapassa o limiar h , um evento é sinalizado.

$$|R_t| > h$$

Representação Local da Série

Dividir a série em subsequências torna visíveis **padrões locais** invisíveis na perspectiva global. A subsequência $X_{t:t+w-1}$ define um recorte de comprimento w iniciado em t :

$$X_{t:t+w-1} = (X_t, X_{t+1}, \dots, X_{t+w-1})$$

Cada subsequência transforma um trecho da série em um objeto comparável: é possível medir similaridade, distância, forma local ou desvio local entre janelas. Isso permite detectar mudanças de comportamento confinadas a intervalos específicos — e é a base do mecanismo de janelas deslizantes.

Janelas Deslizantes

A janela deslizante é o mecanismo que **transforma a série em uma sequência de objetos comparáveis**. A cada posição t , recorta-se um trecho de comprimento w — e a escolha de w define qual escala de evento pode ser detectada.

$$\mathcal{W}_w(X_t) = \{X_{t:t+w-1}\} \text{ para cada posição } t$$

Janelas Curtas

Anomalias pontuais e mudanças abruptas

Janelas Médias

Padrões transitórios e mudanças de regime

Janelas Longas

Tendências e ciclos de larga escala

Como a janela se move sobre a série

Considere uma série com valores observados ao longo do tempo. Com $w = 3$, a janela avança um passo de cada vez:

Posição $t = 1$

$[X_1, X_2, X_3]$ $\cdots X_4 X_5 X_6 X_7 X_8$

Posição $t = 2$

X_1 **$[X_2, X_3, X_4]$** $\cdots X_5 X_6 X_7 X_8$

Posição $t = 3$

$X_1 X_2$ **$[X_3, X_4, X_5]$** $\cdots X_6 X_7 X_8$

Cada janela gera um **objeto local comparável**: calcula-se sua média, desvio ou forma. O ponto X_t é avaliado apenas com base na janela *anterior* — sem vazamento temporal.

O que cobrimos na Parte 1

**As duas perguntas: prever
vs. detectar eventos**

**Série temporal como
sequência ordenada**

**Processo estocástico e
trajetória observada**

**Memória temporal:
autocovariância e
autocorrelação**

**Estacionariedade: estabilidade de
média, variância e dependência**

**Decomposição: tendência,
sazonalidade, ciclo e resíduo**

**Representação local: subsequências
e janelas deslizantes**