



Detecção de Eventos em Séries Temporais

parte 2 - Eventos, taxonomia e tipos



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



O que são Eventos em Séries Temporais?

Eventos em séries temporais são instantes ou intervalos onde as observações mudam de forma considerada importante para análise ou tomada de decisão. A interpretação de um evento varia significativamente entre domínios.

Meteorologia

Intervalos de chuva intensa ou tempestades severas.

Economia

Quedas ou ganhos abruptos em mercados financeiros.

Indústria

Falhas de máquinas, violações de segurança, picos de tráfego de rede.

Saúde

Diagnóstico médico, surtos de doenças, detecção de arritmias.

Em teoria da informação, eventos são intervalos marcados por mudanças significativas de entropia — segmentos que contêm mais informação do que os demais.

Formalização de Eventos Pontuais

$$e(X, k, \sigma) = \{t \mid |tc(x_t) - ep(tc(x_t), k)| > \sigma \vee |tc(x_t) - ef(tc(x_t), k)| > \sigma \vee |ep(tc(x_t), k) - ef(tc(x_t), k)| > \sigma\}$$

Três Tipos Principais

- **Anomalias:** observações que diferem significativamente das típicas
- **Pontos de Mudança:** mudanças significativas na tendência ou volatilidade
- **Motifs:** sequências aproximadamente repetidas na série

Estrutura de Dados para Séries Temporais e Eventos

Séries temporais e eventos podem ser representados em diversas estruturas de dados, dependendo do contexto e propósito da análise.

Granularidade

Eventos Pontuais: observações individuais interpretadas como eventos em relação ao restante da série. Representados em estrutura de dados com timestamp.

Eventos Intervalares: ocorrem ao longo de um período definido, registrados com tempo de início e fim. Exemplos: chuva diária contínua, alto consumo de energia elétrica.

Dimensionalidade

Univariada: uma única variável por observação. Representada como vetor. Exemplo: Série de Temperatura Global Anual (YGT).

Multivariada: múltiplas variáveis por observação. Representada como matriz ou tabela. Exemplo: temperatura, umidade e velocidade do vento por hora.

Uma estrutura comum é uma tabela onde cada linha representa um instante de tempo e cada coluna representa uma variável. Uma coluna adicional pode indicar a presença e o tipo de evento.

Taxonomia de Eventos em Séries Temporais

A taxonomia organiza os principais conceitos associados à detecção de eventos em cinco grandes categorias, fornecendo um contexto estruturado para os métodos da literatura.

Tipo de Evento

Anomalias, Pontos de Mudança, Motifs e Discords — cada um com características e métodos distintos.

Estrutura de Dados

Granularidade (pontual vs. intervalar) e Dimensionalidade (univariada vs. multivariada).

Método de Detecção

Regressão, Classificação, Clustering, Estatístico e Baseado em Domínio.

Cenário de Detecção

Offline (retrospectivo), Online (tempo real) e Predição (eventos futuros).

Avaliação

Acurácia (precisão, recall, F1, AUC-ROC) e Recursos Computacionais.

Os métodos de detecção são especializados: a maioria identifica apenas um tipo específico de evento. Quando detectam múltiplos tipos, geralmente combinam anomalias e pontos de mudança.

Anomalias

Definição

Anomalias são observações que não se conformam às típicas da série temporal. Uma anomalia em x_t ocorre quando o TC escapa do valor esperado tanto antes quanto depois do instante t , segundo o limiar σ :

$$a(X, k, \sigma) = \{t \mid |tc(x_t) - ep(tc(x_t), k)| > \sigma \wedge |tc(x_t) - ef(tc(x_t), k)| > \sigma\}$$

Anomalias de Ruído

O tipo mais simples. Correspondem a variações anormais no componente residual da série. Seja $\hat{X}$ uma estimativa de X pelo modelo α , com $\hat{x}_t = \alpha(x_t)$, o resíduo é $\omega_t = x_t - \hat{x}_t$. Anomalias são identificadas por testes de distribuição estatística (sdt) sobre W :

$$na(X) = sdt(W), \quad \omega_t = x_t - \hat{x}_t$$

Anomalias vs. Outliers: anomalias são eventos que se pretende detectar; outliers são observações indesejadas que se pretende descartar. A distinção é sutil — ambos representam desvios, mas com propósitos analíticos diferentes.

Detecção Paramétrica (Gaussiana)

$$sdt(W) = \{t \mid \omega_t \notin [\bar{W} - 3 \cdot sd(W), \bar{W} + 3 \cdot sd(W)]\}$$

Assume distribuição Gaussiana. Observações além de ± 3 desvios-padrão são anomalias.

Detecção Não-Paramétrica (Box Plot)

$$sdt(W) = \{t \mid \omega_t \notin [Q_1(W) - 1.5 \cdot IQR(W), Q_3(W) + 1.5 \cdot IQR(W)]\}$$

Não assume distribuição específica. Usa quartis e distância interquartil (IQR). Mais robusto para distribuições assimétricas.

Pontos de Mudança

Definição

Pontos de mudança são intervalos de tempo onde há uma mudança significativa nas propriedades estatísticas da série — média, variância, correlação ou outros parâmetros. Representam uma transição entre diferentes estados do processo gerador.

$$cp(X, k, \sigma) = \{t \mid (|tc(x_t) - ep(tc(x_t), k)| > \sigma \vee |tc(x_t) - ef(tc(x_t), k)| > \sigma) \vee |ep(tc(x_t), k) - ef(tc(x_t), k)| > \sigma)\}$$

Diferença-chave em relação a anomalias: o TC segue o esperado antes OU depois de t , mas não em ambos simultaneamente.

Exemplo: na Série de Temperatura Global Anual (YGT), pontos de mudança detectados pelo teste de Chow revelam regimes climáticos distintos — tendências significativamente diferentes antes e depois de cada ponto.

Relação com Concept Drift

Em séries multivariadas D , onde $X \subset D$ é preditor de $Y \in D$, a detecção de pontos de mudança equivale a um teste de hipótese de concept drift:

$$H_0 : \forall t, k (t \neq k) \mid \mathbb{P}_{n(t)} \approx \mathbb{P}_{n(k)}$$

$$H_A : \forall t \exists k (t \neq k) \mid \mathbb{P}_{n(t)} \neq \mathbb{P}_{n(k)}$$

H_0 caracteriza a ausência de drift; H_A nega H_0 . $\mathbb{P}_{n(t)}$ é a função de densidade de probabilidade para D nas observações vizinhas de t (ex.: janela deslizante contendo t).

Motifs e Discords

Motifs

Motifs são subsequências aproximadamente repetidas em uma série temporal. Correspondem a padrões recorrentes com forma distintiva. Dado uma sequência q e uma série X , q é um motif em X se e somente se q ocorre em X pelo menos σ vezes.

São úteis para identificar tendências, padrões sazonais e outliers. Tornam-se mais interessantes quando as sequências fornecem mais informação do que as observações típicas.

Métodos de Descoberta

A abordagem direta (força bruta) tem complexidade $O(n^2)$. Métodos baseados em indexação com SAX (Symbolic Aggregate approXimation) e hashing melhoram o tempo computacional. O estado da arte usa Matrix Profile para computação eficiente.

Discords

Discords são sequências que não se repetem na série temporal — as mais isoladas de todas as demais. São significativamente diferentes do restante das observações.

Exemplo: em um eletrocardiograma (MIT-BIH), as batidas cardíacas regulares formam motifs. Batidas irregulares (arritmias) podem ser interpretadas como:

- Motifs raros: três subsequências similares e incomuns
- Discords: três subsequências significativamente diferentes entre si

Distinção Fundamental

Motifs → similaridade (repetição). Discords → isolamento (singularidade). A mesma subsequência pode ser classificada diferentemente dependendo do critério adotado.

Comportamento Típico e Anomalia


A noção de anomalia nasce da noção de comportamento típico. Um modelo temporal define o que é esperado, e a previsão condicional estabelece o comportamento esperado para cada instante.

O resíduo r_t mede o desvio entre o observado e o esperado. Uma anomalia ocorre quando esse desvio não é compatível com o que o próprio modelo considera típico.

Formalmente, a série $X = \{x_t\}$ contém um conjunto de eventos $\mathcal{E}$, e as anomalias formam um subconjunto: $\mathcal{A} \subset \mathcal{E}$.

$$\hat{x}_t = \mathbb{E}[x_t \mid \mathcal{F}_{t-1}, \mathcal{M}], \quad r_t = x_t - \hat{x}_t$$

Onde $\mathcal{M}$ é o modelo temporal, $\mathcal{F}_{t-1}$ é a informação disponível até $t-1$, $\hat{x}_t$ é o valor esperado, e r_t é o resíduo.



Ruído, Evento e Anomalia

É fundamental distinguir três conceitos que frequentemente se confundem na análise de séries temporais:

Ruído

A variabilidade esperada e inerente ao processo, representada por ε_t . Não é um desvio — é o comportamento normal do sistema, presente em qualquer instante.

Evento

A componente adicional associada a uma perturbação, representada por δ_t . É um termo extra que representa perturbação estruturada sobre o processo, além do ruído esperado.

Anomalia

Um caso particular de evento onde o desvio resultante é estatisticamente significativo no contexto do modelo.

$$x_t = S_t + \varepsilon_t, \quad x_t = S_t + \varepsilon_t + \delta_t$$

Onde S_t é o sinal estruturado, ε_t é o ruído aleatório, e δ_t é a perturbação associada ao evento. Toda anomalia é evento, mas nem todo evento é anomalia. A distinção entre ε_t e δ_t é o que separa variabilidade esperada de perturbação detectável.

Dependência da Representação

O que conta como anomalia depende da representação, do modelo e do objetivo analítico — não é uma propriedade absoluta do dado.

$$\mathcal{A}(\mathcal{R}) = \{t \mid \text{score}(\mathcal{R}(X), t) > \tau\}$$

Valores brutos

→ sem anomalia detectada

Resíduos do modelo

→ anomalia detectada

Componente de volatilidade

→ anomalia diferente

$$\mathcal{A}(\mathcal{R}_1) \neq \mathcal{A}(\mathcal{R}_2)$$

Escolher a representação é escolher o que pode ser anômalo.

Tipos de Anomalias por Natureza

Três manifestações distintas segundo escopo temporal e contexto.

Anomalias Pontuais

Desvios isolados em um único instante de tempo.

Anomalias Coletivas

Sequências que, em conjunto, constituem comportamento anômalo.

Anomalias Contextuais

Valores anômalos apenas em relação ao entorno temporal. Em avaliação offline, o contexto pode incluir vizinhança anterior e posterior:

$C_t = \{x_{t-k}, \dots, x_{t-1}, x_{t+1}, \dots, x_{t+k}\} \setminus \{x_t\}$. O mesmo valor pode ser típico em um regime e anômalo em outro: $x_t \not\sim p(C_t)$.

C_t exclui x_t para evitar que o ponto avaliado defina seu próprio contexto.

A tipicidade é sempre condicionada ao contexto — o limiar e a interpretação do evento dependem da vizinhança temporal.

Síntese: Anomalia como Escolha Metodológica

A síntese final explicita que a anomalia é um conceito relativo, dependente de múltiplas escolhas metodológicas. Detectar anomalias não é simplesmente "procurar pontos estranhos", mas formalizar a *tipicidade* e decidir o que constitui desvio relevante.

Representação

Como transformar a série temporal original

Modelo

Como definir a tipicidade no espaço escolhido — via resíduos, densidade ou parâmetros.

Contexto

Qual vizinhança C_t (ou janela W) o detector considera a cada instante.

Tempo

Quando avaliar e como adaptar critérios

$$\mathcal{A} = f(\mathcal{R}, \mathcal{M}, \mathcal{C}, t)$$

f representa a regra de detecção — não uma função matemática única universal, mas a composição de quatro decisões: representação, modelo de tipicidade, contexto e tempo de avaliação.

Definição

A detecção de pontos de mudança é um problema fundamental de estimação em séries temporais. Dada uma série observada, buscamos identificar os instantes onde a estrutura estatística dos dados muda significativamente.

Formalmente, definimos os instantes $\tau_1 < \tau_2 < \dots < \tau_k$ como pontos de mudança se os parâmetros do processo gerador diferem entre segmentos consecutivos. O conjunto $C = \{\tau_1, \dots, \tau_k\}$ particiona a série em $k+1$ segmentos estatisticamente homogêneos.

A estrutura que muda pode ser a média, a variância, a autocorrelação ou a distribuição completa dos dados — dependendo do modelo adotado para cada segmento.

Mudanças persistentes no processo gerador também aparecem em cenários online como drift. Neste curso, change points serão tratados aqui como mudanças estruturais localizáveis na série, enquanto drift será retomado na aula de detecção online, onde a ênfase está em fluxo, adaptação, latência e atualização da referência.

Motifs versus Outros Eventos

Enquanto anomalias buscam desvios e change points identificam rupturas, motifs capturam regularidades recorrentes. São perspectivas complementares na análise temporal.

Anomalias (A)

Eventos raros que representam desvios locais do padrão esperado. Definidas por $|r_t| > \tau$, onde o resíduo excede um limiar.

Change Points (C)

Representam rupturas entre regimes, definidas por $\theta_1 \neq \theta_2$. Segmentam a série em diferentes fases.

Motifs (M)

Eventos frequentes que representam similaridade entre janelas. Definidos por $d(X_{i:i+v}, X_{j:j+v}) < \epsilon$, onde a distância entre subsequências é menor que um limiar.

O sistema completo de eventos temporais é $E = A \cup C \cup M \cup D$, onde D representa Discords — padrões únicos que não se repetem.

Definição Formal de Motif

Seja q uma sequência de tamanho p e W o conjunto de janelas deslizantes de tamanho p obtidas da série X . O conjunto de ocorrências de q em X é o conjunto de janelas $w_i \in W$ similares a q .

Ocorrências

Definição formal do conjunto de ocorrências de q em X :

$$\text{occurs}(q, X) = \{w_i\} \mid \forall w_i \in W, w_i \approx q$$

Motif com Suporte σ

q é um motif em X com suporte σ se e somente se ocorre em X pelo menos σ vezes:

$$\text{motif}(q, X) \iff |\text{occurs}(q, X)| \geq \sigma$$

O tamanho p de q é também chamado de *word size*.

Matches Triviais

As ocorrências em $\text{occurs}(q, X)$ devem ter sobreposição mínima. Usa-se uma *exclusion zone* (50–80%) para evitar matches triviais entre janelas vizinhas. O **1-motif** é a subsequência mais frequente; o **k-motif** é o k-ésimo mais frequente.

Escolhendo w : Uma Decisão de Escala

O tamanho da janela w não é apenas um parâmetro técnico — ele define **o que pode ser visto**. Mudar w muda o conceito de motif: $\mathcal{M}(w) \neq \mathcal{M}(w')$ em geral.

w Pequeno

Padrões locais e finos — como um pico de batimento cardíaco ou um gesto rápido. Alta resolução, muitas janelas, custo computacional elevado.

w Grande

Estruturas completas e globais — como um ciclo diário de temperatura ou uma tendência de mercado. Menos janelas, padrões mais abstratos.

- ❏ O analista deve escolher w com base no fenômeno que deseja detectar. Não há valor certo — há a escala certa para a pergunta certa.

Definição de Discord

Um discord é uma subsequência "isolada" que se destaca das demais na série temporal. Diferente de uma anomalia pontual, o discord é definido no espaço de subsequências, não em um único ponto.

Considere a série X . Um discord é uma subsequência cuja forma é muito diferente das outras subsequências extraídas da mesma série. Ele mede raridade comparando janelas temporais entre si, revelando padrões temporais excepcionais.

Anomalias Pontuais vs Discords

Anomalia Pontual

Desvio grande em um único instante. Detectada quando o resíduo $|r_t|$ excede um limiar h .

Discord

Desvio grande de uma janela inteira em relação a outras janelas. Envolve distância $d(X_{i:i+w}, X_{j:j+w})$ entre subsequências.

A diferença fundamental está na unidade do evento: anomalia pontual olha para um ponto; discord olha para um trecho completo. Discords podem ser vistos como anomalias coletivas, pois o padrão inteiro da janela é raro.

0 que cobrimos na Parte 2

Taxonomia de eventos:
anomalias, pontos de mudança,
motifs e discords

Anomalias: definição formal,
comportamento típico e desvio

Ruído vs. evento vs. anomalia:
distinções fundamentais

**Dependência da
representação:** anomalia como
escolha metodológica

Tipos de anomalias: pontuais, coletivas e
contextuais

Pontos de mudança: mudanças
estruturais nas propriedades estatísticas

Motifs e discords: padrões recorrentes e
subsequências raras