



Detecção de Eventos em Séries Temporais

parte 3 - Estratégias de detecção



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Arquitetura do Pipeline de Detecção

A detecção de anomalias pode ser formulada como um mapeamento estruturado $\mathcal{D} : \mathcal{R}(X) \rightarrow \mathcal{A}$. O detector não opera sobre os dados brutos, mas sobre uma representação transformada — e o pipeline abaixo detalha cada etapa dessa cadeia.

Pré-processamento

$\mathcal{T}$ transforma X_t em $X_t^{(prep)}$: limpeza e normalização dos dados.

Representação

$\mathcal{R}$ produz Z_t : extração de características relevantes para modelagem.

Modelagem

$\mathcal{M}$ gera $\hat{Z}_t$: comportamento esperado sob normalidade.

Detecção

$\mathcal{D}$ aplica a regra de decisão e identifica $\mathcal{A}$ (conjunto de anomalias): instantes ou subsequências que desviam do comportamento típico.

$$\mathcal{D} : \mathcal{R}(X) \rightarrow \mathcal{A}$$

Checklist Operacional do Detector

O detector opera em três etapas encadeadas — modelar o esperado, calcular o score e decidir — e exige decisões explícitas em sete dimensões:

Representação

Qual sinal extrair dos dados brutos

Modelo de Tipicidade

Como definir o comportamento típico esperado

Score

Como medir o desvio entre observado e esperado: $s_t = g(R(X), t)$

Limiar

Qual nível de desvio classifica como anomalia:
 $a_t = \mathbb{I}(s_t > \tau)$

Janela / Contexto

Qual contexto temporal W o detector considera a cada instante

Modo de Operação

Restrição de informação disponível: offline (série completa), online (sequencial) ou preditivo (horizonte futuro)

Avaliação

Como medir acerto, falso alarme, anomalia perdida e atraso

$$a_t = \mathbb{I}(s_t > \tau)$$

onde $s_t = g(\mathcal{R}(X), t)$ é o score de desvio e τ é o limiar de decisão.

Detecção Estatística de Anomalias

A normalidade é modelada por uma distribuição condicional $p_{\theta}(x_t | \mathcal{F}_{t-1})$, conhecida ou estimada a partir do histórico. O detector mede o quanto cada observação é improvável sob esse modelo e decide com base em um limiar.

$$p_{\theta}(x_t | \mathcal{F}_{t-1})$$

$$s_t = \phi(x_t, p_{\theta,t}), \quad a_t = \mathbb{I}(s_t > \tau)$$

$p_{\theta,t}$: distribuição condicional estimada no instante t ;
 ϕ : função de score (ex: resíduo padronizado, CUSUM, razão de verossimilhança); τ : limiar de decisão.

ENTRADA: série $X = \{x_1, \dots, x_T\}$, limiar τ

PRÉ-CONDIÇÃO: $p_{\{\theta,t\}}$ estimada ou conhecida a partir de dados históricos

PASSO 1 — Para cada $t = 1, \dots, T$:

PASSO 2 — Calcular score: $s_t = \phi(x_t, p_{\{\theta,t\}})$

PASSO 3 — Se $s_t > \tau$: marcar x_t como anomalia ($a_t = 1$)

PASSO 4 — Senão: classificar como normal ($a_t = 0$)

SAÍDA: conjunto $A = \{t : a_t = 1\}$

PÓS-CONDIÇÃO: cada ponto classificado segundo desvio estatístico de $p_{\{\theta,t\}}$

Detecção Baseada em Modelos Temporais

Um modelo temporal f aprende a dinâmica normal da série usando p defasagens. O score é o erro de previsão: quanto maior o erro, mais improvável é a observação. A avaliação só é possível a partir de $t = p+1$, após a janela inicial de treinamento.

$$x_t = f(x_{t-1}, \dots, x_{t-p}) + \varepsilon_t$$

$$s_t = |x_t - \hat{x}_t|, \quad a_t = \mathbb{I}(s_t > \tau)$$

f : modelo preditivo (AR, ARIMA, rede neural); p : ordem — número de defasagens; ε_t : ruído; τ : limiar sobre o erro de previsão. Avaliação inicia em $t = p+1$.

ENTRADA: série $X = \{x_1, \dots, x_T\}$, ordem p , limiar τ

PRÉ-CONDIÇÃO: modelo f treinado em dados históricos normais

PASSO 1 — Para cada $t = p+1, \dots, T$:

PASSO 2 — Prever: $\hat{x}_t = f(x_{t-1}, \dots, x_{t-p})$

PASSO 3 — Calcular erro: $g_t = |x_t - \hat{x}_t|$

PASSO 4 — Se $g_t > \tau$: marcar x_t como anomalia ($a_t = 1$)

PASSO 5 — Senão: classificar como normal ($a_t = 0$)

SAÍDA: conjunto $A = \{t : a_t = 1\}$

PÓS-CONDIÇÃO: anomalias correspondem a erros de previsão acima do limiar

Anomalias Baseadas em Distância

A normalidade é definida por similaridade estrutural: uma subsequência é anômala se não encontra vizinhos próximos na própria série. Não há modelo probabilístico — apenas distância entre padrões. Uma zona de exclusão evita comparação com subsequências sobrepostas quase idênticas.

$$\mathcal{S} = \{s_i = X_{i:i+w-1} : i = 1, \dots, T - w + 1\}$$

$$s_i = \min_{j: |i-j| > w} d(s_i, s_j)$$

$$a_i = \mathbb{I}(s_i > \tau)$$

w : tamanho da janela de subsequência; i, j : índices de subsequências em $\mathcal{S}$; $d(\cdot, \cdot)$: métrica de distância (ex: Euclidiana, DTW); $|i - j| > w$: zona de exclusão que evita comparação com subsequências sobrepostas; τ : limiar de isolamento.

ENTRADA: série $X = \{x_1, \dots, x_T\}$, janela w , limiar τ

PRÉ-CONDIÇÃO: métrica $d(\cdot, \cdot)$ definida; $w < T$

PASSO 1 — Extrair $S = \{X_{t:t+w-1} : t = 1, \dots, T-w+1\}$

PASSO 2 — Para cada subsequência $s_i \in S$:

PASSO 3 — Calcular $s_i = \min_{j: |i-j| > w} d(s_i, s_j)$

PASSO 4 — Se $s_i > \tau$: marcar s_i como anomalia ($a_i = 1$)

PASSO 5 — Senão: classificar como padrão normal ($a_i = 0$)

SAÍDA: conjunto A de subsequências anômalas (discords)

PÓS-CONDIÇÃO: anomalias são subsequências sem vizinhos próximos em S

Detecção com Aprendizado de Máquina

A tipicidade é aprendida implicitamente: o modelo f_θ aprende a representação normal diretamente dos dados, sem especificação explícita de uma distribuição. O score é o erro de reconstrução ou predição no espaço transformado.

$$Z_t = \mathcal{R}(X_{t-w+1:t}), \quad s_t = |Z_t - \hat{Z}_t|, \quad a_t = \mathbb{I}(s_t > \tau)$$

f_θ : modelo aprendido (autoencoder, LSTM, VAE); Z_t : representação da janela; $\hat{Z}_t$: reconstrução esperada; τ : limiar sobre o erro. A força do paradigma está em capturar padrões complexos e não-lineares.

ENTRADA: X_{train} (dados normais), X_{test} (série de teste), w (janela), τ (limiar)
PRÉ-CONDIÇÃO: f_θ treinado em X_{train} com dados sem anomalias; $w < T_{\text{test}}$

PASSO 1 — Treinamento (representação **normal**)

PARA cada janela $W_i = X_{\{i:i+w-1\}}$ em X_{train} :

$\hat{Z}_i \leftarrow f_\theta(W_i)$ // reconstrução ou previsão
atualizar θ via $\min ||W_i - \hat{Z}_i||$

PASSO 2 — Scoring no período de teste

PARA t de w até T_{test} :

$Z_t \leftarrow \mathcal{R}(X_{\{t-w+1:t\}})$ // extração da janela
 $\hat{Z}_t \leftarrow f_\theta(Z_t)$ // reconstrução pelo modelo
 $s_t \leftarrow |Z_t - \hat{Z}_t|$ // erro de reconstrução

PASSO 3 — Classificação

$A \leftarrow \emptyset$

PARA t de w até T_{test} :

SE $s_t > \tau$:
 $A \leftarrow A \cup \{t\}$

SAÍDA: A (conjunto de instantes anômalos)

PÓS-CONDIÇÃO: anomalias correspondem a janelas mal reconstruídas por f_θ ; τ deve ser calibrado nos resíduos de X_{train}

Síntese dos Paradigmas de Detecção

Estatístico

Tipicidade definida por distribuição probabilística conhecida ou estimada

Baseado em Modelos

Tipicidade expressa através de previsão temporal explícita

Baseado em Distância

Tipicidade determinada por similaridade de padrões na série

Aprendizado


Tipicidade aprendida implicitamente via representação e erro

Todos os paradigmas executam a mesma operação: produzir um score s_t e aplicar um limiar τ para identificar anomalias. Diferem em como definem tipicidade ($\mathcal{M}$) e representação ($\mathcal{R}$). A janela/contexto $\mathcal{C}$ é parte integrante da operação do detector, não apenas um parâmetro técnico.

$$\mathcal{D} = f(\mathcal{R}, \mathcal{M}, g, \tau, \mathcal{C})$$

f representa a regra operacional do detector — não uma função universal única, mas a composição das escolhas de $\mathcal{R}$, $\mathcal{M}$, g , τ e $\mathcal{C}$.

Trade-offs na Detecção de Anomalias



A função de custo formaliza os compromissos operacionais do detector através de pesos que refletem prioridades da aplicação.

Não existe detector ótimo universal — cada aplicação requer um ponto de operação específico. Sensibilidade compete com precisão (FN vs FP), latência compete com robustez, e complexidade compete com interpretabilidade.

A função de custo $\mathcal{L}(\mathcal{D}) = \alpha \cdot FP + \beta \cdot FN + \gamma \cdot \bar{\Delta}t$ penaliza falsos positivos, falsos negativos e atraso médio de detecção $\bar{\Delta}t$ (média dos atrasos sobre todos os eventos). Pesos diferentes definem detectores "melhores" para objetivos diferentes: um sistema de alerta crítico prioriza β alto; um sistema de monitoramento contínuo pode tolerar mais FP.

Mudança de Regime como Ponte para Detecção de Eventos

O que são mudanças de regime?

Muitas séries temporais exibem **quebras estruturais** — momentos em que a dinâmica muda abruptamente:

Mudança de regime

O processo salta entre estados com parâmetros distintos (μ_k, ϕ_k) .

Change points

A estrutura da série muda em um instante específico e permanece diferente.

Drift

Deriva gradual nos parâmetros ao longo do tempo.

A limitação dos modelos clássicos

ARIMA, SARIMA e GARCH assumem **parâmetros fixos ao longo do tempo** — são incapazes de representar dinâmicas que mudam de regime.

Quando a série exhibe quebras estruturais, esses modelos ficam mal especificados: os resíduos deixam de ser ruído branco e o poder preditivo cai.

- ❏ A detecção de **change points, quebras estruturais e drift** será tratada em profundidade no bloco dedicado a **Detecção de Eventos**.

Teste de Hipóteses para Mudança Estrutural

Visão Estatística

Detectar mudança equivale a rejeitar a hipótese de estabilidade estrutural através de testes formais.

A detecção pode ser formulada como um teste de hipóteses: sob a hipótese nula, os parâmetros do processo não mudam ao longo do tempo. Sob a hipótese alternativa, existe pelo menos um instante onde os parâmetros sofrem ruptura.

$$H_0 : \theta(t) = \theta_0 \text{ para todo } t$$

$$H_1 : \exists \tau \text{ tal que } \theta(\tau) \neq \theta(\tau - 1)$$

Segmentação Ótima

A detecção de pontos de mudança pode ser transformada em um problema de otimização. Toda segmentação induz um custo total que combina o custo de ajuste do segmento $\mathcal{C}(\cdot)$ com uma penalização pela complexidade do modelo.

Custo por Segmento

Mede quão bem o modelo ajusta cada trecho da série através do custo de ajuste $\mathcal{C}(\cdot)$

Penalização

Controla o número de mudanças para evitar complexidade excessiva

Objetivo

Minimizar o custo total penalizado

Segmentações com muitos pontos ajustam melhor os dados, mas são mais complexas. A penalização β controla esse trade-off:

$$J(\mathcal{C}) = \sum_{i=0}^k \mathcal{C}(X_{\tau_i:\tau_{i+1}}) + \beta k$$

Estatísticas de Mudança

O coração de qualquer método de detecção é uma estatística que mede a discrepância entre segmentos. Construimos um "termômetro" que compara os dados antes e depois de cada tempo t .

A função ϕ pode representar diferença de médias, razão de verossimilhança ou divergência entre distribuições. A decisão ocorre quando o score ultrapassa o limiar de detecção h (reservando τ exclusivamente para indicar a localização do ponto de mudança):

$$S_t = \phi(X_{1:t}, X_{t+1:T})$$

$$S_t > h$$

Famílias de Métodos

Família	Ideia Central	Evidência Usada	Quando Aplicar
Testes Estatísticos	Comparam modelos com e sem quebra via estatística formal	Resíduos de regressão ou verossimilhança	Ponto de mudança suspeito é conhecido ou testado pontualmente
Acumuladores Sequenciais	Acumulam evidência incremental até ultrapassar um limiar	Resíduos ou desvios da média ao longo do tempo	Detecção online em tempo real com baixa latência
Otimização / Segmentação	Buscam a partição global que minimiza custo penalizado	Custo de ajuste por segmento + penalização	Número de mudanças desconhecido, análise offline
Modelos Probabilísticos	Tratam mudanças como variáveis latentes do modelo	Distribuição a posteriori sobre segmentações	Incerteza sobre localização das mudanças é relevante
Aprendizado de Máquina	Detectam ruptura como aumento persistente do erro de previsão do modelo treinado	Erro de previsão em representação aprendida	Séries complexas sem modelo paramétrico claro

Teste de Chow

Ideia Central

Se dois modelos separados ajustam muito melhor do que um único modelo, há evidência de quebra estrutural.

$$F = \frac{(RSS_T - RSS_1 - RSS_2)/k}{(RSS_1 + RSS_2)/(T - 2k)}$$

Sob H_0 , $F \sim F(k, T-2k)$. **RSS_T** é o resíduo do modelo completo; **RSS_1** e **RSS_2** são os resíduos de cada subsegmento; **k** é o número de parâmetros.

ENTRADA: série x , modelo de regressão, candidato τ

PRÉ-CONDIÇÃO: τ especificado a priori; resíduos homocedásticos

PASSO 1 — Ajuste dos três modelos

Ajustar modelo completo $\rightarrow$ **RSS_T**

Ajustar modelo em $x_{\{1:\tau\}} \rightarrow$ **RSS_1**

Ajustar modelo em $x_{\{\tau+1:T\}} \rightarrow$ **RSS_2**

PASSO 2 — Cálculo da estatística

$$F \leftarrow \frac{[(RSS_T - RSS_1 - RSS_2) / k]}{[(RSS_1 + RSS_2) / (T - 2k)]}$$

PASSO 3 — Regra de decisão

SE $F > F_{\{\alpha\}}(k, T-2k)$:

REJEITAR H_0 : há quebra estrutural em τ

SAÍDA: decisão sobre quebra em τ

PÓS-CONDIÇÃO: τ deve ser fixado antes do teste —
busca exaustiva sobre τ invalida o nível nominal α

CUSUM

Ideia Central

Acumula resíduos padronizados de um modelo de referência. Se a soma deriva persistentemente de zero, há mudança estrutural.

$$C_t = \sum_{i=1}^t \frac{\hat{e}_i}{\hat{\sigma}}$$

C_t cruza a banda crítica $\pm b\sqrt{T}$ para sinalizar quebra. A variante de quadrados detecta mudanças na variância.

ENTRADA: série x , modelo de referência M , limiar b

PRÉ-CONDIÇÃO: M ajustado no período estável inicial

PASSO 1 — Ajuste do modelo de referência

$\hat{\sigma} \leftarrow$ desvio padrão dos resíduos de M

PASSO 2 — Acumulação dos resíduos

$C_0 \leftarrow 0$

PARA t de 1 até T :

$\hat{e}_t \leftarrow x_t - \hat{y}_t$ // resíduo do modelo

$C_t \leftarrow C_{t-1} + \hat{e}_t / \hat{\sigma}$

PASSO 3 — Regra de decisão

SE $|C_t| > b \cdot \sqrt{T}$:

SINALIZAR mudança em t

REINICIAR $C_t \leftarrow 0$ // opcional: reset após detecção

SAÍDA: instantes t onde mudança foi sinalizada

PÓS-CONDIÇÃO: sob estabilidade estrutural, a estatística permanece dentro da banda crítica $\pm b\sqrt{T}$; cruzamentos persistentes indicam mudança.

Teste de Page-Hinkley

Ideia Central

Detecta desvio sustentado da média acumulando a diferença entre observações e a média de referência μ_0 estimada em período estável inicial, descontada uma tolerância δ .

$$m_t = \sum_{i=1}^t (x_i - \mu_0 - \delta)$$

$$PH_t = m_t - \min_{1 \leq i \leq t} m_i$$

δ absorve flutuações normais; λ controla sensibilidade.

Método online — $O(1)$ por observação.

ENTRADA: série x , tolerância δ , limiar λ

PRÉ-CONDIÇÃO: $\delta > 0, \lambda > 0$

PASSO 1 — Inicialização

$m_0 \leftarrow 0$; $\min_m \leftarrow 0$; $\mu_0 \leftarrow$ média da janela de referência (período pré-mudança)

PASSO 2 — Atualização incremental

PARA t de 1 até T :

$m_t \leftarrow m_{t-1} + (x_t - \mu_0 - \delta)$

$\min_m \leftarrow \min(\min_m, m_t)$

$PH_t \leftarrow m_t - \min_m$

PASSO 3 — Regra de decisão

SE $PH_t > \lambda$:

SINALIZAR mudança em t

REINICIAR $m, \min_m, \bar{x}$

SAÍDA: instantes t onde mudança foi sinalizada

PÓS-CONDIÇÃO: atraso de detecção cresce com λ

Detecção Bayesiana (BOCPD)

Ideia Central

Trata pontos de mudança como variáveis latentes e mantém uma distribuição sobre o comprimento do segmento atual (run-length r_t).

$$P(r_t \mid x_{1:t}) \propto \sum_{r_{t-1}} P(x_t \mid r_{t-1}, x^{(r)}) P(r_t \mid r_{t-1}) P(r_{t-1} \mid x_{1:t-1})$$

ENTRADA: série x , hazard rate h , modelo preditivo

PRÉ-CONDIÇÃO: $h \in (0,1)$; modelo com atualização conjugada

PASSO 1 — Inicialização

$P(r_0 = 0) \leftarrow 1$

PASSO 2 — Atualização recursiva

PARA t de 1 até T :

$\pi(r) \leftarrow P(x_t \mid r, x^{(r)}) \cdot P(r_{t-1} = r \mid x_{1:t-1})$

$P(r_t = r+1) \leftarrow \pi(r) \cdot (1 - h)$ // segmento continua

$P(r_t = 0) \leftarrow \sum_r \pi(r) \cdot h$ // mudança ocorre

NORMALIZAR $P(r_t)$

PASSO 3 — Decisão

SE $P(r_t = 0) > \text{limiar}$: SINALIZAR mudança em t


SAÍDA: $P(r_t)$ para todo t ; instantes de mudança detectados

PÓS-CONDIÇÃO: incerteza sobre localização explicitamente quantificada

Comparação entre Detectores

AMOC e Chow test são projetados para detectar uma única quebra — retornam apenas o ponto de maior evidência. PELT e BinSeg permitem múltiplas quebras, com sensibilidades distintas controladas pela penalização.

GFT, SCP e CFETS são métodos alternativos com comportamentos intermediários. Os pontos azuis marcam o início de cada segmento; verdes indicam detecções próximas à mudança real; vermelhos indicam detecções adicionais ou tardias.



Similaridade entre Subsequências

A Métrica d

Motifs dependem fundamentalmente de uma noção de distância d entre subsequências. A métrica escolhida determina o que conta como 'mesmo padrão'. Mudar a métrica muda fundamentalmente quais padrões serão considerados recorrentes.

Distância Euclidiana

Compara valor a valor na mesma posição.

$$d_E(s_i, s_j) = \sqrt{\sum (s_i^{(k)} - s_j^{(k)})^2}$$

DTW

Dynamic Time Warping permite desalinhamento temporal entre padrões similares.

Correlação

$d_{corr}(s_i, s_j) = 1 - \rho(s_i, s_j)$. Foca na forma, não no nível absoluto.

Escolha de Métrica para Detecção de Motifs

ENTRADA: s_i, s_j (subsequências de comprimento w),

tipo_métrica $\in \{\text{euclidiana}, \text{dtw}, \text{correlação}\}$

PRÉ-CONDIÇÃO: $|s_i| = |s_j| = w$

PASSO 1 — Distância Euclidiana

SE tipo = euclidiana:

$$d \leftarrow \sqrt{\sum_k (s_i[k] - s_j[k])^2}$$

PASSO 2 — Dynamic Time Warping

SE tipo = dtw:

$$\text{DTW}[0,0] \leftarrow 0$$

PARA $i = 1..w, j = 1..w$:

$$\text{custo} \leftarrow (s_i[i] - s_j[j])^2$$

$$\text{DTW}[i,j] \leftarrow \text{custo} + \min(\text{DTW}[i-1,j], \\ \text{DTW}[i,j-1], \\ \text{DTW}[i-1,j-1])$$

$$d \leftarrow \sqrt{\text{DTW}[w,w]}$$

PASSO 3 — Correlação

SE tipo = correlação:

$$d \leftarrow 1 - \rho(s_i, s_j)$$

SAÍDA: d (distância entre s_i e s_j)

PÓS-CONDIÇÃO: $d \geq 0$; $d = 0$ sse $s_i = s_j$ (para Euclidiana e DTW)

Encontrando Motifs

Visão Geral dos Métodos

Os métodos de descoberta de motifs organizam-se em cinco grupos principais, diferindo em custo computacional e estratégia de busca:

Brute-Force

Exaustivo, $O(n^2)$. Compara todos os pares de subsequências. Exato e completo.

Index-Based

Usa PAA + SAX para indexar a série. Aproximado, $O(n \cdot \log n)$.

Random-Projection

Reduz dimensionalidade por projeção aleatória. Probabilístico.

Early-Abandon (EAD)

Otimiza Brute-Force abandonando cálculos quando distância parcial excede ϵ .

Matrix Profile (STAMP)

Estado da arte para busca par a par. $O(n^2 \cdot \log n)$ com FFT.

Detecção de Motifs por Janela Deslizante

ENTRADA: X (série temporal de comprimento T),

w (tamanho da janela), d (métrica), ϵ (limiar)

PRÉ-CONDIÇÃO: $T > w \geq 1, \epsilon > 0$

PASSO 1 — Extração de janelas

$S \leftarrow \{ X_{[t:t+w-1]} \mid t = 1, \dots, T-w+1 \}$

PASSO 2 — Cálculo de distâncias

PARA cada par $(s_i, s_j) \in S \times S, i \neq j$:

SE $|i - j| < w$: continuar # excluir sobreposição trivial

$D[i, j] \leftarrow d(s_i, s_j)$

PASSO 3 — Agrupamento por proximidade

PARA cada $s_i \in S$:

SE $D[i, j] < \epsilon$ PARA algum s_j :

adicionar (s_i, s_j) ao mesmo grupo M_k

SAÍDA: conjunto de motifs $\{ M_1, M_2, \dots, M_k \}$

PÓS-CONDIÇÃO: cada M_k é um par ou grupo de subsequências

recorrentes segundo a regra de similaridade adotada

(complete-linkage não é garantido)

Matrix Profile – STAMP

Estado da Arte em Busca Par a Par

O Matrix Profile (MP) é uma estrutura de dados que armazena, para cada subsequência de tamanho q , a distância z -normalizada à sua subsequência mais similar na série. O MP é um vetor $M \in \mathbb{R}^{n-q+1}$ e o MP Index $I \in \mathbb{R}^{n-q+1}$ registra a posição do melhor match.

STAMP – Scalable Time Series Anytime Matrix Profile

Algoritmo original do MP. Usa MASS (Mueen's Algorithm for Similarity Search) com FFT para calcular perfis de distância eficientemente. Complexidade: $O(n^2 \cdot \log n)$. Anytime: produz boa aproximação mesmo interrompido antes do fim.

SCRIMP

Refinamento do STAMP. Complexidade $O(n^2)$ — elimina o fator $\log n$. Também anytime. Ambos convergem para o MP exato.

Discords via MP

Os maiores valores do MP identificam discords — subsequências mais distantes de qualquer vizinho. MP unifica descoberta de motifs e anomalias em uma única estrutura.

Leitura do MP para Discords e Motifs

Picos em M (valores altos) → discords: subsequências sem par próximo. Vales em M (valores baixos) → motifs: subsequências com forte correspondência. O MP unifica ambas as tarefas em uma única estrutura — sem necessidade de dois algoritmos separados.

Algoritmo 5.4 — STAMP

ENTRADA: X (série principal), X' (série secundária, nil = self-join),
 q (word size)

PRÉ-CONDIÇÃO: $|X| > q \geq 1$

procedure STAMP(X , $X' = \text{nil}$, q):

$Y' \leftarrow Y \leftarrow \text{zscore}(X)$

SE $X' \neq \text{nil}$:

$Y' \leftarrow \text{zscore}(X')$

$M \leftarrow [+ \infty, \dots, + \infty]$ # MP inicializado com infinito

$I \leftarrow [0, \dots, 0]$ # MP Index inicializado com zeros

PARA $i \leftarrow 1$ até $|Y'| - q$:

$\text{seq} \leftarrow \text{subseq}(Y', i, q)$

$D_i \leftarrow \text{MASS}(\text{seq}, Y)$ # perfil de distância via FFT

$M, I \leftarrow \text{eleMin}(M, I, D_i, i:(i+q-1))$

eleMin ignora exclusion zone quando $Y = Y'$

retornar $\{M, I\}$

SAÍDA: M (Matrix Profile), I (MP Index)

PÓS-CONDIÇÃO: $M[i] = \min$ distância z -norm de $\text{subseq}(Y, i, q)$ a qualquer outra

Complexidade: $O(n^2 \cdot \log n)$ — SCRIMP melhora para $O(n^2)$

Discords Baseados em Distância

A Ideia Central

Cada janela é tratada como um ponto no espaço de subsequências. O score de isolamento $g(s_i)$ é a distância ao vizinho mais próximo. Janelas sem par próximo são discords.

$$g(s_i) = \min_{j \neq i} d(s_i, s_j)$$

g grande $\rightarrow$ janela isolada $\rightarrow$ discord. O limiar τ define o corte.

ENTRADA: série X , tamanho de janela w , limiar τ

PRÉ-CONDIÇÃO: série comparável na escala escolhida; $w \ll T$

PASSO 1 — Extração de janelas

$$S \leftarrow \{ X_{t:t+w-1} \mid t = 1, \dots, T-w+1 \}$$

PASSO 2 — Cálculo do score de isolamento

PARA cada $s_i \in S$:

$$g(s_i) \leftarrow \min_{j : |i-j| \geq w} d(s_i, s_j) \leftarrow \text{exclui sobreposição trivial}$$

PASSO 3 — Detecção

$$\text{discords} \leftarrow \{ s_i \in S \mid g(s_i) > \tau \}$$

PASSO 4 — Ranking (opcional)

$$s^* \leftarrow \operatorname{argmax}_{s_i \in S} g(s_i) \leftarrow \text{discord principal}$$

SAÍDA: conjunto discords, discord principal s^*

PÓS-CONDIÇÃO: s^* é a janela mais isolada da série

Discords via Matrix Profile

O Método Estado da Arte

O Matrix Profile M armazena, para cada subsequência s_i de tamanho w , a distância z-normalizada à sua vizinha mais próxima (excluindo a exclusion zone). Discords são as subsequências com maior valor em M — as mais isoladas da série.

$$s^* = \arg \max_i M[i]$$

Pseudocódigo

1. Construir o Matrix Profile M com STAMP ou SCRIMP
2. Identificar $i^* = \operatorname{argmax} M[i]$
3. Retornar $s_{\{i^*\}}$ como o **top-1** discord
4. Para **top-k**: mascarar exclusion zone em torno de i^* e repetir

Vantagem

A detecção de discords é gratuita após a construção do MP: argmax de M é $O(T)$. O mesmo MP usado para motifs (argmin) detecta discords (argmax) sem reprocessamento.

Abordagem por Clustering

A Ideia Central

Subsequências são tratadas como pontos em espaço vetorial.
Regiões densas formam clusters (motifs); pontos que não pertencem a nenhum cluster são discords.

$$s_i \in \text{discord} \iff s_i \notin \bigcup_k C_k$$

O que sobra fora dos grupos densos é raro — e candidato a discord.

ENTRADA: série X , tamanho de janela w , parâmetros do clustering (k ou ϵ)

PRÉ-CONDIÇÃO: distância $d(\cdot, \cdot)$ definida sobre subsequências

PASSO 1 — Extração de janelas

$$S \leftarrow \{X_{t:t+w-1} \mid t = 1, \dots, T-w+1\}$$

PASSO 2 — Clustering sobre S

$$\{C_1, C_2, \dots, C_k\} \leftarrow \text{Cluster}(S)$$

← DBSCAN: pontos fora de clusters são discords diretos

← k-means: sempre atribui pontos; discords = grande dist. ao centróide

PASSO 3 — Identificação de discords

PARA cada $s_i \in S$:

SE $s_i \notin \bigcup_k C_k$ ← critério DBSCAN

OU $\text{dist}(s_i, \text{centróide mais próximo}) > \theta$ ← critério k-means

marcar s_i como discord

PASSO 4 — Ranking (opcional)

ordenar discords por $\text{dist}(s_i, \text{centróide mais próximo}) \downarrow$

SAÍDA: conjunto de discords ordenados por isolamento

PÓS-CONDIÇÃO: clusters densos correspondem a motifs; outliers a discords

Complexidade Computacional

$O(T^2)$ Abordagem Ingênua

Comparar todas as janelas entre si via brute-force. Inviável para séries longas; custo $O(T^2)$ vezes a complexidade da distância.

STAMP – $O(n^2 \cdot \log n)$

Estado da arte para motifs e discords. Usa MASS (Mueen's Algorithm for Similarity Search) para calcular o Matrix Profile completo. Discords são identificados como argmax do vetor M — sem custo adicional após o MP estar construído.

SCRIMP – $O(n^2)$

Versão anytime do Matrix Profile: produz resultados aproximados rapidamente e refina progressivamente. Permite detectar discords em séries muito longas com orçamento de tempo limitado.

Na prática, STAMP e SCRIMP são os métodos estado da arte para detecção de discords via Matrix Profile. O custo dominante é a construção do MP — a detecção de discords (argmax de M) é $O(T)$ após isso.

O que cobrimos na Parte 3

Pipeline de detecção:
mapeamento estruturado
da representação ao
espaço de alertas

Detecção estatística: score
de log-verossimilhança e
limiares por distribuição
condicional

Modelos temporais: erro de
previsão como score de
anomalia (AR, ARIMA, redes
neurais)

Detecção por distância:
similaridade estrutural
entre subsequências sem
modelo probabilístico

Aprendizado de máquina: tipicidade
aprendida implicitamente via erro de
reconstrução

Mudança de regime: quebras
estruturais e testes formais (Chow,
CUSUM, Page-Hinkley, BOCPD)

Motifs e discords: padrões
recorrentes e subsequências raras
via Matrix Profile (STAMP/SCRIMP)