



Detecção de Eventos em Séries Temporais

parte 4 - Harbinger como ambiente experimental



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Arquitetura Modular

Princípios de Design

Construído sobre o DAL Toolbox, o framework adota uma interface estrita baseada em álgebra de fluxo de trabalho, garantindo consistência entre todos os métodos de detecção.

Inspirado na API do Scikit-learn, as funções `fit()` e `detect()` oferecem uma interface intuitiva para pesquisadores e profissionais.

01

Normalizar

Pré-processamento e padronização

03

Ajustar

Treinamento do modelo e estimação de parâmetros

02

Filtrar

Redução de ruído e realce do sinal


04

Detectar

Identificação e classificação de eventos

Avaliação e Benchmarking de Detectores

O Harbinger oferece avaliação abrangente com métricas padronizadas de precisão, revocação e alinhamento temporal, permitindo comparações objetivas entre algoritmos.



Precisão e Revocação

Quantificam a acurácia da detecção

Alinhamento Temporal


Medem a precisão do tempo

Métricas de Desempenho

Avaliação abrangente de ponta a ponta

Por que a Avaliação Rigorosa é Importante

Observar saídas do modelo não é suficiente — precisamos quantificar precisão e revocação para entender o que o detector captura e o que perde. Métricas padronizadas permitem comparações objetivas entre avaliação rígida e suave.



Do Sinal à Evidência

Uma detecção observada não prova qualidade — a avaliação transforma saídas brutas em evidências mensuráveis e defensáveis.

Tolerância Temporal

Em séries temporais, pequenos deslocamentos são frequentemente aceitáveis quando o objetivo é capturar o evento certo no momento aproximado.

Comparação Justa

Com métricas padronizadas, diferentes detectores podem ser comparados sistematicamente e reproduzidos de forma consistente.

- ❏ A avaliação padronizada faz parte do contrato central do Harbinger: **har_eval()** e **har_eval_soft()** garantem comparabilidade, rigor e consistência em todas as abordagens de detecção.

Resumo

Ambiente Unificado

O Harbinger integra detecção de anomalias, detecção de pontos de mudança e descoberta de motifs.

Arquitetura Modular

Composição flexível de detectores e modelos ensemble robustos.

Avaliação Rigorosa

Métricas de precisão/revocação garantem resultados confiáveis e verificáveis.

Representação Fuzzy de Eventos

Além do binário, para uma análise mais matizada e próxima da percepção humana.

Código Aberto e CRAN

Pronto para uso pela comunidade, contribuições e desenvolvimento ativo.

Roteiro de Aprendizagem

Caminho de aprendizagem guiado com o pacote R **harbinger** — cada tutorial se baseia no anterior, do fluxo mínimo à análise avançada de motivos.

Primeiros Passos

T01: Fluxo mínimo · T02: Explorando os dados · T03: Visualizando séries temporais

Detecção de Anomalias

T04: Detector baseado em histograma · T05: Detector ARIMA · T06: Avaliando detecções

Pontos de Mudança e Transformações

T07: Detector AMOC · T08: Médias móveis (MAS) · T09: SAX e XSAX

Motifs e Padrões

T10: Motifs e discords

📄 **Experimente você mesmo!** Exemplos completos com gráficos gerados estão disponíveis no repositório oficial. Execute o código de cada tutorial e acompanhe os resultados visuais em: <https://github.com/cefet-rj-dal/harbinger/tree/master/examples>

Referência principal: Ogasawara, E., Salles, R., Porto, F., Pacitti, E. *Event Detection in Time Series*. Springer, 2025. doi:10.1007/978-3-031-75941-3

0 Framework Harbinger

Carregar Dados

Importe seu conjunto de dados de séries temporais.

Configurar Modelo

Defina os parâmetros do algoritmo.

fit()

Treine o modelo com dados históricos.

detect()

Identifique eventos na série.

evaluate()

Avalie o desempenho da detecção.

har_plot()

Visualize os eventos detectados.

Saída Estruturada

`detect()` sempre retorna um data frame com três colunas: `idx` (índice), `event` (lógico) e `type` (categoria do evento).

Contrato Unificado

`fit()`, `detect()` e `evaluate()` compartilham a mesma interface — troque qualquer algoritmo sem alterar o código subsequente.

Visualização Universal

`har_plot()` funciona de forma idêntica para anomalias, pontos de mudança e motifs — uma interface para todos os tipos de evento.

Primeiros Passos

```
library(harbinger)

data(examples_anomalies)
dataset <- examples_anomalies$simple
head(dataset)

## serie event
## 1 1.0000000 FALSE
## 2 0.9689124 FALSE

# Plot series with labels
har_plot(harbinger(),
         dataset$serie,
         event = dataset$event)
```

```
# Create default model
model <- harbinger()

# Run detection
detection <- detect(model, dataset$serie)
head(detection)

## idx event type
## 1 1 FALSE
## 2 2 FALSE

# Plot detections vs labels
har_plot(model, dataset$serie,
         detection, dataset$event)
```

Passo a Passo

- Carregue o pacote e `examples_anomalies$simple`
- Inspecione `head()`: colunas `serie` e `event`
- Visualize a série com `har_plot()` antes de qualquer modelo
- Crie o objeto padrão `harbinger()`
- Execute `detect()` e explore a saída
- Compare as detecções com os rótulos de referência (ground-truth)

📌 **Conceito-chave:** Um método Harbinger recebe uma série temporal e retorna uma saída padronizada e orientada a eventos — pronta para visualizar ou avaliar.

Avaliando Detecções

```
library(daltoolbox)
library(harbinger)

data(examples_anomalies)
dataset <- examples_anomalies$simple
model <- hanr_arima()
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)
```

```
# Strict evaluation (hard)
hard_eval <- har_eval()
hard_result <- evaluate(hard_eval,
  detection$event, dataset$event)
hard_result$confMatrix
##      event
## detection TRUE FALSE
##   TRUE    1    0
##   FALSE    0   100
```

```
# Tolerant evaluation (soft)
soft_eval <- har_eval_soft()
soft_result <- evaluate(soft_eval,
  detection$event, dataset$event)
soft_result$confMatrix
##      event
## detection TRUE FALSE
##   TRUE    1    0
##   FALSE    0   100
```

```
# Metrics returned by both:
# accuracy=1, F1=1, precision=1,
# recall=1, balanced_accuracy=1
```

Passo a Passo

- Ajuste `hanr_arima()` e execute `detect()`
- **Avaliação rígida** (`har_eval()`): exige correspondência exata de timestamp
- **Avaliação suave** (`har_eval_soft()`): tolera pequenos deslocamentos temporais
- Ambas retornam accuracy, F1, precision, recall, balanced_accuracy
- Os resultados coincidem aqui; podem divergir em dados reais

📌 **Conceito-chave:** A avaliação suave recompensa detecções próximas, mas não exatas — reconhecendo que um timing quase certo ainda pode ser significativo na prática.

Harbinger: O Pipeline de Detecção de Eventos

O Harbinger oferece uma interface unificada `fit` → `detect` → `plot` para identificar anomalias, pontos de mudança e motivos em séries temporais. Construído sobre o DAL Toolbox, permite a troca transparente de detectores com mínimo esforço.

Ajustar

Treinar o modelo com dados de séries temporais

Detectar

Identificar eventos sinalizados em um data frame

Visualizar

Visualizar os resultados da detecção de eventos

Referência: Ogasawara, E. et al. "Event Detection in Time Series." Springer, 2025. doi:10.1007/978-3-031-75941-3

Pipeline Padrão: `harbinger()`

Demonstrações completas do pipeline padrão de detecção de eventos em conjuntos de dados de séries temporais diversos: não-estacionariedade, temperatura global (mensal/anual), multivariado e clima de Seattle.

```
# Install (once only)
#install.packages("harbinger")

# Load packages
library(daltoolbox)
library(harbinger)

# Load example datasets
data(examples_harbinger)
model <- harbinger()

# Example: non-stationarity
dataset <- examples_harbinger$nonstationarity
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)
har_plot(model, dataset$serie,
          detection, dataset$event)
```

```
# Example: global temperature (monthly)
dataset <-
examples_harbinger$global_temperature_monthl
y
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)
har_plot(model, dataset$serie,
          detection, dataset$event)

# Example: global temperature (yearly)
dataset <-
examples_harbinger$global_temperature_yearly
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)
har_plot(model, dataset$serie,
          detection, dataset$event)
```

Detalhamento Passo a Passo

- **Instalar/carregar** — `harbinger` depende de `daltoolbox`
- **`data()`** — carrega conjuntos de dados de séries temporais prontos para uso
- **`harbinger()`** — instancia o objeto do pipeline padrão
- **`fit()`** — ajusta o modelo à série temporal
- **`detect()`** — executa a detecção de eventos
- **`har_plot()`** — visualiza a série, as detecções e os eventos de referência

📌 **Conceito-chave:** O pipeline unificado `fit` → `detect` → `plot` funciona de forma consistente para anomalias, pontos de mudança e motivos — tudo pela mesma interface.

Agregação de Resíduos: Funções de Distância L1 e L2

Resíduos multidimensionais precisam ser agregados em um único sinal escalar antes da etapa de limiarização. As normas L1 e L2 são as principais estratégias de agregação.

Norma L1 (Distância de Manhattan)

Calculada como a soma dos valores absolutos dos componentes individuais do resíduo. $\sum_{i=1}^n |r_i|$

- **Robusto a outliers:** valores absolutos crescem linearmente.
- **Trata todos os desvios proporcionalmente.**
- **Ideal quando há flutuações grandes não anômalas.**

Norma L2 (Distância Euclidiana)

Calculada como a raiz quadrada da soma dos quadrados dos componentes individuais do resíduo. $\sqrt{\sum_{i=1}^n r_i^2}$

- **Sensível a grandes desvios:** erros são elevados ao quadrado.
- **Distância euclidiana,** amplamente usada em modelagem estatística.
- **Ideal quando qualquer desvio grande sinaliza anomalia.**

A escolha entre L1 e L2 influencia diretamente a eficácia da limiarização subsequente.

Referência: Ogasawara et al. (2025). Event Detection in Time Series. Springer. doi:10.1007/978-3-031-75941-3

Estratégias de Limiarização para Detecção de Anomalias

A limiarização converte o sinal residual contínuo em uma decisão binária (anomalia ou não), definindo o limite além do qual um desvio é considerado significativo.

Regra Gaussiana 3-Sigma

Sinaliza valores além de $\mu \pm 3\sigma$, assumindo distribuição normal dos resíduos.

- **Prós:** Simples, rápida e amplamente compreendida.
- **Contras:** Falha com distribuições assimétricas ou não normais.

Método Boxplot / IQR

Define limites de anomalia com base no intervalo interquartil (IQR), independentemente da forma da distribuição.

- **Prós:** Robusto a assimetria e outliers no sinal residual.
- **Contras:** Menos sensível a desvios extremos em distribuições muito amplas.

Limiarização Baseada em Razão

Sinaliza valores que desviam por uma proporção relativa de uma linha de base dinâmica, adaptando-se a mudanças de escala.

- **Prós:** Eficaz quando a variância dos resíduos muda ao longo do tempo.
- **Contras:** Requer ajuste cuidadoso; menos preciso para resíduos estáveis.

O Harbinger permite trocar estratégias via `model$har_outliers` — a escolha ideal depende da distribuição dos resíduos.

Referência: Chandola, V., Banerjee, A., Kumar, V. (2009). Anomaly detection: A survey. ACM Computing Surveys, 41(3), 1–58.

Agrupamento de Detecções: De Sequências a Eventos

Quando um limiar é ultrapassado por múltiplos passos consecutivos, gera-se uma 'sequência' de detecções para um único evento, inflando falsos positivos. O agrupamento resolve isso tratando blocos contíguos como um único evento.

Padrão: Sem Agrupamento

Cada passo sinalizado é reportado separadamente, podendo obscurecer o tempo real do evento e gerar supercontagem de anomalias.

Controlado via `model$har_outliers_check`, oferece modularidade equivalente aos demais componentes do pipeline.

Agrupado: Seleção de Pico

Usando `har_outliers_checks_highgroup`, apenas o passo com maior magnitude residual (o 'pico') é retido por sequência, fornecendo um timestamp preciso.

Referência: Sobrinho et al. (2025). Fine-Tuning Detection Criteria for Enhancing Anomaly Detection in Time Series. SBBD, SBC. doi:10.5753/sbbd.2025.247063

Avaliação Estrita: Métricas da Matriz de Confusão

A matriz de confusão é a base para avaliar objetivamente qualquer sistema de detecção de eventos, evitando que detectores que sinalizam tudo pareçam eficazes.

Verdadeiro Positivo (VP)

Uma detecção que coincide exatamente com um evento rotulado.

Falso Positivo (FP)

Uma detecção em um passo de tempo onde nenhum evento rotulado existe.

Falso Negativo (FN)

Um evento rotulado que o detector não conseguiu identificar.

Verdadeiro Negativo (VN)

Nenhum evento e nenhuma detecção, indicando inação correta.

Acurácia

$$(TP + TN) / (TP + FP + FN + TN)$$

Precisão

$TP / (TP + FP)$ – quantas detecções são eventos reais.

Revocação

$TP / (TP + FN)$ – quantos eventos reais foram capturados.

F1 Score

Média harmônica de precisão e revocação, equilibrando ambas as métricas.

No critério estrito, uma detecção é VP apenas se coincidir exatamente com o evento rotulado — sem tolerância temporal.

Avaliação Suave: Métricas com Tolerância Temporal (SoftED)

A avaliação estrita penaliza detecções ligeiramente deslocadas como falsos positivos completos — inadequado quando timestamps são incertos por atrasos de sensores ou rótulos aproximados.

Avaliação Estrita: Limitações

- Assume temporização perfeita dos eventos.
- Sem tolerância para deslocamentos temporais.
- Detecção ligeiramente deslocada é um Falso Positivo completo.
- Não reflete a imprecisão do mundo real.

SoftED: A Solução com Tolerância Temporal

- Define uma janela deslizante (`sw_size`) em torno de cada evento.
- Detecções dentro da janela recebem crédito parcial.
- Produz VP, FP, FN "suaves" para avaliação mais matizada.
- Reflete melhor o desempenho com incerteza temporal.

O SoftED integra a matriz de confusão suave ao framework familiar de precisão, revocação e F1, sendo mais adequado quando há incerteza temporal.

Referência: Salles, R. et al. (2024). SoftED: Metrics for soft evaluation of time series event detection. Computers and Industrial Engineering. doi:10.1016/j.cie.2024.110728

Inspecione Antes de Modelar

Antes de modelar, é essencial compreender a estrutura do conjunto de dados para evitar incompatibilidades com o método de detecção escolhido.

01

Estrutura do Conjunto de Dados

Uma lista de data frames, cada um representando uma série temporal.

03

Tipo de Dado

Univariado ou multivariado, conforme o número de colunas de sinal.

02

Separação de Colunas

Colunas de metadados (`idx`, `event`, `type`, `seq`, `seqlen`) são separadas das colunas de sinal.

04

Visualize Primeiro

Inspecione visualmente a série antes de prosseguir com a modelagem.

 Para um tratamento abrangente da detecção de eventos em séries temporais, consulte: Ogasawara, E., Salles, R., Porto, F., Pacitti, E. Event Detection in Time Series. Springer, 2025. doi:10.1007/978-3-031-75941-3

Padrão de Inspeção de Conjuntos de Dados

```
library(harbinger)

dataset_summary <- function(x) {
  first_series <- x[[1]]
  meta_cols <- c("idx", "event",
    "type", "seq", "seqlen")
  signal_cols <- setdiff(
    names(first_series), meta_cols)
  dataset_type <- if (
    "value" %in% names(first_series) ||
    length(signal_cols) == 1
  ) "univariate" else "multivariate"
  plot_column <- if (
    "value" %in% names(first_series)
  ) "value" else signal_cols[1]
  list(
    n_series = length(x),
    dataset_type = dataset_type,
    signal_cols = signal_cols,
    plot_column = plot_column,
    preview_size = min(1000,
      nrow(first_series)),
    first_series = first_series
  )
}
```

```
show_dataset <- function(x, name) {
  info <- dataset_summary(x)
  cat("Dataset:", name, "\n")
  cat("Number of series:",
    info$n_series, "\n")
  cat("Dataset type:",
    info$dataset_type, "\n")
  invisible(info)
}

plot_dataset_preview <- function(info) {
  preview <- info$first_series[
    seq_len(info$preview_size),,
    drop = FALSE]
  har_plot(harbinger(),
    preview[[info$plot_column]],
    event = preview$event)
}
```

Detalhamento Passo a Passo

- **meta_cols**: colunas de metadados excluídas da análise de sinal
- **signal_cols**: as colunas restantes que carregam os valores reais do sinal
- **dataset_type**: classificado como univariado se uma coluna `value` existir ou apenas uma coluna de sinal estiver presente; caso contrário, multivariado
- **plot_column**: a primeira coluna de sinal selecionada para visualização
- **preview_size**: limitado a 1.000 observações para manter os gráficos legíveis e responsivos
- **show_dataset()**: imprime um resumo conciso no console
- **plot_dataset_preview()**: chama `har_plot()` com o sinal selecionado e seus rótulos de evento

❏ **Conceito-chave:** Essas três funções auxiliares formam um padrão de inspeção reutilizável usado em todos os notebooks — carregue, resuma e visualize antes de modelar.

Yahoo S5 – Um Benchmark Rotulado para Detecção de Anomalias

O Yahoo S5, lançado pelo Yahoo Labs, é um dos benchmarks mais usados para detecção de anomalias, com quatro subcoleções (A1–A4) cobrindo cenários reais e sintéticos.

1

A1Benchmark

67 séries reais da infraestrutura do Yahoo com rótulos de anomalias de incidentes de produção.

2

A2Benchmark

100 séries univariadas sintéticas para experimentos controlados.

3

A3Benchmark

100 séries sintéticas com observações anômalas rotuladas.

4

A4Benchmark

100 séries com anomalias pontuais e pontos de mudança estrutural — os cenários mais desafiadores.

Todas as séries são univariadas; a progressão A1→A4 permite avaliação em diferentes níveis de dificuldade.

 Laptev, N., Amizadeh, S., Flint, I. (2015). Generic and scalable framework for automated time-series anomaly detection. In KDD '15.
[doi:10.1145/2783258.2788611](https://doi.org/10.1145/2783258.2788611)

NAB – Detecção de Anomalias em Fluxo em Tempo Real

O NAB avalia algoritmos em contexto de fluxo em tempo real, penalizando detecções tardias e recompensando as antecipadas — diferente dos benchmarks offline tradicionais.

Séries Sintéticas e do Mundo Real

Inclui dados de ad exchange, métricas AWS, tráfego rodoviário e volume do Twitter.

Rotulagem Orientada a Eventos

Detecções dentro de uma janela ao redor do evento verdadeiro são contadas como corretas.

Pontuação em Tempo Real

A função de pontuação penaliza explicitamente detecções tardias.

Diversidade de Domínios

Cada subcoleção representa um contexto distinto do mundo real.

Todas as séries são univariadas, simplificando o desenvolvimento de algoritmos.

 Lavin, A., Ahmad, S. (2015). Evaluating Real-Time Anomaly Detection Algorithms — The Numenta Anomaly Benchmark. In ICMLA 2015. [doi:10.1109/ICMLA.2015.141](https://doi.org/10.1109/ICMLA.2015.141)

Arquivo UCR de Anomalias – Detecção Orientada a Subsequências

O Arquivo UCR foca em anomalias de subsequências — segmentos inteiros que desviam da norma — exigindo detectores especializados distintos dos métodos pontuais.

Domínios Diversos

Inclui ECG, telemetria da NASA, sinais fisiológicos e demanda de energia elétrica.

Anomalias em Subsequências

Segmentos contíguos com desvios significativos em padrão ou comportamento.

Detectores Especializados

Requer algoritmos baseados em janela deslizante ou conscientes de subsequências.

Compacto e Representativo

Cada subcoleção tem 10–11 séries com desafios focados e variados.

Estudos Multidisciplinares

Ideal para avaliar generalização entre setores biomédico, aeroespacial e energético.

 Wu, R., Keogh, E. J. (2021). Current Time Series Anomaly Detection Benchmarks are Flawed and are Creating the Illusion of Progress. IEEE TKDE. [doi:10.1109/TKDE.2021.3112126](https://doi.org/10.1109/TKDE.2021.3112126)

Resumo da Coleção

Conjunto de Dados	Séries	Tipo	Domínio	Característica Principal
AlBenchmark	67	Univariado	Yahoo S5	Séries temporais reais rotuladas
A2 / A3 / A4	100 cada	Univariado	Yahoo S5	Sintético; A4 inclui pontos de mudança
NAB (6 grupos)	5–10	Univariado	Múltiplos	Avaliação em tempo real com janelas de eventos
UCR (4 grupos)	10–11	Univariado	Múltiplos	Detecção de anomalias em subsequências
MIT-BIH (4 derivações)	4–5	Univariado	ECG	Arritmias segmentadas por derivação
3W Oil (7 tipos)	3–12	Multivariado	Petróleo e Gás	7 sensores por série; tipos distintos de falha
GECCO	10	Univariado	Água	Eventos reais de qualidade da água

 **Referência:** Ogasawara, E., Salles, R., Porto, F., Pacitti, E. *Event Detection in Time Series*. Springer, 2025. doi:10.1007/978-3-031-75941-3

O que cobrimos na Parte 4

Pipeline de detecção: fit → detect → plot com o framework Harbinger

Agregação de resíduos: funções de distância L1 e L2

Estratégias de limiarização: conversão do sinal contínuo em decisão binária

Agrupamento de detecções: de sequências contíguas a eventos únicos

Avaliação estrita: métricas da matriz de confusão (precisão, revocação, F1)

Avaliação suave (SoftED): tolerância temporal para detecções deslocadas

Benchmarks: Yahoo S5, NAB, UCR e coleções de séries temporais rotuladas