



Detecção de Eventos em Séries Temporais

parte 5 - Anomalias



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Outliers e Anomalias Temporais

A distinção entre outliers clássicos e anomalias temporais é crucial para a análise correta de séries temporais.

Outlier Clássico

Compara x_t com uma média μ e desvio padrão σ globais, assumindo independência entre observações.


$$|x_t - \mu| > k\sigma$$

Anomalia Temporal

Considera a dependência temporal. O "típico" em t depende do histórico e do modelo, usando resíduos para medir desvios.

$$|r_t| > \lambda\sigma_r$$

Em séries temporais, a abordagem clássica é inadequada porque ignora a estrutura de dependência. A definição temporal primeiro explica o esperado naquele instante e só depois mede o desvio.



Detecção de Anomalia Estrutural Local

A Ideia Central

O processo tem parâmetros típicos θ_0 . Uma anomalia estrutural local é uma quebra temporária em $[\tau_1, \tau_2]$ após a qual o processo retorna ao regime original — diferente de uma mudança estrutural persistente.

$$\theta(t) \approx \begin{cases} \theta_0, & t \notin [\tau_1, \tau_2] \\ \theta'_0 \neq \theta_0, & t \in [\tau_1, \tau_2] \end{cases}$$

❗ Esta é uma detecção **offline**: a janela $\{x_{t-w}, \dots, x_{t+w}\}$ usa passado e futuro. Em uso **online**, use apenas janela passada $\{x_{t-w}, \dots, x_{t-1}\}$.

w é a largura da janela de teste. δ é o limiar de divergência de parâmetros. Quando o fenômeno não reverte, aproxima-se de mudança estrutural global: $X_t \sim F_{\theta_1} \rightarrow F_{\theta_2}$.

ENTRADA: x_{train} (período de referência sem anomalias), x (série completa),
 w (largura de janela), δ (limiar de divergência)

PRÉ-CONDIÇÃO: x_{train} é um período considerado normal; $T > 2w$;
estimador de parâmetros θ disponível; detecção offline

PASSO 1 — Estimação do regime de referência

$\theta_0 \leftarrow \text{estimar_parâmetros}(x_{\text{train}})$

// usar período de treinamento limpo evita contaminar θ_0 com as próprias anomalias

PASSO 2 — Varredura por janela deslizante (offline)

PARA t de $w+1$ até $T-w$:

janela $\leftarrow \{x_{t-w}, \dots, x_{t+w}\}$

$\theta_t \leftarrow \text{estimar_parâmetros}(\text{janela})$

PASSO 3 — Teste de divergência

$A \leftarrow \emptyset$

PARA t de $w+1$ até $T-w$:

SE $\text{divergência}(\theta_t, \theta_0) > \delta$:

$A \leftarrow A \cup \{t\}$

PASSO 4 — Verificação de reversão

PARA cada intervalo $[\tau_1, \tau_2] \subseteq A$:

SE $\theta(t) \approx \theta_0$ para $t > \tau_2$:

// processo retorna ao regime de referência

classificar como anomalia estrutural local

SENÃO:

// processo permanece no novo regime

classificar como mudança estrutural global

SAÍDA: A particionado em anomalias locais e mudanças globais

PÓS-CONDIÇÃO: anomalias locais satisfazem $\theta(t) \rightarrow \theta_0$ após τ_2 ; mudanças globais persistem

Detecção por Limiar Estatístico

A Ideia Central

Uma anomalia ocorre quando o resíduo r_t supera λ desvios padrão da variabilidade típica. O modelo define o esperado; o limiar define o inaceitável.

$$r_t = x_t - \hat{x}_t, \quad |r_t| > \lambda \sigma_r$$

λ controla a sensibilidade: valores menores detectam mais, com risco de falsos positivos. α controla a raridade: $\mathbb{P}(|R_t| > |r_t|) < \alpha$.

- ❑ σ_r estimado no treinamento — em uso preditivo, não usar resíduos futuros para estimar a variabilidade típica.

ENTRADA: x_{train} (período de treinamento), x_{test} (período de teste), M (modelo ajustado), λ (sensibilidade)
PRÉ-CONDIÇÃO: M estimado sobre x_{train} ; σ_r calculado nos resíduos de treinamento; resíduos aproximadamente estacionários

PASSO 1 — Estimação da variabilidade típica (treinamento)

PARA t em x_{train} :

$$\hat{x}_t \leftarrow E[x_t \mid F_{\{t-1\}}, M]$$

$$r_t \leftarrow x_t - \hat{x}_t$$

$$\sigma_r \leftarrow \text{desvio_padrão}(\{r_t : t \in x_{\text{train}}\})$$

PASSO 2 — Geração dos resíduos de teste

PARA t em x_{test} :

$$\hat{x}_t \leftarrow E[x_t \mid F_{\{t-1\}}, M]$$

$$r_t \leftarrow x_t - \hat{x}_t$$

PASSO 3 — Classificação

$$A \leftarrow \emptyset$$

PARA t em x_{test} :

$$\text{SE } |r_t| > \lambda \cdot \sigma_r:$$

$$A \leftarrow A \cup \{t\}$$

SAÍDA: A (conjunto de instantes anômalos no período de teste)

PÓS-CONDIÇÃO: sob resíduos padronizados aproximadamente $N(0,1)$, λ controla a taxa esperada de alarmes — a afirmação só vale se resíduos forem independentes e bem calibrados

Detecção por Densidade Condicional

A Ideia Central

O comportamento esperado é a distribuição condicional p_t , estimada a partir do contexto C_t . Se o valor observado cai numa região de baixa densidade sob p_t , é anômalo.

$$x_t \mid C_t \sim p_t, \quad p_t(x_t) < \varepsilon$$

p_t pode ser estimada por kernel, mistura de gaussianas ou outro estimador não-paramétrico. ε é o limiar de baixa densidade — sua escala depende do estimador usado.

ENTRADA: x (série temporal), k (largura de janela de contexto), ε (limiar de densidade)

PRÉ-CONDIÇÃO: comprimento $T > k$; estimador de densidade não-paramétrico disponível; ε calibrado na escala do estimador

PASSO 1 — Construção do contexto e estimação de p_t

PARA t de $k+1$ até T :

$C_t \leftarrow \{x_{t-k}, \dots, x_{t-1}\}$

$p_t \leftarrow \text{estimar_densidade}(C_t)$

// C_t exclui x_t para evitar vazamento de informação

PASSO 2 — Avaliação da densidade no ponto observado

PARA t de $k+1$ até T :

$\text{score}_t \leftarrow p_t(x_t)$

PASSO 3 — Classificação

$A \leftarrow \emptyset$

PARA t de $k+1$ até T :

SE $\text{score}_t < \varepsilon$:

$A \leftarrow A \cup \{t\}$

SAÍDA: A (conjunto de instantes anômalos)

PÓS-CONDIÇÃO: anomalias correspondem a regiões de baixa probabilidade condicional sob p_t ; ε deve ser validado empiricamente

Três Níveis de Formalização

A síntese organiza a noção de anomalia em três "portas de entrada" complementares que formam um conjunto unificado. A união $\mathbf{A} = \mathbf{A}_{stat} \cup \mathbf{A}_{dist} \cup \mathbf{A}_{struct}$ é uma organização conceitual — as classes não são necessariamente disjuntas.

Estatístico

Desvio raro nos resíduos, medido por limiar λ sobre σ_r .

$$|r_t| > \lambda \sigma_r$$

Critério: limiar sobre desvio padrão dos resíduos de treinamento.

Distribucional

Ocorrência improvável sob distribuição condicional p_t estimada no contexto C_t .

$$p_t(x_t) < \varepsilon$$

Critério: densidade local — ε calibrado na escala do estimador.

Estrutural

Divergência temporária de parâmetros em $[\tau_1, \tau_2]$, com retorno ao regime θ_0 .

$$\theta(t) \neq \theta_0 \text{ em } [\tau_1, \tau_2]$$

Critério: divergência(θ_t, θ_0) $> \delta$, verificada por janela deslizando offline.

$$\mathcal{A} = \mathcal{A}_{stat} \cup \mathcal{A}_{dist} \cup \mathcal{A}_{struct}$$

Mudar o critério muda o conjunto de anomalias detectadas.

Desafios na Detecção de Anomalias

Quatro tensões metodológicas que afetam qualquer sistema de detecção.

Definição de Comportamento Típico

O que é "normal" em processos não-estacionários e com múltiplos regimes?

Escolha de Representação

Qual transformação preserva a informação relevante para a detecção?

Sensibilidade vs Especificidade

Como detectar anomalias reais sem gerar excessivos falsos positivos?

Adaptação Temporal

Como ajustar modelos conforme o processo evolui ao longo do tempo?

Cenários, Janela e Arquitetura

O detector não opera sobre a série inteira — ele usa um contexto W . O cenário temporal determina a restrição de informação disponível; a arquitetura determina como W é atualizado.

Offline

Série completa $X_{1:T}$ disponível. Permite calibração global com toda a informação.

Online

Dados chegam sequencialmente. Decisões tomadas à medida que observações aparecem.

Preditivo

Estima $\mathbb{P}(a_{t+h} = 1 | \mathcal{F}_t)$: probabilidade de anomalia futura dado o histórico $\mathcal{F}_t$ até t , com horizonte h .

Batch

Contexto fixo. Processamento completo da janela de uma só vez.

Streaming

Contexto deslizante. Atualização incremental; W define também memória e custo computacional.

Híbrida

Contexto adaptativo. Combina processamento completo e incremental.

Tamanho da Janela w — Janela Pequena

Reação rápida, mas pode confundir ruído com anomalia — sensível a variações locais.

Tamanho da Janela w — Janela Grande

Decisão estabilizada, mas aumenta latência e pode diluir desvios curtos.

Mudar w altera o que conta como "recente" e pode modificar o conjunto de anomalias detectadas.

Avaliação: Acerto e Pontualidade

Avaliar um detector significa entender quatro tipos de resultado possíveis — e, em séries temporais, também o quão rápido a detecção ocorre.

Acerto (*True Positive*)

Anomalia real detectada corretamente.

Falso Alarme (*False Positive*)

Alerta disparado sem anomalia real.

Evento Perdido (*False Negative*)

Anomalia real não detectada.

Atraso (*Latency*)

Detecção correta, mas tardia.

Precisão e revocação comparam os conjuntos $\hat{A}$ e A , mas exigem uma regra de correspondência temporal — a interseção exata pode ser injusta quando uma detecção ligeiramente deslocada ainda é útil.

Atraso de Detecção

$\Delta t = \max(0, t_{\text{det}} - t_{\text{real}})$ mede o tempo entre a anomalia real e sua detecção.

Métrica com Penalização Temporal

$Q = F_1 \cdot P(\Delta t)$, onde $P(\Delta t) = e^{-\lambda \Delta t}$ é uma escolha de penalização — não uma métrica universal.

ARIMA – Autoregressive Integrated Moving Average

Como funciona

- Modela a série como combinação linear de valores passados (AR), erros passados (MA) e diferenciação para estacionariedade (I)
- `fit()` seleciona automaticamente a ordem (p,d,q) e estima os parâmetros
- `detect()` calcula resíduos padronizados: $(\text{observado} - \text{previsto}) / \sigma$
- Resíduos acima do limiar (via `harutils()`) são sinalizados como anomalias

Quando usar

- Séries com estrutura de autocorrelação linear
- Séries estacionárias ou facilmente diferenciadas
- Quando se prefere um modelo estatístico consolidado

Parâmetros principais

- Sem parâmetros obrigatórios — seleção automática via `auto.arima()`
- Limiar controlado internamente por `harutils()`

Referência

Box, G.E.P. & Jenkins, G.M. (1976). Time Series Analysis: Forecasting and Control. Holden-Day.

📄 Score de anomalia: $|\text{resíduo padronizado}|$.
Grandes desvios da previsão ARIMA sinalizam anomalias.

02 · hanr_arima() – Resíduos ARIMA

```
library(daltoolbox)
library(harbinger)

data(examples_anomalies)
dataset <- examples_anomalies$simple

# Visualizar série bruta
har_plot(harbinger(), dataset$serie)

# Configurar detector ARIMA
model <- hanr_arima()

# Ajustar (estima ordem ARIMA
# e armazena parâmetros)
model <- fit(model, dataset$serie)

# Detectar (calcula resíduos
# padronizados e flags)
detection <- detect(model,
                    dataset$serie)
```

```
print(detection |>
      dplyr::filter(event == TRUE))
## idx event type
## 1 50 TRUE anomaly

# Avaliar
evaluation <- evaluate(model,
                       detection$event, dataset$event)
print(evaluation$confMatrix)
## detection TRUE FALSE
##   TRUE  1   0
##  FALSE  0 100

# Plotar detecções vs ground truth
har_plot(model, dataset$serie,
          detection, dataset$event)

# Plotar magnitude dos resíduos
# e limiares de decisão
har_plot(model,
          attr(detection, "res"),
          detection, dataset$event,
          yline = attr(detection,
                       "threshold"))
```

Passo a passo

- Mesmo fluxo: carregar dados, visualizar, configurar, ajustar, detectar
- `hanr_arima()` sem argumentos usa seleção automática de ordem
- `fit()` estima ARIMA(p,d,q) e armazena os parâmetros
- `detect()` calcula resíduos padronizados e aplica limiar via `harutils()`
- Resultado perfeito neste dataset: 1 VP, 0 FP
- O segundo `har_plot()` exibe magnitudes dos resíduos com a linha de limiar

📌 **Conceito-chave:** Ajusta um modelo ARIMA(p,d,q) à série e usa resíduos padronizados elevados como evidência de anomalia. Limiares definidos via `harutils()`.

Família de Métodos Residuais – Visão Geral

ARIMA

Ajusta um modelo estatístico e usa resíduos padronizados para detecção de anomalias.

FBIAD

Compara inércia direta e reversa em janelas deslizantes para identificar desvios.

EMD/REMD

Decompõe a série em modos empíricos e analisa componentes em busca de anomalias.

FFT + Changepoint

Filtra o espectro de potência e detecta pontos de mudança para identificar anomalias.

📌 **Conceito-chave:** Todos os métodos compartilham o mesmo fluxo: `fit()` → `detect()` → `evaluate()`. A diferença está em como cada um calcula o score de anomalia.

GARCH – Generalized Autoregressive Conditional Heteroscedasticity

Como funciona

- Modela a variância condicional como função de resíduos quadráticos passados (termos ARCH) e variâncias passadas (termos GARCH)
- `harbinger` usa `sGARCH(1,1)` com equação de média ARMA por padrão
- `fit()` estima as equações de média e variância simultaneamente
- `detect()` calcula resíduos padronizados: $(\text{observado} - \text{média}) / \text{desvio_condicional}$
- Pontos com resíduos padronizados elevados — acima do previsto pela volatilidade local — são sinalizados

Quando usar

- Séries com volatilidade variável no tempo (agrupamento de volatilidade)
- Dados financeiros ou de sensores com variância variável
- Quando anomalias se manifestam como picos relativos ao ruído local, não à média global

Parâmetros principais

- Sem parâmetros obrigatórios — `sGARCH(1,1)` com média ARMA é o padrão
- Limiar via `harutils()`

Referências

Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.

Bollerslev, T. (1986). Generalized autoregressive conditional heteroscedasticity. *Journal of Econometrics*, 31(3), 307–327.

📄 **Score de anomalia:** $|\text{resíduo padronizado}|$ relativo à variância condicional. Captura picos elevados dado o nível de volatilidade local.

11 · hanr_garch() – Heterocedasticidade Condicional

```
library(daltoolbox)
library(harbinger)

data(examples_anomalies)
dataset <- examples_anomalies$simple

# Configurar detector GARCH
# Configuração típica: sGARCH(1,1)
# com média ARMA
model <- hanr_garch()
model <- fit(model, dataset$serie)

detection <- detect(model,
                    dataset$serie)

print(detection |>
      dplyr::filter(event == TRUE))
## idx event type
## 1 50 TRUE anomaly
```

```
evaluation <- evaluate(model,
  detection$event, dataset$event)
print(evaluation$confMatrix)
## detection TRUE FALSE
##   TRUE  1   0
##   FALSE 0 100

har_plot(model, dataset$serie,
  detection, dataset$event)

har_plot(model,
  attr(detection, "res"),
  detection, dataset$event,
  yline = attr(detection,
    "threshold"))
```

Passo a passo

- Ajusta um modelo GARCH para capturar heterocedasticidade condicional
- Configuração padrão: sGARCH(1,1) com equação de média ARMA
- Observações com resíduos padronizados elevados são sinalizadas como anomalias
- Resíduos são sumarizados e limitados via `harutils()`
- Mais adequado para séries com volatilidade variável no tempo

 **Conceito-chave:** GARCH modela a variância condicional da série. Anomalias são pontos com resíduos padronizados elevados — desvios que superam o previsto pela volatilidade local. Refs: Engle 1982, Bollerslev 1986.

Resumo: Fundamentos e Modelos Residuais

Fundamentos

`hanr_histogram()`

Primeira linha de base para qualquer dataset. Sem parâmetros de modelo — foca na distribuição empírica. Rápido e interpretável.

Modelos Residuais

`hanr_arima()`, `hanr_fbiad()`, `hanr_emd()`, `hanr_fft()` (+ AMOC, BinSeg, CUSUM, SMA variants), `hanr_garch()`, `hanr_remd()`, `hanr_rtad()`, `hanr_wavelet()`

Use quando a série tem estrutura temporal conhecida. Cada método ajusta um modelo diferente (estatístico, espectral, decomposição ou volatilidade) e sinaliza observações cujos resíduos superam o limiar. A maioria obteve 1 VP, 0 FP no dataset simples — REMD produziu 1 FP pela sensibilidade combinada EMD+ARIMA.

Métodos de Ensemble para Detecção de Anomalias – Teoria

Métodos de ensemble combinam múltiplos detectores base para obter resultados mais robustos e precisos do que qualquer detector isolado.

Combinação de Detectores	Motivação e Robustez	Votação por Maioria	Diversidade de Detectores	Equilíbrio Viés-Variância
Combinam previsões de vários detectores individuais, produzindo decisões mais confiáveis e resilientes a ruído.	Detectores individuais têm pontos fortes e fracos distintos. Combiná-los reduz falsos positivos e aumenta a robustez geral.	Um ponto é sinalizado como anomalia apenas se a maioria dos detectores base o identificar como tal, exigindo consenso forte.	A eficácia do ensemble depende da diversidade dos detectores base — combinar famílias distintas (ARIMA, EMD, FBIAD) garante cobertura ampla.	Ensembles diversos reduzem a variância das previsões sem aumentar o viés, resultando em detecção mais estável.

Cited: Dietterich, T. G. (2000). Ensemble methods in machine learning. In International Workshop on Multiple Classifier Systems. Springer. | Aggarwal, C. C. (2017). Outlier Analysis (2nd ed.). Springer. — Chapter on ensemble methods for outlier detection.

Fuzificação Temporal em Ensembles – Teoria

Em ensembles, detectores base frequentemente identificam a mesma anomalia com pequenos deslocamentos temporais. A fuzificação temporal resolve esse problema garantindo consenso robusto.

O Desafio do Deslocamento Temporal

Detectores diferentes podem sinalizar a mesma anomalia em instantes ligeiramente distintos, dificultando o consenso e a avaliação precisa.

Definição de Fuzificação Temporal

Técnica que mescla detecções individuais ocorridas dentro de uma janela `time_tolerance` antes da votação do ensemble.

Mecanismo de Fusão

Flags dentro da janela `time_tolerance` são consolidados em um único evento por detector, simplificando a entrada para o mecanismo de consenso.

Benefícios: Precisão e Alinhamento

Evita a contagem dupla de uma mesma anomalia e alinha as detecções com a granularidade dos rótulos de ground truth.

Quando Usar Fuzificação

Especialmente útil quando detectores apresentam deslocamentos temporais sistemáticos em relação à ocorrência real da anomalia.

Cited: Tatbul, N., Lee, T. J., Zdonik, S., Alam, M., & Gottschlich, J. (2018). Precision and recall for time series. In Advances in Neural Information Processing Systems (NeurIPS). | Gama, J., Zliobaite, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. ACM Computing Surveys.

Análise de Componentes Principais para Detecção de Anomalias

A maioria dos métodos opera em uma única série. Quando múltiplas variáveis correlacionadas são observadas, anomalias podem ser visíveis apenas no comportamento conjunto.

Como o PCA funciona para detecção de anomalias:

- 1. PCA aprende um subespaço de baixa dimensão que captura a variância normal dos dados
- 2. Cada nova observação é projetada nesse subespaço e reconstruída
- 3. O erro de reconstrução mede o desvio da observação em relação ao subespaço normal
- 4. Observações com erro elevado são sinalizadas como anomalias

Entrada	Modelo	Score de anomalia
DataFrame multivariado (múltiplas séries simultâneas)	Projeção linear nos componentes principais	Erro de reconstrução (norma L2 do resíduo)
Limiar	Função Harbinger	
Estimado automaticamente dos resíduos de treinamento	hmu_pca()	

❏ Ref: Jolliffe, I.T. (2002). Principal Component Analysis. Springer, 2nd ed. | Shyu et al. (2003). A Novel Anomaly Detection Scheme Based on Principal Component Classifier. ICDM.

Autoencoders – Detecção de Anomalias por Reconstrução

Um autoencoder é uma rede neural treinada para comprimir uma entrada em uma representação latente compacta e depois reconstruí-la. Treinado apenas com dados normais, falha em entradas anômalas, gerando alto erro de reconstrução.

Pipeline de detecção de anomalias:

1. Treinar o autoencoder em janelas normais da série temporal
2. Para cada nova janela, calcular o erro de reconstrução
3. Se o erro superar o limiar aprendido, sinalizar a janela como anômala

Nota: No Harbinger, todas as variantes são acessadas via `han_autoencoder(encoder_size, decoder_size, type, num_epochs)` — apenas o argumento `type` muda.

autoenc_ed

Básico: baseline denso encoder-decoder

autoenc_denoise_ed

Denoising: treinado com entradas corrompidas para robustez a ruído

autoenc_conv_ed

Convolucional: camadas Conv1D para detecção de padrões locais

autoenc_lstm_ed

LSTM: camadas recorrentes para dependências temporais de longo alcance

autoenc_stacked_ed

Empilhado: múltiplas camadas ocultas para representações profundas

autoenc_variational_ed

VAE: probabilistic latent space (μ, σ^2)

autoenc_adv_ed

AAE: regularização adversarial do espaço latente

O que cobrimos na Parte 5

Anomalia estrutural local:
quebra temporária de
parâmetros com retorno ao
regime original

**Detecção por limiar
estatístico:** resíduo r_t
comparado a λ desvios
padrão da variabilidade
típica

**Detecção por densidade
condicional:** observação
avaliada contra a
distribuição condicional p_t
estimada do contexto

Três níveis de formalização:
 $A = A_{\text{stat}} \cup A_{\text{dist}} \cup$
 A_{struct} como conjunto
unificado de anomalias

Desafios metodológicos:
definição de normalidade,
separabilidade, latência e
custo de anotação

Métodos de ensemble:
combinação de detectores
base para robustez e
precisão superiores

Fuzificação temporal:
consenso robusto entre
detectores com
deslocamentos temporais
distintos

PCA multivariado: detecção
via erro de reconstrução no
subespaço de baixa
dimensão

Autoencoders: variantes densas, denoising, convolucionais, LSTM, VAE e AAE para detecção por reconstrução