



Detecção de Eventos em Séries Temporais

parte 7 - Motifs e discords



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Escala Temporal dos Motifs

Motifs Locais

Aparecem em uma região específica $X_{t_0:t_1}$, sugerindo padrões típicos de um regime ou fase particular.

Motifs Globais

Aparecem ao longo de toda a série $X_{1:T}$, revelando regularidade estrutural que se repete consistentemente no processo.

Motifs nos Componentes Temporais

Motifs podem aparecer no sinal bruto ou em séries transformadas — qualquer componente ou derivada da série original é um domínio válido de busca.

Motifs de Valor (M_{val})

Padrões recorrentes no nível observado x_t .
Ex.: uma forma de preço recorrente no sinal bruto, antes de qualquer transformação.

Motifs de Tendência (M_{trend})

Padrões em $tr(x_t)$: subidas/descidas similares que se repetem no componente de tendência extraído.

Motifs de Volatilidade (M_{vol})

Padrões em $v(x_t)$: períodos de alta/baixa variância recorrentes na série de resíduos ou em medidas de volatilidade.

O conjunto completo é a união: $\mathbf{M} = \mathbf{M}_{val} \cup \mathbf{M}_{trend} \cup \mathbf{M}_{vol}$. Esta abordagem conecta motifs com a engenharia de features temporais.

Estrutura Conceitual dos Motifs

Motifs emergem de três escolhas fundamentais que definem o procedimento operacional. Não existe "motif universal" - tudo depende destas definições.

Subsequências ($\mathcal{S}$)

Definir as janelas de análise

Distância (d)

Escolher métrica de similaridade

Janela (w)

Determinar escala temporal

Limiar (ϵ)

Controlar o critério de agrupamento

O resultado é sintetizado como: $\mathcal{M} = f(\mathcal{S}, d, w, \epsilon)$, onde f representa o procedimento de detecção e agrupamento. Trocar qualquer um desses elementos muda fundamentalmente o resultado.

Motifs e Sazonalidade

Sazonalidade é repetição com período fixo T_s , tipicamente ligada ao calendário. Motifs podem ser buscados diretamente no componente sazonal π_t .

Periodicidade

Em uma série periódica com período T_s , janelas separadas por T_s tendem a ser similares: $X_{t:t+w-1} \approx X_{t+T_s:t+T_s+w-1}$. Motifs capturam essa repetição localmente.

Isolar o componente sazonal permite interpretar motifs como padrões recorrentes associados diretamente à sazonalidade.

Decomposição Sazonal

A série pode ser decomposta em $x_t = \beta_t + \pi_t + \omega_t$, onde π_t é o componente sazonal de período T_s .

Definição Matemática de Motif

Um motif pode ser definido como o par mais próximo de subsequências ou como um grupo de subsequências mutuamente similares — a escolha depende do algoritmo e da aplicação.

Definição por Par

O par (s_i, s_j) com menor distância $d(s_i, s_j)$ na série, excluindo sobreposições triviais.

Definição por Grupo

$\mathcal{M}_k = \{s \in \mathcal{S} \mid d(s, s') < \varepsilon, \text{ para algum } s' \in \mathcal{M}_k\}$ — conjunto de subsequências mutuamente próximas segundo ε .

Indexação de Séries Temporais

Pré-processamento para Busca Eficiente

Antes de buscar motifs, a série é normalizada e comprimida para reduzir custo computacional. As duas técnicas centrais são PAA e SAX, frequentemente aplicadas em sequência.

Z-Score

Normalização padrão: média zero e variância um. Garante comparabilidade entre séries de escalas diferentes. Pré-condição para a maioria dos métodos.

PAA – Piecewise Aggregate Approximation

Reduz n observações para n' calculando a média de segmentos iguais. Complexidade $O(n + k)$. Fórmula: $x'_j = (n/n') \cdot \sum x_t$ para t de $n'(j-1)+1$ até $n' \cdot j$.

SAX – Symbolic Aggregation Approximation

Discretiza os valores em símbolos de um alfabeto de tamanho m usando limiares da distribuição Gaussiana. Complexidade $O(n + m \cdot \log m)$. Permite busca exata por string matching.

Pré-processamento: Z-Score $\rightarrow$ PAA $\rightarrow$ SAX

ENTRADA: X (série de comprimento n), n' (tamanho PAA),
 m (tamanho do alfabeto SAX)

PRÉ-CONDIÇÃO: $n > n' \geq 1$, $m \geq 2$

PASSO 1 — Normalização Z-Score

$X' \leftarrow \text{zscore}(X)$

X' com média 0 e variância 1

PASSO 2 — PAA: redução dimensional

PARA $j = 1$ até n' :

$x'_j \leftarrow (n/n') \cdot \sum X'_t$, $t = n'(j-1)+1 \dots n' \cdot j$

Complexidade: $O(n + k)$

PASSO 3 — SAX: discretização simbólica

Definir limiares $\beta_1 < \beta_2 < \dots < \beta_{m-1}$ (Gaussiana)

PARA cada x'_j em X' :PAA:

$y_j \leftarrow a_k$ tal que $x'_j \in [\beta_{k-1}, \beta_k]$

Complexidade: $O(n + m \cdot \log m)$

SAÍDA: Y (série simbólica de comprimento n')

PÓS-CONDIÇÃO: $Y \in \{a_1, \dots, a_m\}^{n'}$, pronta para busca por string matching

Brute-Force Discovery

Busca Exaustiva

O método mais simples e exato. Compara todos os pares possíveis de subsequências da série normalizada.

Garante cobertura completa, mas tem custo $O(n^2)$ vezes a complexidade da função de distância. Adequado para séries curtas ou word sizes pequenos.

Parâmetros

X: série temporal; q: word size (tamanho da subsequência); σ : suporte mínimo (número mínimo de ocorrências); ϵ : limiar de distância.

Complexidade

$O(n^2) \times O(\text{dist})$. Para distância Euclidiana: $O(n^2 \cdot p)$. Exato — não há aproximação. Inviável para séries longas com word sizes grandes.

ENTRADA: X (série temporal), q (word size), σ (suporte mínimo), ϵ (limiar)

PRÉ-CONDIÇÃO: $|X| > q \geq 1, \sigma \geq 1, \epsilon > 0$

procedure BruteForce(X, q, σ , ϵ):

$X' \leftarrow \text{zscore}(X)$

motifs $\leftarrow \emptyset$

PARA i $\leftarrow 1$ até $|X'| - q$:

p $\leftarrow \text{subseq}(X', i, q)$

occurrences $\leftarrow \{i\}$

PARA j $\leftarrow i + 1$ até $|X'| - q$:

p' $\leftarrow \text{subseq}(X', j, q)$

SE $\text{dist}(p, p') < \epsilon$:

occurrences $\leftarrow \text{occurrences} \cup \{j\}$

SE $|\text{occurrences}| \geq \sigma$:

motifs $\leftarrow \text{motifs} \cup \{p, \text{occurrences}\}$

retornar motifs

SAÍDA: conjunto de motifs com suas ocorrências

PÓS-CONDIÇÃO: todo motif q tem $|\text{occurs}(q, X)| \geq \sigma$ e $\text{dist} < \epsilon$ entre ocorrências

Index-Based Discovery

Busca Aproximada por Indexação

Em vez de calcular distâncias exatas entre todas as subsequências, a série é indexada com PAA + SAX. A busca por motifs torna-se uma operação de agrupamento simbólico — muito mais eficiente. Representante: EMMA (Enumeration of Motifs Through Matrix Approximation).

Parâmetros

X: série temporal; a: tamanho do alfabeto SAX; k: número de segmentos PAA; q: word size; σ : suporte mínimo.

Complexidade

$O(n \cdot \log n)$. Aproximado — tolera erros introduzidos pela discretização PAA/SAX. Adequado para séries longas onde Brute-Force é inviável.

Algoritmo 5.2 — Index-Based Discovery

ENTRADA: X (série temporal), a (alfabeto SAX),
k (segmentos PAA), q (word size), σ (suporte mínimo)
PRÉ-CONDIÇÃO: $|X| > q \geq 1, \sigma \geq 1$

```
procedure IndexBased(X, a, k, q,  $\sigma$ ):  
  X'  $\leftarrow$  zscore(X)  
  Y  $\leftarrow$  PAA(X', k)    # redução dimensional  
  Y'  $\leftarrow$  SAX(Y, a)    # discretização simbólica  
  W  $\leftarrow$  sw(Y', q)    # sliding window sobre Y'  
  motifs  $\leftarrow$  group_by_having(W,  $\sigma$ )  
  retornar motifs
```

SAÍDA: motifs com ocorrências $\geq \sigma$
PÓS-CONDIÇÃO: motifs agrupados por igualdade simbólica em Y'
Complexidade: $O(n \cdot \log n)$

Random-Projection Discovery

Busca Probabilística por Projeção Aleatória

Reduz a dimensionalidade das janelas por projeção aleatória de q colunas, usando Hamming Distance com tolerância ext — inspirado em princípios genéticos de mutação em sequências de DNA. O resultado é probabilístico: o algoritmo é executado múltiplas vezes e uma collision matrix acumula os candidatos mais frequentes.

Parâmetros

X : série temporal; q : word size; ext : tolerância Hamming (número de posições que podem diferir); σ : suporte mínimo.

Collision Matrix

A cada execução, posições com matches incrementam a collision matrix. Após múltiplas iterações, os índices com maior contagem são os candidatos a motif. A propriedade é probabilística — não há garantia de completude.

Complexidade

Sub-quadrática. Pode ser aplicado diretamente a séries numéricas, acelerando casos onde subsequências claramente não são motifs.

Algoritmo 5.3 — Random-Projection Discovery

ENTRADA: X (série temporal), q (word size),
 ext (tolerância Hamming), σ (suporte mínimo)
PRÉ-CONDIÇÃO: $|X| > q \geq 1$, $ext \geq 0$, $\sigma \geq 1$

```
procedure RandomProjection( $X$ ,  $q$ ,  $ext$ ,  $\sigma$ ):  
   $Y \leftarrow \text{index}(X)$       # Z-Score + SAX  
   $W \leftarrow \text{sw}(Y, q + ext)$  # janela alargada com tolerância  
   $W' \leftarrow \text{project}(W, q)$   # projeção aleatória de  $q$  colunas  
  motifs  $\leftarrow \text{group\_by\_having}(W', \sigma)$   
  retornar motifs
```

Para motifs longos: repetir com collision matrix
procedure RandomProjectionMulti(X , q , ext , σ , R):

```
 $C \leftarrow \text{zeros}(|X|)$       # collision matrix  
PARA  $r \leftarrow 1$  até  $R$ :  
   $W' \leftarrow \text{RandomProjection\_step}(X, q, ext)$   
  PARA cada par  $(i, j)$  com match em  $W'$ :  
     $C[i] \leftarrow C[i] + 1$   
     $C[j] \leftarrow C[j] + 1$   
  motifs  $\leftarrow$  índices com  $C[i] \geq \sigma$   
  retornar motifs
```

SAÍDA: motifs (probabilístico)
PÓS-CONDIÇÃO: resultado converge com R iterações
Complexidade: sub-quadrática; resultado probabilístico

Early-Abandon Distance (EAD)

Otimização do Brute-Force por Abandono Antecipado

O EAD otimiza o Brute-Force abandonando o cálculo da distância assim que a distância parcial acumulada já excede o limiar ϵ . Para a distância Euclidiana, em vez de aplicar a raiz quadrada ao final, eleva-se ϵ ao quadrado e verifica-se a soma parcial componente a componente.

Vantagem 1 – Verificação mais rápida

Evita o cálculo da raiz quadrada: compara a soma parcial $\sum(p[k]-p'[k])^2$ com ϵ^2 a cada componente. Se exceder, abandona imediatamente.

Vantagem 2 – Redução do espaço de busca

Evita matches triviais entre janelas vizinhas, reduzindo o número de pares efetivamente comparados. Economias empíricas significativas em dados reais.

Complexidade

Mesma complexidade assintótica do Brute-Force: $O(n^2)$. Porém, com ganhos práticos expressivos — o abandono antecipado reduz drasticamente o número de operações executadas.

ENTRADA: X (série temporal), q (word size), σ (suporte mínimo), ϵ (limiar)

PRÉ-CONDIÇÃO: $|X| > q \geq 1, \sigma \geq 1, \epsilon > 0$

procedure EAD(X, q, σ, ϵ):

$X' \leftarrow \text{zscore}(X)$

$\epsilon^2 \leftarrow \epsilon * \epsilon$ # evita raiz quadrada no loop

$\text{motifs} \leftarrow \emptyset$

PARA $i \leftarrow 1$ até $|X'| - q$:

$p \leftarrow \text{subseq}(X', i, q)$

$\text{occurrences} \leftarrow \{i\}$

PARA $j \leftarrow i + 1$ até $|X'| - q$:

$p' \leftarrow \text{subseq}(X', j, q)$

$\text{soma} \leftarrow 0$

$\text{abandonar} \leftarrow \text{falso}$

PARA $k \leftarrow 1$ até q : # abandono antecipado

$\text{soma} \leftarrow \text{soma} + (p[k] - p'[k])^2$

SE $\text{soma} > \epsilon^2$:

$\text{abandonar} \leftarrow \text{verdadeiro}$

parar

SE NÃO abandonar:

$\text{occurrences} \leftarrow \text{occurrences} \cup \{j\}$

SE $|\text{occurrences}| \geq \sigma$:

$\text{motifs} \leftarrow \text{motifs} \cup \{ p, \text{occurrences} \}$

retornar motifs

SAÍDA: conjunto de motifs com suas ocorrências

PÓS-CONDIÇÃO: equivalente ao Brute-Force, com menor custo prático

Complexidade: $O(n^2)$ — ganhos empíricos expressivos por abandono antecipado

Medindo Isolamento e Definição de Discord

Para cada subsequência s_i , encontramos seu vizinho mais próximo — a janela mais similar na série. A distância mínima $D(s_i) = \min_{j \neq i} d(s_i, s_j)$ mede o quão longe está até a correspondência mais próxima. Janelas muito sobrepostas ($|i - j| < w$) devem ser ignoradas na comparação para evitar matches triviais. O discord é a janela que, mesmo comparada ao seu par mais similar, permanece a mais diferente: $s^* = \arg \max_{s_i \in S} D(s_i)$.

Extrair janelas de tamanho w

O espaço S contém todas as subsequências $s_t = X_{t:t+w-1}$ da série

Encontrar o vizinho mais próximo de cada janela

Calcular $D(s_i) = \min_{j \neq i} d(s_i, s_j)$ para todo $s_i \in S$

Top- k Discords

As k janelas com maior $D(s_i)$: não é o ponto mais extremo, mas o trecho cuja forma não se repete na série

Se até o vizinho mais próximo está distante, a janela não tem par — ela é um discord.

Abordagem Probabilística

A Ideia Central

Em vez de medir distância, medimos quão improvável é o padrão. A janela é representada como vetor Z_t ; um modelo de densidade aprende as regiões típicas. Discords ocorrem onde a probabilidade é baixa.

$$Z_t = R(X_{t:t+w-1}), \quad \text{discord se } p(Z_t) < h_p$$

Raridade é definida pelo modelo, não por distância a vizinhos. O limiar h_p controla a sensibilidade.

ENTRADA: série X , tamanho de janela w , limiar h_p , representação $R(\cdot)$

PRÉ-CONDIÇÃO: modelo de densidade $p(\cdot)$ treinável sobre vetores de $\mathbb{R}^d$

PASSO 1 — Extração e representação

PARA cada t de 1 até $T-w+1$:

$Z_t \leftarrow R(X_{t:t+w-1})$ ← ex: média, FFT, autoencoder

PASSO 2 — Estimação de densidade

$p(\cdot) \leftarrow \text{AjustarModelo}(\{Z_1, \dots, Z_{T-w+1}\})$

← ex: KDE, GMM, normalizing flow

PASSO 3 — Detecção

PARA cada Z_t :

SE $p(Z_t) < h_p$:

marcar $X_{t:t+w-1}$ como discord

PASSO 4 — Ranking (opcional)

ordenar discords por $p(Z_t) \uparrow$ ← menor prob = mais raro

SAÍDA: conjunto de discords ordenados por raridade probabilística

PÓS-CONDIÇÃO: discords são janelas em regiões de baixa densidade aprendida

Avaliação Formal de Discords

Avaliamos detectores comparando os discords estimados $\hat{D}$ com os reais D . Como discords são janelas, usamos uma tolerância temporal δ para definir quando uma detecção conta como acerto.

Precisão

Dos discords detectados, quantos eram realmente raros?

Revocação

Dos discords reais, quantos foram encontrados?

F1-Score

Equilíbrio entre precisão e revocação.

Na prática, a escolha de δ e do limiar τ afeta diretamente os resultados — não existe avaliação sem definir o que conta como acerto.

STAMP: Matrix Profile Escalável

O Matrix Profile registra, para cada subsequência, a distância ao seu vizinho mais próximo — permitindo descoberta eficiente de motifs e discords.

Algoritmo Anytime

Proposto por Yeh et al. (2016), o STAMP aproxima o Matrix Profile com ordenação aleatória de pares. Pode ser interrompido a qualquer momento e ainda retorna um resultado válido.

Propriedades

- Resultados aproximados para maior velocidade
- Escalável para séries longas
- Amostragem aleatória
- Complexidade: $O(n^2 \log n)$

Quando Usar

Ideal para grandes datasets onde o Matrix Profile exato é inviável e uma aproximação é suficiente.

 **Citação:** Yeh, C.-C. M., et al. (2016). Matrix Profile I: All Pairs Similarity Joins for Time Series. IEEE ICDM.

01 – Descoberta de Motifs com STAMP

O STAMP usa amostragem aleatória para aproximar o Matrix Profile, escalando bem para séries longas. Cada distância de uma subsequência ao seu vizinho mais próximo é calculada.

```
# Carregar pacotes
library(daltoolbox)
library(harbinger)

# Carregar dados
data(examples_motifs)
dataset <- examples_motifs$simple

# Visualizar série
har_plot(harbinger(), dataset$serie)
```

```
# Definir modelo STAMP
# arg2: tamanho da janela
# arg3: número de motifs
model <- hmo_mp("stamp", 4, 3)

# Ajustar e detectar
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)

# Avaliar
evaluation <- evaluate(model,
  detection$event, dataset$event)
print(evaluation$confMatrix)
```

Passo a Passo

- Carregue `daltoolbox` e `harbinger`
- Selecione `examples_motifs$simple`
- Visualize a série antes de ajustar o modelo
- Defina `hmo_mp("stamp", 4, 3)`: janela=4, 3 motifs
- Execute `fit()` → `detect()` → `evaluate()`
- Resultado: 2 VP, 8 FP, 1 FN, 90 VN

📌 **Conceito-chave:** O STAMP aproxima o Matrix Profile via amostragem aleatória — eficiente para séries longas, mas sem garantia de resultado exato.

STOMP: Cálculo Exato do Matrix Profile

O STOMP calcula o Matrix Profile com exatidão garantida, essencial para aplicações que exigem alta precisão.

Exatidão Garantida

Proposto por Zhu et al. (2016), o STOMP calcula o Matrix Profile de forma exata, sem aproximações.

Inovação Computacional

Explora a relação entre produtos escalares consecutivos, evitando cálculos redundantes e superando abordagens de força bruta.

Propriedades

- Resultados exatos
- Otimização por janela deslizante
- Complexidade: $O(n^2)$
- Espaço: $O(n)$

STOMP vs. STAMP

O STAMP oferece aproximação anytime; o STOMP garante exatidão. Ambos têm runtimes similares, mas o STOMP é preferido quando precisão é essencial.

Quando Usar

Ideal quando o Matrix Profile exato é indispensável e o dataset cabe na memória disponível.

📄 **Citação:** Zhu, Y., et al. (2016). Matrix Profile II: Exploiting a Novel Algorithm and GPUs to Break the One Hundred Million Barrier for Time Series Motifs and Joins. IEEE ICDM.

02 – Descoberta de Motifs com STOMP

O STOMP é exato e eficiente para séries longas. Garante o Matrix Profile completo sem aproximações, concluindo em 0,01 seg neste exemplo.

```
# Carregar pacotes e dados
library(daltoolbox)
library(harbinger)
data(examples_motifs)
dataset <- examples_motifs$simple

# Visualizar série bruta
har_plot(harbinger(), dataset$serie)
```

```
# Definir modelo STOMP
# arg2: tamanho da janela
# arg3: número de motifs
model <- hmo_mp("stomp", 4, 3)

# Ajustar e detectar
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)
# Finished in 0.01 secs

# Avaliar contra rótulos
evaluation <- evaluate(model,
  detection$event, dataset$event)
print(evaluation$confMatrix)
## TRUE FALSE
## TRUE  3   8
## FALSE 0  90
```

Passo a Passo

- Mesma estrutura de dados do STAMP
- Basta alterar o argumento para "stomp"
- O STOMP detectou 11 eventos (vs. 10 com o STAMP)
- 3 VP, 8 FP, 0 FN — revocação perfeita neste dataset
- Tempo de execução: 0,01 seg

 **Conceito-chave:** O STOMP calcula o Matrix Profile de forma exata usando ordem aleatória de colunas — mais preciso que o STAMP com custo computacional similar.

SCRIMP: Matrix Profile Incremental e Anytime

O SCRIMP introduz uma abordagem anytime para o cálculo do Matrix Profile, permitindo refinamento progressivo com aproximações válidas a qualquer momento.

Anytime e Incremental

Proposto por Zhu et al. (2018), o SCRIMP processa diagonais da matriz de distâncias em ordem aleatória, fornecendo aproximações válidas em qualquer estágio.

Inovação Principal

Processa diagonais em ordem aleatória, garantindo que qualquer resultado parcial seja uma aproximação válida do Matrix Profile completo.

Propriedades

- Interrompível com resultado válido
- Travessia diagonal aleatória
- Converge para o resultado exato
- Complexidade: $O(n^2)$

SCRIMP vs. STAMP

Ambos são anytime, mas o SCRIMP usa computação diagonal (mais eficiente em cache) em vez da amostragem por colunas do STAMP.

Quando Usar

Ideal para cenários com tempo limitado ou que precisam de refinamento progressivo do Matrix Profile.

 **Citação:** Zhu, Y., et al. (2018). Matrix Profile XI: SCRIMP++: Time Series Motif Discovery at Interactive Speeds. IEEE ICDM.

03 – Descoberta de Motifs com SCRIMP

O SCRIMP é um algoritmo incremental (anytime): aproxima progressivamente o Matrix Profile e pode ser interrompido a qualquer momento.

```
# Carregar pacotes e dados
library(daltoolbox)
library(harbinger)
data(examples_motifs)
dataset <- examples_motifs$simple

# Visualizar série bruta
har_plot(harbinger(), dataset$serie)
```

```
# Definir modelo SCRIMP
model <- hmo_mp("scrimp", 4, 3)

# Ajustar e detectar
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)
# Finished in 0.03 secs

# Avaliar
evaluation <- evaluate(model,
  detection$event, dataset$event)
print(evaluation$confMatrix)
## TRUE FALSE
## TRUE  2   8
## FALSE 1  90
```

Passo a Passo

- Substitua o algoritmo por "scrimp"
- Janela=4, 3 motifs — mesmos parâmetros
- Resultado idêntico ao STAMP: 2 VP, 8 FP, 1 FN
- Tempo: 0.03 seg (ligeiramente mais lento)
- Útil quando o tempo de execução é limitado

📌 **Conceito-chave:** O SCRIMP é um algoritmo *anytime* — pode ser interrompido e ainda retorna uma aproximação válida do Matrix Profile.

PMP: O Pan Matrix Profile

O PMP estende o Matrix Profile para analisar séries temporais em múltiplos tamanhos de janela simultaneamente, oferecendo uma visão holística dos padrões em diferentes escalas.

Conceito Estendido

Proposto por Linardi et al. (2020), o PMP computa e consolida Matrix Profiles para uma faixa de tamanhos de janela, em vez de apenas um fixo.

Agnóstico ao Tamanho de Janela

Revela motifs robustos em diferentes escalas, com maior precisão e menos falsos positivos que abordagens de janela única.

Eliminação de Hiperparâmetro

Elimina a necessidade de ajustar manualmente o tamanho da janela — frequentemente o hiperparâmetro mais difícil de calibrar.

Casos de Uso Ideais

Melhor para análise exploratória onde a escala ótima do padrão é desconhecida.



Citação: Linardi, M., et al. (2020). VALMOD: A Suite for Easy and Exact Detection of Variable Length Motifs in Data Series. ACM SIGMOD.

VALMOD: Descoberta de Motifs de Comprimento Variável

O VALMOD estende o Matrix Profile para descobrir padrões de comprimentos variados, adaptando-se às escalas inerentes dos motifs.

Conceito Central

Proposto por Linardi et al. (2018), o VALMOD busca motifs em uma faixa de comprimentos $[l_{min}, l_{max}]$, sem exigir janela fixa.

Busca Eficiente

Usa técnica de lower-bounding para podar o espaço de busca e garantir resultados exatos.

Propriedades

- Suporte a subsequências de comprimento variável.
- Atualizações incrementais e streaming.
- Descoberta exata na faixa especificada.
- Distância normalizada por comprimento.

VALMOD vs. PMP

Enquanto o PMP consolida perfis para todos os tamanhos, o VALMOD foca no **melhor motif único** em um espectro de comprimentos.

Quando Usar

- Ambientes de streaming onde dados chegam continuamente.
- Quando o comprimento ótimo do motif é desconhecido.

📄 **Citação:** Linardi, M., et al. (2018). Matrix Profile X: VALMOD — Scalable Discovery of Variable-Length Motifs in Data Series. ACM SIGMOD.

Resumo: Todos os Métodos

Todos os métodos seguem o mesmo pipeline no harbinger: `fit()` → `detect()` → `evaluate()`. A tabela compara os nove notebooks por família, estratégia e resultados no dataset `examples_motifs$simple` (motifs) ou `mitdb102` (discords).

Algoritmo	Família	Estratégia	Resultado (TP/FP/FN)	Tempo
STAMP	Matrix Profile	Amostragem aleatória (aprox.)	2 / 8 / 1	0.02 sec
STOMP	Matrix Profile	Exato, ordem aleatória	3 / 8 / 0	0.01 sec
SCRIMP	Matrix Profile	Incremental (anytime)	2 / 8 / 1	0.03 sec
PMP	Matrix Profile	Multi-janela unificado	3 / 4 / 0	—
VALMOD	Matrix Profile	Streaming, comprimento variável	3 / 8 / 0	0.02 sec
SAX	Simbólico	Frequência de palavras simbólicas	3 / 0 / 0	—
XSAX	Simbólico	Alfabeto alfanumérico estendido	3 / 0 / 0	—
STOMP (discord)	Discord · MP	Máx. distância ao vizinho mais próximo	0 / 4 / 3	—
SAX (discord)	Discord · Simbólico	Palavras simbólicas raras	0 / 121 / 3	—

SAX – Symbolic Aggregate approXimation

O SAX converte séries temporais numéricas em sequências de caracteres (palavras simbólicas), tornando a busca por motivos — padrões repetitivos — muito mais eficiente. Em vez de comparar valores brutos, comparamos palavras de um alfabeto finito.

Como Funciona o SAX

Normalização Z

A subsequência é normalizada para média zero e desvio padrão unitário, eliminando dependências de escala e deslocamento.

PAA – Piecewise Aggregate Approximation

A série normalizada é dividida em **w** segmentos de igual comprimento. A média de cada segmento gera uma representação compacta com **w** valores.

Discretização Simbólica

Cada valor PAA é mapeado a uma letra do alfabeto usando *breakpoints* gaussianos, produzindo uma **palavra simbólica** de comprimento **w**.

Motivos são palavras simbólicas que se repetem com alta frequência. Com `hmo_sax(26, 3, 3)` — alfabeto de 26 letras e palavra de comprimento 3 — cada subsequência torna-se uma palavra de 3 letras. O motivo "QST" foi detectado 3 vezes, nos índices 25, 50 e 75.

Parâmetros Principais

Tamanho do Alfabeto (*a*)

Controla a resolução simbólica. Mais letras = distinções mais finas entre valores PAA. Exemplo: `a = 26`.

Comprimento da Palavra (*w*)

Controla a granularidade temporal. Palavras mais longas = padrões mais específicos. Exemplo: `w = 3`.

Ocorrências Mínimas

Número mínimo de repetições para que uma palavra simbólica seja considerada um motivo. Exemplo: `min_occurrences = 3`.

Referência: Lin, J., Keogh, E., Lonardi, S., Chiu, B. (2007). A symbolic representation of time series, with implications for streaming algorithms. *Data Mining and Knowledge Discovery*, 15, 107–144.

XSAX – Representação Simbólica Estendida

O **XSAX** (Extended SAX) é uma extensão direta do SAX que substitui o alfabeto de letras por um alfabeto alfanumérico (dígitos 0–9 + letras A–Z), aumentando a resolução simbólica. O pipeline é idêntico ao SAX — z-normalização, PAA e mapeamento simbólico — mas com mais símbolos disponíveis para capturar variações de amplitude mais finas.

SAX

- **Alfabeto:** apenas letras (ex: a=26)
- **Palavra detectada:** "QST"
- **Resolução:** mais grosseira — intervalos de amplitude mais amplos por símbolo
- Ideal para padrões amplos e dados de baixa variação de amplitude

XSAX

- **Alfabeto:** dígitos + letras (ex: a=37: 0–9 e A–Z + 1)
- **Palavra detectada:** "0N0P0R" (cada segmento PAA gera 2 caracteres)
- **Resolução:** mais fina — distingue variações sutis de amplitude
- Ideal para séries com alta variabilidade de amplitude

Prefira o XSAX quando pequenas flutuações de amplitude são relevantes para a identificação de eventos ou motifs. Na mesma série sintética do exemplo SAX, o XSAX encontrou os mesmos índices (25, 50, 75), mas representou o motif com a palavra simbólica mais expressiva "0N0P0R" — preservando nuances que o alfabeto menor do SAX não consegue distinguir.

Referência: Ogasawara, E., Salles, R., Porto, F., Pacitti, E. *Event Detection in Time Series*. Springer, 2025. doi:10.1007/978-3-031-75941-3

08 – Descoberta de Discords com STOMP (hdis_mp)

Discords são subsequências maximamente dissimilares — o inverso dos motifs. O Matrix Profile identifica aquelas com maior distância ao vizinho mais próximo. Dataset: ECG `mitdb102`.

```
# Carregar pacotes e dados
library(daltoolbox)
library(harbinger)
data(examples_motifs)

# Dataset ECG com anomalias anotadas
dataset <- examples_motifs$mitdb102

# Visualizar série
har_plot(harbinger(), dataset$serie)
```

```
# Definir modelo de discord (STOMP)
# w: tamanho da janela (25)
# qtd: número de discords (10)
model <- hdis_mp(mode = "stomp",
                 w = 25, qtd = 10)

# Ajustar e detectar
model <- fit(model, dataset$serie)
suppressMessages(
  detection <- detect(model, dataset$serie))

# Avaliar
evaluation <- evaluate(model,
                       detection$event, dataset$event)
print(evaluation$confMatrix)

## TRUE FALSE
## TRUE  0   4
## FALSE 3 7195
```

Passo a Passo

- Use `hdis_mp()` em vez de `hmo_mp()`
- Dataset: ECG `mitdb102` (~7.200 pontos)
- Janela=25, recuperar 10 discords
- 4 eventos detectados nos índices 2602, 3844, 4017, 6135
- 0 VP, 4 FP, 3 FN — os discords não coincidem com os rótulos de referência

📌 **Conceito-chave:** Discord = a subsequência com a *maior* distância ao seu vizinho mais próximo no Matrix Profile. Inverte a lógica do motif: busca o que é raro, não o que se repete.

09 – Descoberta de Discords com SAX (hdis_sax)

A descoberta de discords por SAX identifica subsequências raras discretizando a série e encontrando palavras únicas com alta entropia. Dataset: ECG mitdb102. Detecta 121 discords.

```
# Carregar pacotes e dados
library(daltoolbox)
library(harbinger)
data(examples_motifs)

# Dataset ECG com anomalias
dataset <- examples_motifs$mitdb102

# Visualizar série bruta
har_plot(harbinger(), dataset$serie)
```

```
# Configurar SAX para discords
# arg1: alfabeto (26)
# arg2: tamanho da palavra/janela (25)
model <- hdis_sax(26, 25)

# Ajustar e detectar
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)
# 121 eventos detectados

# Avaliar
evaluation <- evaluate(model,
  detection$event, dataset$event)
print(evaluation$confMatrix)
## TRUE FALSE
## TRUE  0 121
## FALSE 3 7078
```

Passo a Passo

- Use `hdis_sax(alfabeto, janela)` — sem parâmetro de quantidade
- Alfabeto=26, janela=25 (tamanho da palavra simbólica)
- 121 discords detectados — muito mais do que a abordagem do Matrix Profile
- 0 VP, 121 FP, 3 FN — alta sensibilidade, baixa precisão
- Discords simbólicos capturam variação local, não anomalias globais

📌 **Conceito-chave:** O discord SAX encontra palavras simbólicas raras — detecta muitas regiões incomuns, mas pode não coincidir com anomalias clinicamente rotuladas.

Resumo: Métodos Simbólicos e Análise de Discords

Descoberta de Motifs – SAX

`hmo_sax(a, w, min)` — Use para encontrar **padrões repetidos**. Converte subsequências em palavras simbólicas; motifs são as palavras mais frequentes. Rápido e interpretável.

Descoberta de Discords – Matrix Profile (STOMP)

`hdis_mp(mode="stomp", w, qtd)` — Use para encontrar **subsequências globalmente anômalas**. Calcula distâncias ao vizinho mais próximo via MASS. Preciso, mas pode perder eventos rotulados clinicamente.

Descoberta de Motifs – XSAX

`hmo_xsax(a, w, min)` — Extensão do SAX com alfabeto alfanumérico maior. Use quando a série tem **alta variabilidade de amplitude** e é necessária maior resolução simbólica.

Descoberta de Discords – SAX

`hdis_sax(a, w)` — Use quando **alta sensibilidade** a regiões locais incomuns é necessária. Encontra palavras simbólicas raras; alto recall, baixa precisão.

O que cobrimos na Parte 7

Motifs e Discords: padrões recorrentes (motifs) e subsequências anômalas (discords) como objetos centrais da análise de séries temporais

Escala e domínio dos motifs: motifs ocorrem no sinal bruto ou em componentes transformados – tendência, sazonalidade, resíduos e derivadas

Estrutura conceitual: três pilares – comprimento de janela m , função de distância $d(\cdot, \cdot)$ e critério de não-trivialidade

Motifs e sazonalidade: padrões sazonais como caso especial de motif com periodicidade conhecida

Definição matemática: motif como par (i^*, j^*) que minimiza $d(s_i, s_j)$; discord como s_i^* que maximiza $D(s_i) = \min_j d(s_i, s_j)$

Indexação com PAA e SAX: compressão e discretização da série para busca eficiente de padrões

Métodos de descoberta: Brute-Force ($O(n^2)$), Index-Based (PAA+SAX), Random-Projection e Early-Abandon Distance – trade-off exatidão $\times$ custo

Abordagem probabilística de discords: densidade de probabilidade como alternativa à distância – regiões de baixa densidade sinalizam anomalia

Avaliação com tolerância δ : matching temporal com janela δ define TP, FP, FN – métricas de precisão e recall variam com δ

Matrix Profile – STAMP, STOMP, SCRIMP: distância ao vizinho mais próximo para cada subsequência – base unificada para motifs e discords

PMP e VALMOD: extensões do Matrix Profile para múltiplos tamanhos de janela simultâneos e comprimentos variáveis de motif

Resumo comparativo dos métodos: nove abordagens por família, estratégia e desempenho no dataset `examples_motifs$simple`

SAX e XSAX: discretização simbólica da série – motifs como palavras frequentes, discords como palavras raras

Resumo final: quatro funções harbinger – `hmo_sax`, `hmo_xsax`, `hdis_mp` e `hdis_sax` – com casos de uso e trade-offs